

**UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE TECNOLOGIA
PROGRAMA DE PÓS-GRADUAÇÃO EM INFORMÁTICA**

**CLASSIFICAÇÃO DE ESTÁGIOS DE SONO
ATRAVÉS DA APLICAÇÃO DE
TRANSFORMADA WAVELET DISCRETA
SOBRE UM ÚNICO CANAL DE
ELETROENCEFALOGRAMA**

DISSERTAÇÃO DE MESTRADO

Thiago Lopes Trugillo da Silveira

Santa Maria, RS, Brasil

2016

**CLASSIFICAÇÃO DE ESTÁGIOS DE SONO ATRAVÉS DA
APLICAÇÃO DE TRANSFORMADA WAVELET DISCRETA
SOBRE UM ÚNICO CANAL DE ELETROENCEFALOGRAMA**

Thiago Lopes Trugillo da Silveira

Dissertação apresentada ao Curso de Mestrado Programa de
Pós-Graduação em Informática (PPGI), Área de Concentração em
Computação, da Universidade Federal de Santa Maria (UFSM, RS),
como requisito parcial para obtenção do grau de
Mestre em Ciência da Computação

Orientadora: Prof^a. Dr^a. Alice de Jesus Kozakevicius

Co-orientador: Prof. Dr. Cesar Ramos Rodrigues

Santa Maria, RS, Brasil

2016

da Silveira, Thiago Lopes Trugillo

Classificação de Estágios de Sono Através da Aplicação de Transformada *Wavelet* Discreta Sobre um Único Canal de Eletroencefalograma / por Thiago Lopes Trugillo da Silveira. – 2016.

92 f.: il.; 30 cm.

Orientadora: Alice de Jesus Kozakevicius

Co-orientador: Cesar Ramos Rodrigues

Dissertação (Mestrado) - Universidade Federal de Santa Maria,
Centro de Tecnologia, Programa de Pós-Graduação em Informática, RS,
2016.

1. Transformada *wavelet* discreta (DWT).
 2. Classificação do sono.
 3. Sinais de eletroencefalograma (EEG).
- I. Kozakevicius, Alice de Jesus. II. Rodrigues, Cesar Ramos. III. Título.

**Universidade Federal de Santa Maria
Centro de Tecnologia
Programa de Pós-Graduação em Informática**

A Comissão Examinadora, abaixo assinada,
aprova a Dissertação de Mestrado

**CLASSIFICAÇÃO DE ESTÁGIOS DE SONO ATRAVÉS DA APLICAÇÃO
DE TRANSFORMADA WAVELET DISCRETA SOBRE UM ÚNICO
CANAL DE ELETROENCEFALOGRAMA**

elaborada por
Thiago Lopes Trugillo da Silveira

como requisito parcial para obtenção do grau de
Mestre em Ciência da Computação

COMISSÃO EXAMINADORA:

Alice de Jesus Kozakevicius, Dr^a.
(Presidente/Orientadora)

Giovani Baratto, Dr. (UFSM)

Carla Diniz Lopes Becker, Dr^a. (UFPel)

Santa Maria, 25 de Janeiro de 2016.

À sociedade...

AGRADECIMENTOS

Agradeço a todos que estiveram comigo durante todo esse tempo e que, de uma forma ou outra, contribuíram para a realização deste trabalho. Em especial, agradeço à minha mãe, Ilse Trindade Lopes, meu pai, André Trugillo da Silveira, e a todos os demais familiares. Agradeço enormemente à minha namorada, Samara Dias Osorio, pelo carinho e amor que, dela, sempre recebi.

Agradeço também a todos meus professores pelos mais diversos ensinamentos, incentivos e conselhos. Agradeço aos, não somente orientadores, mas também amigos: Professora Dr^a. Alice Kozakevicius e Professor Dr. Cesar Rodrigues, que estiveram sempre presentes durante esses dois anos. Agradeço também aos Professores Dr. Giovani Baratto e Dr^a. Carla Becker por terem aceito fazer parte da banca avaliadora deste trabalho e contribuído para com a discussão do mesmo.

Um especial agradecimento aos meus amigos e colegas de curso com quem compartilhei ensinamentos, discussões e momentos de descontração. Agradeço também à Coordenação de Aperfeiçoamento de Pessoal de Nível Superior (CAPES) pelo auxílio financeiro, permitindo que eu pudesse concentrar meus esforços no desenvolvimento deste e outros trabalhos relacionados.

Um enorme agradecimento a todos aqueles que não foram diretamente citados, mas que certamente contribuíram muito para que eu chegasse até aqui.

“Whatever you’re thinking... think bigger.”
— TONY HSIEH

RESUMO

Dissertação de Mestrado
Programa de Pós-Graduação em Informática
Universidade Federal de Santa Maria

CLASSIFICAÇÃO DE ESTÁGIOS DE SONO ATRAVÉS DA APLICAÇÃO DE TRANSFORMADA WAVELET DISCRETA SOBRE UM ÚNICO CANAL DE ELETROENCEFALOGRAMA

AUTOR: THIAGO LOPES TRUGILLO DA SILVEIRA

ORIENTADORA: ALICE DE JESUS KOZAKEVICIUS

CO-ORIENTADOR: CESAR RAMOS RODRIGUES

Local da Defesa e Data: Santa Maria, 25 de Janeiro de 2016.

A correta classificação dos estágios de sono possibilita que especialistas possam diagnosticar e tratar distúrbios como apneia, narcolepsia e insônia. Tal tarefa é classicamente feita por médicos do sono, na qual um ou mais sinais fisiológicos são visualmente inspecionados. Por serem considerados bons indicadores para análise do sono, sinais de eletroencefalograma (EEG) são amplamente utilizados como entrada para tal procedimento. Entretanto, a classificação adequada de uma noite de sono pode demorar de duas a quatro horas de análise, além de ser frequentemente realizada por um par de especialistas. O presente trabalho apresenta um novo sistema de apoio à decisão, com o objetivo de facilitar a tarefa destes especialistas. A metodologia proposta é baseada na análise multirresolução de um único canal de EEG através da aplicação da transformada *wavelet* discreta (DWT). Métodos que consideram apenas um canal de EEG para classificação de estágios de sono têm reduzido custo computacional e os dispositivos de aquisição envolvidos são mais simples de usar em comparação com aqueles que consideram vários canais. Após a decomposição do sinal através da DWT, características estatísticas de ritmos cerebrais relacionados ao sono são extraídas e alimentam um classificador. Neste trabalho, florestas aleatórias são utilizadas para classificação. Em testes, é considerado um conjunto de 39 sinais correspondente a 20 voluntários de um banco de dados público. O desempenho do método proposto é avaliado através de técnicas como validação cruzada, na qual são atingidas acuráncias maiores do que 90% e coeficientes *kappa* maiores do que 0.8 para as classificações de 2 a 6 estados de estágios de sono. O método proposto atinge resultados melhores do que, ou ao menos comparáveis a, de outros trabalhos no estado da arte em todos os cenários analisados.

Palavras-chave: Transformada *wavelet* discreta (DWT). classificação do sono. sinais de eletroencefalograma (EEG).

ABSTRACT

Master's Dissertation
Graduate Program in Informatics
Federal University of Santa Maria

SLEEP STAGES CLASSIFICATION THROUGH APPLICATION OF THE DISCRETE WAVELET TRANSFORM ON A SINGLE ELECTROENCEPHALOGRAM CHANNEL

AUTHOR: THIAGO LOPES TRUGILLO DA SILVEIRA

ADVISOR: ALICE DE JESUS KOZAKEVICIUS

COADVISOR: CESAR RAMOS RODRIGUES

Defense Place and Date: Santa Maria, January 25th, 2016.

The correct sleep stage classification allows sleep experts to diagnose and treat disorders such as apnea, narcolepsy and insomnia. Such task is classically performed by sleep medicine experts, where one or more physiological signals are visually inspected. Since electroencephalogram (EEG) signals are considered good indicators for sleep analysis, they are widely used for sleep stage scoring. Although, the adequate sleep classification for a single night of sleep can demand from two to four hours of analysis, being frequently performed by two experts. The current study presents a novel decision support system, aiming to facilitate this experts' task. The proposed methodology is based on the multi-resolution analysis of a single EEG channel through the application of the discrete wavelet transform (DWT). Methodologies which consider only one EEG channel for sleep scoring have reduced computational cost and the related acquisition equipments are easier to use in comparison with the multi-channel ones. Afterwards the signal decomposition by DWT, statistical features from sleep related brain rhythms are extracted and feed a classifier. Random forests are used for classification task in the current study. A set of 39 signals corresponding to 20 volunteers of a public database is considered. The performance of the proposed method is evaluated through techniques such as cross-validation, where accuracies keep higher than 90% and kappa coefficient higher than 0.8 are achieved for 2 to 6 states of sleep stages. The introduced method achieves better, or at least comparable, results when compared with state-of-the-art studies in all analyzed scenarios.

Keywords: Discrete wavelet transform (DWT). sleep classification. electroencephalogram (EEG) signals.

LISTA DE FIGURAS

<p>Figura 2.1 – Estrutura básica de uma célula neural em sinapse com outra célula neural. Figura adaptada de (PFEIL, 2015).</p> <p>Figura 2.2 – Esquema para colocação de 35 eletrodos no escâlpo e 2 referenciais (A1 e A2) nas orelhas de acordo com o sistema de posicionamento 10-20. O canal destacado (Pz-Oz) é utilizado neste estudo. Figura adaptada de (HUNTER et al., 2005).</p> <p>Figura 2.3 – Sinal completo (a) e épocas de 30 segundos da segunda noite de sono do sujeito de número 11. De acordo com as anotações do banco de dados, respectivamente, as épocas de posição 310, 1196, 1592, 1370, 1522 e 1430 são características dos estados (b) W, (c) S1, (d) S2, (e) S3, (f) S4 e (g) REM.</p> <p>Figura 2.4 – Vetor exemplo C_2 visto como (a) uma sequência de pontos e (b) função constante por partes. Vetores (c) C_1 e (d) C_0 vistos como funções constantes por partes.</p> <p>Figura 2.5 – Funções $\phi_0^0(x)$ e $\psi_0^0(x)$, respectivamente, em (a) e (b); $\phi_i^1(x)$ com $i = 0, 1$ em (c) e (d) e $\psi_i^1(x)$ com $i = 0, 1$ em (e) e (f).</p> <p>Figura 2.6 – Diferentes combinações lineares do vetor exemplo C_2. Em (a) têm-se $C_2 = 2\phi_0^2(x) + 0\phi_1^2(x) + 1\phi_2^2(x) + 5\phi_3^2(x)$; (b) têm-se $C_2 = 1\phi_0^1(x) + 3\phi_1^1(x) + 1\psi_0^1(x) + (-2)\psi_1^1(x)$ e (c) $C_2 = 2\phi_0^0(x) + (-1)\psi_0^0(x) + 1\psi_0^1(x) + (-2)\psi_1^1(x)$.</p> <p>Figura 2.7 – Análise multirresolução de Haar não-normalizada sobre um conjunto de dados exemplo $C_4 = [72 \ 128 \ 130 \ 104 \ 72 \ 46 \ 28 \ 18 \ 16 \ 18 \ 22 \ 26 \ 28 \ 30 \ 32 \ 32]$. Adaptação de (STOLLNITZ; DEROSE; SALESIN, 1995).</p> <p>Figura 2.8 – Funções $\phi_k^2(x)$ com $k = 0, 1, 2$ e 3, respectivamente, em (a – d) e $\psi_k^2(x)$ com $k = 0, 1, 2$ e 3, respectivamente, em (e – h).</p> <p>Figura 2.9 – Primeira, segunda, $l - 2$-ésima e $l - 1$-ésima iterações da aplicação do algoritmo de decomposição wavelet com $D = 4$ para encontrar C_{j-1} a partir de C_j. Coeficientes destacados são usados no cálculo na respectiva iteração. O processo para encontrar D_{j-1} é análogo.</p> <p>Figura 2.10 – Pseudo-algoritmo para cálculo da transformada direta de Daubechies para vetores de entrada com tamanho par. Os parâmetros do procedimento C_j, h, g, E, e D são, respectivamente, os coeficientes de escala no j-ésimo nível, os filtros de escala, os filtros wavelet, as amostras extrapoladas no nível j e duas vezes o número de momentos nulos ($D = 4$). O procedimento retorna C_{j-1} e D_{j-1} que são os conjuntos de coeficientes de escala e wavelet em um nível mais grosso $j - 1$, cada um contendo metade da quantidade de valores do vetor original.</p> <p>Figura 2.11 – Decomposição wavelet em cinco níveis, faixas de frequência em cada nível e ritmos cerebrais associados. Conjuntos de coeficientes destacados em cinza são utilizados na etapa de redução de dimensionalidade. Este esquema de decomposição wavelet considera o sinal de entrada \tilde{C}_5 com frequência de amostragem de 100Hz.</p> <p>Figura 2.12 – Decomposição wavelet em cinco níveis da 1800^a época da segunda noite do sujeito de número 11. Neste momento, de acordo com os especialistas do PhysioBank, este encontra-se em S4.</p>	<p>26</p> <p>29</p> <p>32</p> <p>38</p> <p>40</p> <p>43</p> <p>45</p> <p>46</p> <p>48</p> <p>49</p> <p>50</p> <p>51</p>
---	---

Figura 2.13 – Variância, curtose (multiplicada por 5) e assimetria (multiplicada por 15) dos coeficientes <i>wavelet</i> em cada um dos cinco níveis de decomposição e do último conjunto de coeficientes de escala (de cima para baixo, respectivamente) da segunda noite do sujeito de número 02. As cores de fundo branco, cinza claro e cinza escuro correspondem, respectivamente, aos estágios W, S1 e S2, de acordo com as anotações do banco de dados.	54
Figura 2.14 – Arquitetura de um classificador do tipo floresta aleatória. Figura adaptada de (FRAIWAN et al., 2012).	56
Figura 2.15 – Fluxograma da metodologia proposta e a técnica de <i>k-fold cross validation</i> para avaliação de seu desempenho.....	57
Figura D.1 – Remoção de linha base: (a) terceira época da segunda noite de sono do sujeito de número 00, (b) sua linha base, e (c) época sem sua linha base.	90

LISTA DE TABELAS

Tabela 2.1 – Distribuição das classes dos dados válidos da base <i>Sleep EDF [Expanded]</i> ..	33
Tabela 2.2 – Coeficientes de filtro não-normalizados e normalizados para DWT de Haar ..	44
Tabela 2.3 – Exemplo de aplicação da transformada de Haar não-normalizada	44
Tabela 2.4 – Exemplo de aplicação da transformada de Haar normalizada	45
Tabela 2.5 – Coeficientes de filtro normalizados para Db2	47
Tabela 3.1 – Interpretação qualitativa do coeficiente <i>kappa</i> de LANDIS; KOCH (1977) ..	59
Tabela 3.2 – Matriz de confusão para a classificação de 2 estados de estágios de sono	60
Tabela 3.3 – Matriz de confusão para a classificação de 3 estados de estágios de sono	61
Tabela 3.4 – Matriz de confusão para a classificação de 4 estados de estágios de sono	62
Tabela 3.5 – Matriz de confusão para a classificação de 5 estados de estágios de sono	63
Tabela 3.6 – Análise comparativa para a classificação de 5 estados de estágios de sono ...	64
Tabela 3.7 – Matriz de confusão para a classificação de 6 estados de estágios de sono	65
Tabela 3.8 – Acurárias e coeficientes <i>kappa</i> para classificações de 2 a 6 estados de está- gios de sono	65
Tabela 3.9 – Comparação de metodologia com FRAIWAN et al. (2012).....	67
Tabela 3.10 – Comparação de desempenho com ZHU; LI; WEN (2014).	68
Tabela B.1 – Acurácia (%) e tempos (s) de treino e teste dos algoritmos avaliados nas classificações de 2 a 6 estados de estágios de sono	83

LISTA DE APÊNDICES

APÊNDICE A – TRABALHO APRESENTADO NO PRIMER ENCUENTRO DE JÓVENES INVESTIGADORES EN MATEMÁTICA APLICADA DE LA AUGM	81
APÊNDICE B – DESEMPENHO DE ALGORITMOS DE CLASSIFICAÇÃO DA FERRAMENTA WEKA	82
APÊNDICE C – TRABALHO APRESENTADO NO XXX SIMPÓSIO SUL DE MICROELETRÔNICA	85
APÊNDICE D – REVOCAÇÃO DE S1 × PRÉ-PROCESSAMENTO	89
APÊNDICE E – PRODUÇÃO CIENTÍFICA	91

LISTA DE ABREVIATURAS E SIGLAS

AASM	Academia Americana de Medicina do Sono
ANN	Rede neural artificial
CV	Validação cruzada
CWT	Transformada <i>wavelet</i> contínua
ddp	Diferença de potencial
Db1	Transformada <i>wavelet</i> de Haar
Db2	Transformada <i>wavelet</i> de Daubechies com dois momentos nulos
DFT	Transformada discreta de Fourier
DVG	Grafo de diferença de visibilidade
DWT	Transformada <i>wavelet</i> discreta
ECG	Eletrocardiograma / eletrocardiografia
ECoG	Eletrocorticograma / eletrocorticografia
EDF	<i>European Data Format</i>
EDF+	<i>European Data Format plus</i>
EEG	Eletroencefalograma / eletroencefalografia
EMG	Eletromiograma / eletromiografia
EOG	Eletrooculograma / eletrooculografia
FT	Transformada de Fourier
FFT	Transformada rápida de Fourier
FNN	Rede neural do tipo <i>feedforwarded</i>
GNU	<i>General Public License</i>
HVG	Grafo de visibilidade horizontal
k-NN	k-vizinhos mais próximos
LDA	Análise de discriminantes lineares
MDH	Tempo maior do que 12 horas
NA	Não avaliado
NREM	Movimento não-rápido dos olhos
OMS	Organização Mundial da Saúde
PNN	Rede neural probabilística
PSG	Polissonógrafo / polissonografia
QDA	Análise de discriminantes quadráticos
R&K	Rechtschaffen e Kales

REM	Movimento rápido dos olhos
S1	Estágio de sono 1
S2	Estágio de sono 2
S3	Estágio de sono 3
S4	Estágio de sono 4
STFT	Transformada de Fourier de tempo-curto
SLP	Estágio dormindo
SVM	Máquinas de vetores de suporte
SWS	Sono de ondas lentas
W	Estágio acordado
WEKA	<i>Waikato Environment for Knowledge Analysis</i>
WPT	Transformada <i>wavelet packet</i>
WT	Transformada <i>wavelet</i>

LISTA DE SÍMBOLOS

C_j	Coeficiente <i>wavelet</i> de escala de nível j
D_j	Coeficiente <i>wavelet</i> de detalhe de nível j
$\phi_i^j(x)$	Função escala de uma DWT com escala j e deslocamento i
$\psi_i^j(x)$	Função <i>wavelet</i> de uma DWT com escala j e deslocamento i
V^j	Espaço vetorial gerado por todas as translações de $\phi_i^j(x)$
W^j	Espaço vetorial gerado por todas as translações de $\psi_i^j(x)$
$L^2(\mathbb{R})$	Espaço vetorial de todas as funções integráveis em \mathbb{R} cujo quadrado também é integrável em \mathbb{R}
h	Espaçamento entre pontos de um vetor em V^j ou W^j
h_k	Coeficiente de filtro da função escala de posição k
g_k	Coeficiente de filtro da função <i>wavelet</i> de posição k
M	Número de momentos nulos da <i>wavelet</i>
$D = 2M$	Quantidade de filtros associados à <i>wavelet</i>
L	Tamanho de um vetor de dados em V^j
R	Parcela ímpar do tamanho de um vetor de dados em V^j
K	Logaritmo da parcela par do tamanho de um vetor de dados em V^j
X	Conjunto de dados
$\text{Kurt}(X)$	Curtose de X
$\text{Skew}(X)$	Assimetria de X
$\text{Var}(X)$	Variância de X
\bar{X}	Valor médio de X
T	Quantidade de amostras em X
F	Quantidade de atributos utilizados para o crescimento de cada árvore da floresta aleatória
P	Quantidade total de atributos de cada instância do conjunto de dados
N	Quantidade de árvores da floresta aleatória
\mathbf{M}	Matriz de confusão
Q	Ordem da matriz de confusão
$\text{Acc}(\mathbf{M})$	Acurácia de uma matriz de confusão \mathbf{M}
$\text{Pre}(\mathbf{M}, i)$	Precisão da classe i de uma matriz de confusão \mathbf{M}
$\text{Rec}(\mathbf{M}, i)$	Revocação da classe i de uma matriz de confusão \mathbf{M}
$\kappa(\mathbf{M})$	Coeficiente <i>kappa</i> de uma matriz de confusão \mathbf{M}
$\text{EA}(\mathbf{M})$	Conformidade esperada de uma matriz de confusão \mathbf{M}

SUMÁRIO

1 INTRODUÇÃO.....	18
1.1 Motivação e objetivos	18
1.2 Estado da arte e proposta de trabalho	21
1.3 Estrutura do texto	24
2 MATERIAIS E MÉTODOS	25
2.1 Sinais cerebrais, eletroencefalografia e base de dados	25
2.1.1 Sinais cerebrais.....	25
2.1.2 Eletroencefalografia	28
2.1.3 Base de dados <i>Sleep EDF [Expanded]</i>	30
2.2 Pré-processamento	34
2.2.1 Divisão dos sinais em épocas	34
2.2.2 Remoção de épocas inválidas.....	36
2.3 Extração de características	36
2.3.1 Transformada <i>wavelet</i> discreta (DWT).....	36
2.3.1.1 DWT de Haar	37
2.3.1.2 DWT de Daubechies	45
2.3.2 Redução de dimensionalidade e seleção de atributos	52
2.4 Classificação	53
2.4.1 <i>Waikato Environment for Knowledge Analysis</i> (WEKA)	53
2.4.2 Florestas aleatórias	55
2.5 Fluxograma do método.....	57
3 RESULTADOS E DISCUSSÕES.....	58
3.1 Experimento e métricas de avaliação	58
3.2 Desempenho geral da metodologia	60
3.3 Outras avaliações da metodologia	66
3.3.1 Comparação com FRAIWAN et al. (2012)	66
3.3.2 Comparação com ZHU; LI; WEN (2014)	67
4 CONCLUSÕES.....	69
5 TRABALHOS FUTUROS	71
REFERÊNCIAS	72
APÊNDICES.....	80

1 INTRODUÇÃO

Segundo a Organização Mundial da Saúde (OMS) (WHO, 2004), o ser humano gasta quase um terço de sua vida dormindo. A OMS argumenta que manter uma boa qualidade de sono é essencial para se desfrutar de saúde e bem-estar. Entretanto, o estilo de vida da atual sociedade está desencadeando sérios problemas relacionados à privação de sono (PANDI-PERUMAL et al., 2006). As principais consequências da restrição crônica do sono incluem efeitos físicos (sonolência, fadiga e hipertensão), disfunções cognitivas (deterioração do desempenho em tarefas, quedas de atenção, memória e motivação e diminuição da capacidade intelectual) e, em instâncias mais graves, complicações mentais (WHO, 2004). Estima-se que, pelo menos, 45% da população mundial esteja afetada por algum tipo de desordem relacionada ao sono (NOOR et al., 2014).

1.1 Motivação e objetivos

Para que médicos especialistas possam intervir em transtornos relacionados ao sono, faz-se necessário o entendimento dos padrões das atividades cerebrais durante este período, uma vez que o processo de sonolência dá-se através do tronco cerebral (KRYGER; ROTH; DEMENT, 2011). A correta classificação, ou rotulagem, dos estágios de sono possibilita que esses especialistas possam diagnosticar e tratar distúrbios como apneia, narcolepsia e insônia (ZHU; LI; WEN, 2014; FRAIWAN et al., 2012; COLE et al., 1992). Esta rotulagem é classicamente feita por médicos do sono através da inspeção visual de sinais fisiológicos captados em clínicas especializadas (TEPLAN, 2002). Tais sinais são obtidos por meio de equipamentos de polissonografia (PSG) que frequentemente contêm canais¹ de eletroencefalograma (EEG), elektromiograma (EMG), eletrooculograma (EOG) e eletrocardiograma (ECG) (EBRAHIMI et al., 2008). De acordo com TEPLAN (2002) e JAP et al. (2009), do ponto de vista fisiológico, sinais de EEG são considerados poderosos indicadores para análise do sono. CHARBONNIER et al. (2011) argumentam que tais sinais são cruciais para sua análise e rotulagem.

De fato, a classificação de estágios de sono é baseada principalmente no comportamento de sinais de EEG, uma vez que, através deles, é possível associar ritmos cerebrais ao estado cognitivo de um sujeito (NATIONAL INSTITUTES OF HEALTH, 2003). Para tanto, seguem-

¹ Considera-se, aqui, canal como sendo a informação advinda de dois eletrodos condutores, seja por derivação monopolar ou bipolar (RAO, 2013).

se ou as recomendações de RECHTSCHAFFEN; KALES (1969) (R&K) ou as da Academia Americana de Medicina do Sono (AASM) (IBER et al., 2007). Ambos padrões apresentam diretrizes para classificação de estágios de sono, que consideram pequenos intervalos de tempo dos sinais adquiridos, ECG, EMG, EOG e principalmente o EEG. Esses trechos de sinais são denominados épocas e geralmente têm 20 ou 30 segundos (HSU et al., 2013). Cada época é relacionada a um estado de sono, independentemente do padrão de classificação escolhido pelos especialistas, isto é R&K ou AASM.

Como endereçado em ZHU; LI; WEN (2014), as recomendações de R&K organizam os estágios de sono em cinco diferentes grupos, cada um com 6, 5, 4, 3 e 2 estados de estágios de sono. A classificação envolvendo os 6 estados é a mais completa, sendo composta pelos estados: acordado (W), de movimento rápido dos olhos (REM), e quatro estágios intermediários denominados estágios de sono 1, 2, 3 e 4 (S1–S4). Na classificação de 5 estados, os estágios S3 e S4 são agrupados em um único estado, chamado de sono de ondas lentas (SWS). O grupo de 4 estados de estágios de sono considera W, SWS, REM e S1/S2, que é a junção dos estágios S1 e S2. A classificação de 3 estados combina S1/S2 e SWS em um estágio mais amplo, denominado movimento não-rápido dos olhos (NREM). Por fim, na classificação de 2 estados de estágios de sono, têm-se apenas W e o estado de repouso (SLP) que compreende NREM e REM juntos.

A associação das épocas dos sinais de EEG com cada fase do sono é feita de acordo com certos fenômenos, suas intensidades e as durações da atividade cerebral de cada sujeito (KRYGER; ROTH; DEMENT, 2011). Alguns desses fenômenos, chamados ritmos cerebrais, têm faixas de frequência bem definidas e servem como principais indicadores para o problema de classificação de estágios de sono e sonolência (SILVEIRA, 2012). O ritmo delta (1 – 4Hz) aparece intensamente durante os estágios S3 e S4. No primeiro, de 20 a 50% da energia do espectro é predominantemente relacionada a este ritmo e, no segundo, mais de 50% (RONZHINA et al., 2012). Na transição do estado acordado (W) para os de descanso, o ritmo teta (4 – 8Hz) gradualmente aumenta enquanto que o ritmo alfa (8 – 13Hz) decai (SUBASI, 2005). De acordo com CORSI-CABRERA et al. (2006), o ritmo beta (13 – 30Hz) é principalmente associado ao estágio acordado. O ritmo baixo-gama (30 – 50Hz) é relacionado à memória de trabalho e atenção (JIA; KOHN, 2011), e, portanto, ao estado acordado. Embora saiba-se que frequências acima de 50Hz (alto-gama) sejam associadas à cognição (RAO, 2013), neste estudo, estas são descartadas.

De acordo com EBRAHIMI et al. (2008), a classificação de estágios do sono é uma

tarefa que consome muito tempo do especialista. RONZHINA et al. (2012) acrescentam que, para cada oito horas de sinal gravado, são despendidas entre duas e quatro horas no processo de análise. Objetivando assistir no processo de classificação de estágios de sono, é proposta neste trabalho uma metodologia para construção de um sistema de apoio à decisão. Dentre os estudos com propostas para classificação de estágios de sono, cada um com sua metodologia em particular, destacam-se BERTHOMIER et al. (2007), CHARBONNIER et al. (2011), KRAKOVSKÁ; MEZEIOVÁ (2011), RONZHINA et al. (2012), LIANG et al. (2012), HSU et al. (2013) e ZHU; LI; WEN (2014) que seguem as recomendações de R&K e FRAIWAN et al. (2012), guiado pelo padrão da AASM. Visando aumentar o âmbito das comparações entre as diferentes metodologias e seus desempenhos, o presente trabalho também segue as recomendações de R&K.

Portanto, o objetivo geral deste trabalho é propor e avaliar uma metodologia única capaz de rotular, com bom nível de acurácia, estágios de sono em todos os 2 a 6 cenários de classificação. A fim de atingir esse objetivo principal, destacam-se os seguintes objetivos específicos:

- Fazer uma revisão bibliográfica concisa acerca do funcionamento do cérebro humano e aquisição via eletroencefalografia;
- Fazer uma ampla revisão bibliográfica acerca de métodos computacionais para rotulagem do sono - focando especialmente naqueles que atendem aos vários cenários de classificação;
- Fazer uma busca por bases de dados públicas, confiáveis e amplamente utilizadas, possibilitando comparações com outros trabalhos no estado da arte;
- Estudar métodos para pré-processamento de dados e avaliar alternativas que comprometam menos os dados analisados;
- Identificar características robustas dos sinais de eletroencefalografia que refletem o comportamento das diversas classes e relacionar essas características a relevantes ritmos cerebrais;
- Testar algoritmos de aprendizagem de máquina para as tarefas de classificação e selecionar aquele com melhor desempenho e/ou relação custo-benefício;
- Apresentar uma análise completa dos resultados, combinando métricas de avaliação clássicas para o problema e comparando-as com aquelas obtidas em outros trabalhos.

1.2 Estado da arte e proposta de trabalho

As primeiras propostas de sistemas digitais para classificação do sono datam da década de 1970 (MARTIN et al., 1972) e apenas com RAY et al. (1986) obtiveram o conceito de sistema especialista ou de apoio à decisão. O crescente desenvolvimento de técnicas de reconhecimento de padrões e de inteligência artificial tem possibilitado que novas metodologias computacionais para identificação do sono através de sinais fisiológicos sejam introduzidas na literatura ainda nos dias atuais (RONZHINA et al., 2012). A maioria das recentes propostas compreende três principais etapas: (i) pré-processamento e (ii) extração de características dos sinais fisiológicos e (iii) aplicação do procedimento de classificação em si (FRAIWAN et al., 2012).

Independentemente dos sinais de PSG a serem utilizados, as etapas (i)–(iii) devem ser seguidas. Em ANDERER et al. (2005) é apresentado um algoritmo para extração e classificação de densidades e intensidades de sinais de um canal de EEG, dois de EOG e outro de EMG. Em tal estudo, sinais do banco de dados de polissonografia *Siesta* (PENZEL et al., 2011) são utilizados. Para validação, os autores contam com uma divisão aleatória dos dados em 50% para treino e 50% para teste. Como resultado, 80% de acurácia são obtidos para 5 estados de estágios de sono. CHAPOTOT; BECQ (2010) extraem um conjunto de 16 características estatísticas, espectrais e não-lineares de sinais de EEG e EMG. Um subconjunto de 5 destas características alimenta uma rede neural artificial (ANN) associada à regras de decisão. Os autores obtém uma acurácia média de 78% para classificação de 6 estados, considerando um banco de dados privado.

KRAKOVSKÁ; MEZEIOVÁ (2011) utilizaram análise de discriminantes quadráticos (QDA) considerando várias características de seis canais de EEG e de canais de ECG, EMG e EOG. A acurácia obtida em tal pesquisa para classificação de 5 estados foi de 81%. A base de dados *Siesta* também é utilizada em KRAKOVSKÁ; MEZEIOVÁ (2011). CHARBONNIER et al. (2011) propuseram um método de rotulagem dos 5 estágios de sono de acordo com R&K, baseando-se em quatro canais de EEG e um único canal de EMG, EOG e ECG. O melhor resultado obtido nesta proposta, onde quatro arquiteturas de ANN são testadas, foi de 85,5% de acertos.

Embora vários métodos considerem sinais de EMG, EOG e ECG, tanto na etapa de pré-processamento (KOLEY; DEY, 2012), quanto nas demais etapas (KRAKOVSKÁ; MEZEIOVÁ, 2011), a comunidade científica tem provado que bons resultados para análise de sono podem

ser atingidos usando apenas sinais de EEG (ZHU; LI; WEN, 2014; FRAIWAN et al., 2012; BERTHOMIER et al., 2007). Além do mais, como argumentado em ZHU; LI; WEN (2014), metodologias baseadas em um único canal de EEG, ao invés de vários, são mais simples e, portanto, consumem menos recursos computacionais. Ainda, os dispositivos de aquisição para um único canal de EEG são mais fáceis de serem utilizados pelos pacientes quando comparados com aqueles que aderem a múltiplos canais.

BERTHOMIER et al. (2007) apresentaram um método baseado em lógica nebulosa para classificação de características de um único canal de EEG. Os resultados obtidos em tal estudo foram de 95,4%, 88,3%, 74,5% e 71,2% de acurácia para os problemas de 2 a 5 estados. Um total de 8 indivíduos da base de dados *Sleep EDF* (GOLDBERGER et al., 2000) foi utilizado em BERTHOMIER et al. (2007). LIANG et al. (2012), ao considerarem a mesma base de dados, obtêm 76,9% de acurácia para o caso de cinco classes. Tais autores calculam entropias multi-escala a partir de sinais de um único canal de EEG e as classificam via análise de discriminantes lineares (LDA). Similarmente, RONZHINA et al. (2012) propõem uma série de arquiteturas de ANN utilizando energias de faixas de frequência específicas de sinais de EEG. Inúmeros resultados via validação cruzada são obtidos em tal estudo para 2, 3, 4 e 6 estados de estágios de sono.

FRAIWAN et al. (2012) aplicam três extratores de características – transformada *wavelet* contínua (CWT), distribuição de Choi-Williams e transformada de Hilbert-Huang – sobre épocas de 30 segundos. Ainda, é calculada a entropia de Renyi a partir das características extraídas. Após este passo, os autores treinam um classificador do tipo floresta aleatória com dois terços dos dados e o testam com o restante. A acurácia total obtida em tal estudo é de 83% para a classificação de 5 estados. A metodologia introduzida em HSU et al. (2013) é baseada em energias por faixas de frequência de um único canal de EEG. Os autores treinaram e testaram redes neurais do tipo *feedforwarded* (FNN), probabilísticas (PNN) e de Elman, obtendo, respectivamente, 81,1%, 81,8% e 87,2% de acurácia para a classificação de 5 estados. ZHU; LI; WEN (2014) utilizam máquinas de vetores de suporte (SVM) sobre características extraídas via grafos de diferença de visibilidade (DVG) e grafos de visibilidade horizontais (HVG). O método introduzido em tal estudo atinge 97,9%, 92,6%, 89,3%, 88,9% e 87,5% de acertos no problema de 2 a 6 estados.

Dos métodos apresentados nesta breve revisão bibliográfica, BERTHOMIER et al. (2007), CHAPOTOT; BECQ (2010), CHARBONNIER et al. (2011), KRAKOVSKÁ; MEZEIOVÁ

(2011), RONZHINA et al. (2012) e HSU et al. (2013) utilizam para extração de características a transformada de Fourier (FT) nas suas mais diversas versões (BRIGGS; HENSON, 1995); a transformada discreta de Fourier (DFT), a transformada rápida de Fourier (FFT) e a transformada de Fourier de tempo-curto (STFT).

Apesar da FT ser uma importante ferramenta para análise de sinais, esta não é capaz de manter eficientemente informações pontuais no domínio de tempo, diferentemente das transformadas *wavelet* (WTs) (DAUBECHIES, 1992). WTs têm a habilidade de prover uma análise multirresolução do sinal em ambos os domínios de tempo e escala, que tem relação direta com frequência (MALLAT, 2008). Além disso, as WTs permitem a discriminação de propriedades de sinais não-estacionários, como é o caso dos de EEG. De fato, diferentes algoritmos para aplicação das WTs foram utilizados na análise do sono, como *wavelet packet* (WPT) em EBRAHIMI et al. (2008), a transformada *wavelet* discreta (DWT) em KIYMIK; AKIN; SUBASI (2004) e SUBASI (2005) e a CWT em FRAIWAN et al. (2010, 2012).

Inspirado em KRAKOVSKÁ; MEZEIOVÁ (2011); RONZHINA et al. (2012); HSU et al. (2013) que usam atributos baseados em faixas de frequência, neste trabalho este conceito é revisitado e explorado no contexto das DWTs. Como contribuição, o algoritmo clássico de Daubechies é adaptado para tornar possível a análise de sinais de tamanho par qualquer (não necessariamente potência de dois). Além disso, na metodologia proposta são utilizados momentos estatísticos como forma de se obter características significativas dos sinais transformados em cada nível da DWT (os quais são relacionados a ritmos cerebrais), permitindo uma drástica redução da dimensão do conjunto de atributos a ser considerado por algoritmos de classificação. Aqui, a ferramenta *Waikato Environment for Knowledge Analysis* (WEKA) – que oferece implementações de diversos algoritmos de aprendizagem de máquina – é utilizada. Baseado em testes de desempenho de classificadores disponíveis no WEKA – cujos resultados são compatíveis com aqueles obtidos em FRAIWAN et al. (2012); SEN et al. (2014) e RADHA et al. (2014) – opta-se por utilizar neste estudo o classificador floresta aleatória. Além de apresentar o melhor desempenho geral, o classificador em voga tem uma arquitetura simples, rápida e robusta a ruídos (HASTIE; TIBSHIRANI; FRIEDMAN, 2009).

Neste estudo é feita uma ampla revisão bibliográfica sobre métodos para classificação de estágios de sono. Em especial, foca-se na identificação dos estudos que consideram apenas um canal de eletroencefalograma e se preocupam com as classificações dos diferentes cenários: com 2, 3, 4, 5 e 6 estados de estágios de sono. Diferentemente dos outros trabalhos encontrados

na literatura, aqui, as classificações de todos os 2 a 6 estados de estágios de sono são realizadas utilizando-se uma única metodologia – ou seja, um único tipo de pré-processamento, processamento (com a extração de um único conjunto de características) e classificação. Através do método de validação cruzada (ALPAYDIN, 2010), acurárias e coeficientes *kappa* (LANDIS; KOCH, 1977) são obtidos, mantendo-se superiores, respectivamente, a 90% e 0,8 em todos os cenários de classificação. Aqui, preocupa-se com a reproduzibilidade dos resultados uma vez que é considerada uma base de dados pública. Ademais, a totalidade de dados válidos é utilizada, sem que haja qualquer tipo de seleção arbitrária.

1.3 Estrutura do texto

O restante do texto está organizado como segue. O Capítulo 2 apresenta os materiais e métodos necessários para o desenvolvimento deste trabalho. Na Seção 2.1 são apresentados os conceitos básicos sobre sinais cerebrais e sua captação através da eletroencefalografia. Na mesma seção, aspectos importantes a respeito da base de dados utilizada são detalhados. A Seção 2.2 apresenta os dois tipos de pré-processamento utilizados neste trabalho: um geral e outro útil apenas para construção e avaliação do método de classificação. Na Seção 2.3 são explanados aspectos da etapa de extração de características, como a DWT e a redução de dimensionalidade dos dados transformados. Por fim, a etapa de classificação é discutida na Seção 2.4 e a ferramenta WEKA, aqui considerada, é apresentada de forma sucinta. Além disso o classificador do tipo floresta aleatória, escolhido para o desenvolvimento deste estudo, também é descrito nesta seção. Ao fim do capítulo, na Seção 2.5, é apresentado um fluxograma para ilustrar cada um dos passos da metodologia proposta. O Capítulo 3 reporta e discute os resultados deste estudo. A Seção 3.1 apresenta o experimento e as figuras de mérito consideradas. A Seção 3.2 avalia, de forma geral, o comportamento da metodologia proposta para as classificações de 2 a 6 estados de estágios de sono, sempre comparando com outros estudos. Testes adicionais, os quais são apresentados na Seção 3.3, são realizados para comparar o estudo corrente com dois outros trabalhos no estado da arte, permitindo minimizar quaisquer distorções referentes à distribuição dos dados e métricas de avaliação. Por fim, as conclusões e perspectivas futuras desse trabalho são expostas, respectivamente, nos Capítulos 4 e 5.

2 MATERIAIS E MÉTODOS

Este capítulo apresenta a metodologia proposta para classificação de 2 a 6 estados de estágios de sono considerando um único canal de EEG. Na Seção 2.1, os conceitos básicos necessários para o entendimento da técnica de eletroencefalografia são brevemente introduzidos. Além disso, nesta mesma seção, são apresentadas ainda algumas informações importantes com respeito ao banco de dados utilizado. As técnicas de pré-processamento estudadas são apresentadas na Seção 2.2. A Seção 2.3 explica as transformadas *wavelet* discretas de Haar, para exemplificação e fixação de conceitos, e de Daubechies que, de fato, é utilizada neste estudo. Além disso, a adaptação do algoritmo clássico de Daubechies para permitir sua utilização com dados de tamanho par qualquer (não necessariamente potência de dois), bem como sua aplicação são expostas nesta seção. O procedimento de redução de dimensionalidade dos dados transformados é descrito e embasado nesta mesma seção. Por fim, a etapa de classificação é apresentada na Seção 2.4. Em tal seção, é apresentada a ferramenta WEKA, aqui considerada, e o classificador do tipo floresta aleatória o qual é escolhido para o desenvolvimento deste estudo. Ao fim do capítulo, na Seção 2.5, é apresentada uma visão geral da metodologia proposta.

2.1 Sinais cerebrais, eletroencefalografia e base de dados

2.1.1 Sinais cerebrais

De acordo com RAO (2013), as capacidades de processamento de informações do cérebro humano surgem da maneira única com que ele trabalha: paralelamente, de forma distribuída e em tempo real. A unidade básica de cômputo do sistema nervoso, o neurônio, é um tipo de célula altamente especializada, capaz de receber informações de diversos outros neurônios, processar essas informações, e transmitir sua saída para centenas de outros neurônios (AMABIS; MARTHO, 2006).

Como mencionado em RAO (2013), um neurônio pode, grosseiramente, ser visto como uma “bolsa, com pequenos furos, cheia de líquidos eletronicamente carregados”. Tecnicamente, uma célula nervosa, a qual contém todas organelas citoplasmáticas de qualquer célula animal (BEAR; CONNONRS; PARIDISO, 2015), é envolta por uma membrana lipídica dupla, permeável apenas para alguns tipos de íons. A Figura 2.1 – adaptada de (PFEIL, 2015) – apresenta um esquema simplificado de um neurônio. Os neurônios localizam-se em um meio aquoso

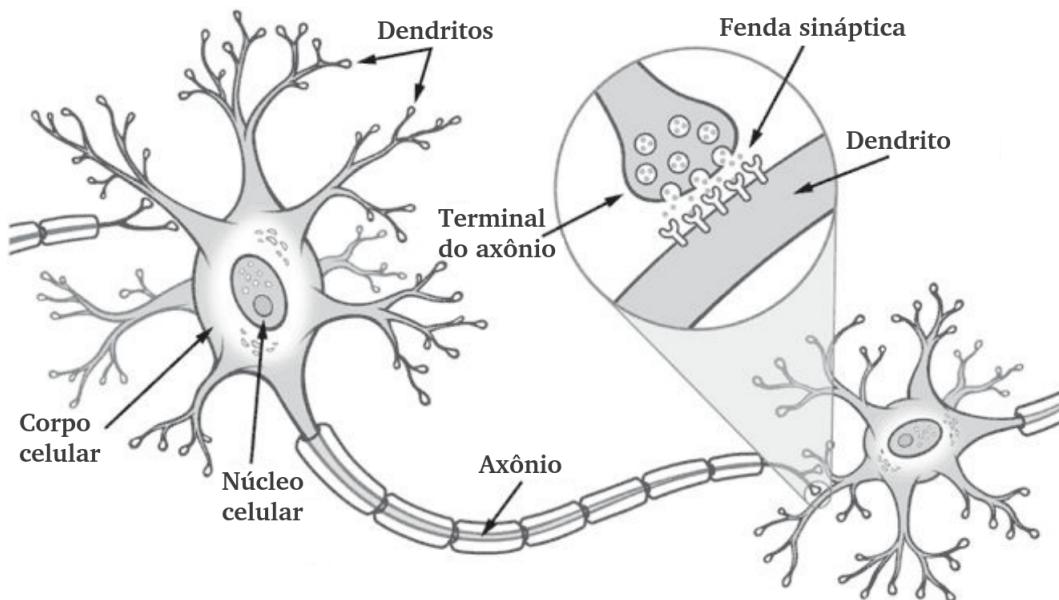


Figura 2.1: Estrutura básica de uma célula neural em sinapse com outra célula neural. Figura adaptada de (PFEIL, 2015).

com grande concentração de íons de sódio (Na^+), cloro (Cl^-) e cálcio (Ca^{2+}) e, por sua vez, têm grande concentração de cátions de potássio (K^+) e ânions orgânicos em seu interior (TEPLAN, 2002). Resultante desse desbalanceamento iônico, existe uma diferença de potencial (ddp) de aproximadamente -70mV (milivolts) entre as duas faces da membrana do neurônio, quando em repouso. Bombas de sódio-potássio agem através de canais iônicos – fendas na membrana plasmática onde ocorrem as trocas de íons entre os meios interno e externo – preservando a estabilidade da ddp (RAO, 2013). Assim, a superfície interna da membrana plasmática mantém-se eletricamente negativa em relação à superfície externa (BEAR; CONNONRS; PARIDISO, 2015).

Quando o neurônio é estimulado, isto é, recebe impulsos suficientemente fortes de outros neurônios, ocorre um fluxo de alternâncias elétricas em sua membrana, dos dendritos em direção ao axônio. A alternância elétrica, nomeada despolarização, consiste na inversão brusca das cargas elétricas em uma pequena área da membrana da célula. A superfície interna desta área passa a ser, por um breve período, mais positiva do que a externa, e a ddp passa de -70mV para aproximadamente $+40\text{mV}$ (AMABIS; MARTHO, 2006). A diferença de potencial elétrico entre as duas faces da membrana plasmática, durante o processo de despolarização, é o que se chama de potencial de ação. A situação de repouso na área da membrana em que ocorre o potencial de ação é restabelecida, passado aproximadamente 1,5 milissegundo (AMABIS;

MARTHO, 2006). Este fenômeno é conhecido como repolarização. Apesar disso, a região que se despolarizou estimula a área imediatamente adjacente a se despolarizar também. Tal fenômeno se repete, propagando-se rapidamente até as extremidades do axônio. A essa propagação do potencial de ação, dá-se o nome de impulso nervoso (RAO, 2013).

De acordo com AMABIS; MARTHO (2006), o impulso nervoso geralmente se propaga em um sentido único em um axônio. Nos dendritos, o impulso se propaga das extremidades dendríticas para o corpo celular (ou soma), e deste para a terminação do axônio. Estímulos captados pelos dendritos ou pelo próprio corpo celular geram um impulso nervoso que percorre todo axônio, e chega às suas extremidades. Ao atingir a terminação de um axônio, o impulso nervoso é transmitido a outra célula, em geral, um outro neurônio. A região de proximidade entre o extremo de um axônio e a célula vizinha, por onde se dá a transmissão do impulso nervoso, é chamada de sinapse nervosa ou fenda sináptica (ver Figura 2.1). Um neurônio é dito pré-sináptico se é aquele que está transmitindo o impulso nervoso através de seu axônio para um outro neurônio. Este último, que recebe o impulso através de um dendrito ou de seu soma, é chamado de neurônio pós-sináptico (RAO, 2013). Quando um potencial de ação chega de um neurônio pré-sináptico, isso causa a descarga de substâncias químicas, conhecidas como neurotransmissores, na fenda sináptica. Esses neurotransmissores ativam os canais iônicos do neurônio pós-sináptico, causando suas aberturas e, portanto, influenciando o potencial da membrana local da célula pós-sináptica (BEAR; CONNONRS; PARIDISO, 2015).

Sinapses podem ser excitatórias ou inibitórias. As sinapses excitatórias causam um acréscimo no potencial da membrana local do neurônio pós-sináptico. Esse aumento, chamado de potencial excitatório pós-sináptico, contribui para ampliar a probabilidade de disparo de um impulso pela célula pós-sináptica. Em contrapartida, as sinapses inibitórias causam potências inibitórios pós-sinápticos, que temporariamente diminuem o potencial da membrana local da célula pós-sináptica. Simplificadamente, a propagação dos impulsos elétricos de um neurônio para outros neurônios é dada quando o somatório dos potenciais pós-sinápticos recebidos pelo primeiro excede um limiar específico (TEPLAN, 2002). De acordo com BEAR; CONNONRS; PARIDISO (2015), o valor típico para este limiar é -65mV. Em outras palavras, cada sinapse que um neurônio faz com os demais, contribui positiva ou negativamente para que haja a propagação dos impulsos nervosos através de uma rede neural. Este é o modo dominante de comunicação entre neurônios (RAO, 2013).

2.1.2 Eletroencefalografia

Eletroencefalografia (EEG) é definida como a técnica de medição da atividade elétrica cerebral a partir de, ao menos, dois eletrodos condutores posicionados na superfície do escalpo (SCHOMER; SILVA, 2010). O posicionamento destes eletrodos geralmente segue o sistema de posicionamento 10-20, que propõe um arranjo proporcionalmente alinhado de forma que se possa cobrir todas as regiões do escalpo onde a atividade cerebral é captável via EEG (TEPLAN, 2002; RAO, 2013). A Figura 2.2 esquematiza o sistema 10-20.

Há aproximadamente 140 anos, os primeiros passos da eletroencefalografia teriam sido dados. O fisiologista britânico Richard Caton, em 1875, viu que existiam correntes elétricas vindas de cérebros expostos de mamíferos, como coelhos e cães, enquanto os examinava com um dispositivo primitivo sensível à tensão (BEAR; CONNONRS; PARIDISO, 2015). Quase meio século depois, em 1924, o alemão Hans Berger utilizou um equipamento de rádio para amplificar sinais elétricos de atividade cerebral medidos, desta vez, através do escalpo de humanos (TEPLAN, 2002). Com este feito, Berger anunciou que a atividade cerebral poderia ser medida sem a necessidade de expor o crânio de indivíduos e, além disso, que esta atividade poderia ser graficada em uma folha de papel. Ainda, o cientista alemão observou que havia mudanças no comportamento dessas atividades elétricas em diversas ocasiões: durante o sono, sob ação de anestesia, sob falta de oxigênio, etc. Berger cunhou a palavra “eletroencefalograma” para descrever os sinais que gravava. Mais tarde, ADRIAN; MATTHEWS (1934) conceituaram ondas cerebrais humanas, primeiramente com identificação do ritmo alfa.

De acordo com BEAR; CONNONRS; PARIDISO (2015), milhares de neurônios devem estar ativados “simultaneamente” para gerar um estímulo grande o suficiente que possa ser medido via EEG. Isto ocorre por que o crânio e o escalpo têm altas resistividades elétricas, que acabam atenuando os sinais provenientes da atividade cerebral (SILVEIRA, 2012). Maneiras muito mais precisas para obtenção destas atividades, como eletrocorticografia (ECoG), não são adotadas em situações usuais, visto que geralmente tratam-se de técnicas invasivas. Assim, devido à capacidade de refletir ambas as atividades cerebrais normais e anormais, EEG é tido como uma ferramenta muito importante nos campos de neurologia e neurofisiologia clínica (TEPLAN, 2002). BEAR; CONNONRS; PARIDISO (2015) argumentam que EEG é uma tecnologia clássica para medição de ritmos cerebrais e essencial para o estudo do sono.

Eletroencefalogramas são adequados para capturar a atividade cerebral oscilatória ou

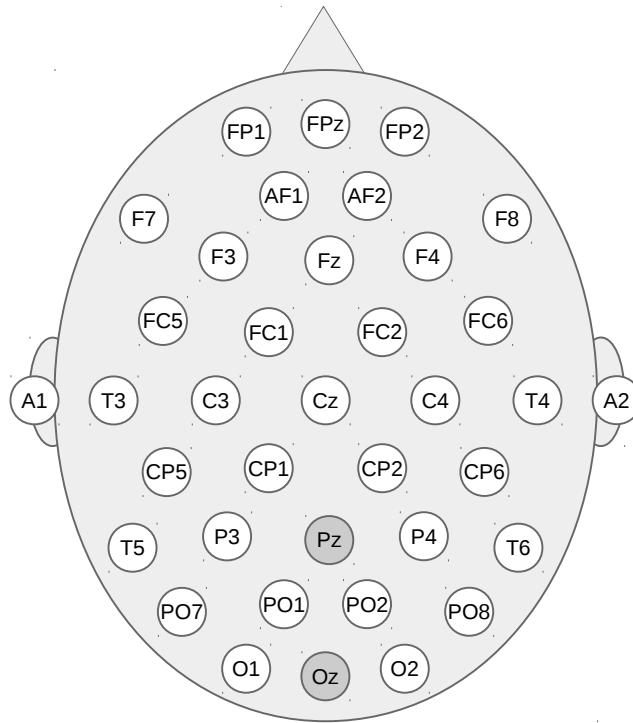


Figura 2.2: Esquema para colocação de 35 eletrodos no escalpo e 2 referenciais (A1 e A2) nas orelhas de acordo com o sistema de posicionamento 10-20. O canal destacado (Pz-Oz) é utilizado neste estudo. Figura adaptada de (HUNTER et al., 2005).

“ondas cerebrais” em uma grande variedade de frequências (RAO, 2013). Essas ondas, que aparecem do sincronismo de uma grande população de neurônios ativos, têm frequências e distribuição espacial características e, usualmente, são correlacionadas com diferentes estados funcionais do cérebro.

As ondas delta (1 – 4Hz), consideradas as oscilações mais lentas, são características no sono profundo (BEAR; CONNONRS; PARIDISO, 2015). O ritmo teta (4 – 8Hz) ocorre tanto no estado de vigília quanto durante o sono (BEAR; CONNONRS; PARIDISO, 2015), embora possa ser um bom indicativo de sonolência (RAO, 2013). Segundo KRYGER; ROTH; DEMENT (2011), este ritmo pode também aparecer no estado REM. O ritmo alfa (8 – 13Hz) é o mais conhecido e estudado tipo de oscilação da atividade cerebral, sendo principalmente relacionado a estados nos quais o indivíduo está tranquilo, mas acordado (RAO, 2013). Geralmente, neste caso, têm-se baixas amplitudes deste ritmo (KRYGER; ROTH; DEMENT, 2011). A atividade beta (13 – 30Hz) é dominante durante o estado de vigília (TEPLAN, 2002). O baixo-gama (30 – 50Hz) está amplamente associado à memória recente (RAO, 2013; BEAR; CONNONRS; PARIDISO, 2015) e à atenção (JIA; KOHN, 2011).

Como observado, EEG mostra-se como uma importante técnica para captação da ativi-

dade elétrica cerebral que, através de oscilações em faixas de frequências bem definidas, serve como ótimo indicativo para identificação e classificação de estados cognitivos e de sono. Para um material completo sobre células neurais, potenciais de ação, transmissões sinápticas, neurotransmissores, etc., o leitor é direcionado para BEAR; CONNONRS; PARIDISO (2015). Da mesma forma, encaminha-se o leitor a SCHOMER; SILVA (2010) se este tiver interesse em um amplo estudo sobre eletroencefalografia.

2.1.3 Base de dados *Sleep EDF [Expanded]*

O *PhysioNet*, acessível em <http://physionet.org>, é uma plataforma aberta que oferece uma série de conjuntos de dados de sinais fisiológicos, com anotações de especialistas, aplicáveis a diversos tópicos de pesquisa relacionados à biomedicina. Ao banco de dados da plataforma *PhysioNet*, dá-se o nome de *PhysioBank* (GOLDBERGER et al., 2000). No presente trabalho, a base *Sleep EDF [Expanded]* (PHYSIONET, 2013a), parte do *PhysioBank*, é considerada. Esta base complementa outro banco de dados presente na plataforma, *Sleep EDF* (PHYSIONET, 2013b), que contém apenas 8 registros. Apesar de pequeno, tal banco de dados foi utilizado em trabalhos recentes como BERTHOMIER et al. (2007), RONZHINA et al. (2012), HSU et al. (2013) e ZHU; LI; WEN (2014). A principal vantagem da utilização de uma base de dados pública é a possibilidade de reprodução de todos os resultados obtidos no estudo que a considera, por qualquer pesquisador interessado em tal tópico de pesquisa. Aqui este cuidado é tomado.

A base *Sleep EDF [Expanded]* conta com 61 registros de sinais de PSG (EEG, EOG, EMG), formatados em EDF (KEMP et al., 1992), os quais são divididos em dois grupos. O primeiro grupo de sinais de PSG, com 39 registros coletados entre 1987 e 1991, foi inicialmente utilizado em um estudo sobre os efeitos da idade e gênero no sono de pessoas saudáveis (MOURTAZAEV et al., 1995). Já o segundo grupo, com 22 registros, foi empregado em um estudo sobre os efeitos do uso de uma determinada substância (Temazepam) no sono humano (KEMP; JANSSEN; ROESSEN, 1993). O presente estudo, assim como em CHAPOTOT; BECQ (2010) , CHARBONNIER et al. (2011) e KRAKOVSKÁ; MEZEIOVÁ (2011), aborda o problema de classificação de estágios de sono através da análise de sinais de pacientes saudáveis. Portanto, apenas os registros do primeiro grupo são considerados.

Os 39 registros utilizados neste estudo são referentes a gravações de duas noites subsequentes (aproximadamente 20h) de sono de 20 Caucasianos (10 homens e 10 mulheres) com

idades entre 25 e 34 anos, saudáveis, e que afirmaram não utilizar nenhuma medicação relacionada ao sono. O registro da segunda noite de análise do paciente de número 13 não está disponível no banco de dados. Os demais registros de indivíduos saudáveis – todos aqueles disponíveis no banco de dados *Sleep EDF [Expanded]* – são utilizados nesta pesquisa.

Cada registro contém sinais de dois canais de EEG (FPz-Cz e Pz-Oz) um de EOG e um de EMG. Os sinais de EEG e EOG estão amostrados a 100Hz enquanto que o de EMG está amostrado a 1Hz. Juntamente com os sinais, são providas anotações, em formato EDF+ (KEMP; OLIVAN, 2003), feitas por especialistas para cada época (intervalo de tempo fixado em 30 segundos). As anotações são chamadas hipnogramas e indicam a classificação das épocas, de acordo com o padrão de R&K, em um dos possíveis estados: W, S1, S2, S3, S4, REM, “tempo de movimento” ou “não classificado”. Os padrões de oscilação em sinais de EEG para o estado acordado e as cinco fases do sono são exemplificados na Figura 2.3, onde, além do sinal completo, épocas de 30 segundos das gravações referentes à segunda noite de sono do sujeito de número 11 são ilustradas.

Os registros da base *Sleep EDF [Expanded]* são nomeados com o prefixo “SC4” seguido do número de identificação do sujeito (de 00 à 19) e o valor 1 ou 2, para indicar, respectivamente, a primeira ou a segunda noite de gravação. A distribuição de épocas rotuladas como W, S1–S4 ou REM por registro (sujeito/noite) é apresentada na Tabela 2.1. Nota-se que, naturalmente, há uma maior quantidade de épocas etiquetadas como W em registros de exames clínicos de pacientes saudáveis deste banco. Este estudo considera, em sua análise principal, todos os dados disponíveis (ver Seção 3.2). Entretanto, outras distribuições de épocas por classe são também analisadas (ver Seções 3.3.1 e 3.3.2), visando mostrar que (i) o desbalanceamento dos dados é encontrado em outros trabalhos da literatura e (ii) ainda assim obtém-se, aqui, resultados melhores ou, ao menos, comparáveis aos obtidos nestes outros trabalhos.

SWEDEN et al. (1990) mostram que, considerando ambos FPz-Cz e Pz-Oz (ver Figura 2.2), pode-se, com sucesso, rotular o sono de acordo com as recomendações de R&K. O presente trabalho assim como outros (ver Seção 1.2), utiliza apenas um canal de EEG para realizar a análise dos sinais e classificação de estágios de sono. HSU et al. (2013) selecionam empiricamente o canal FPz-Cz para análise. Entretanto, neste estudo, o canal Pz-Oz é adotado visto que, através deste, melhores resultados podem ser atingidos em problemas relacionados à análise do sono (ZHU; LI; WEN, 2014; RONZHINA et al., 2012). Testes preliminares confirmaram a tendência apontada por esses estudos.

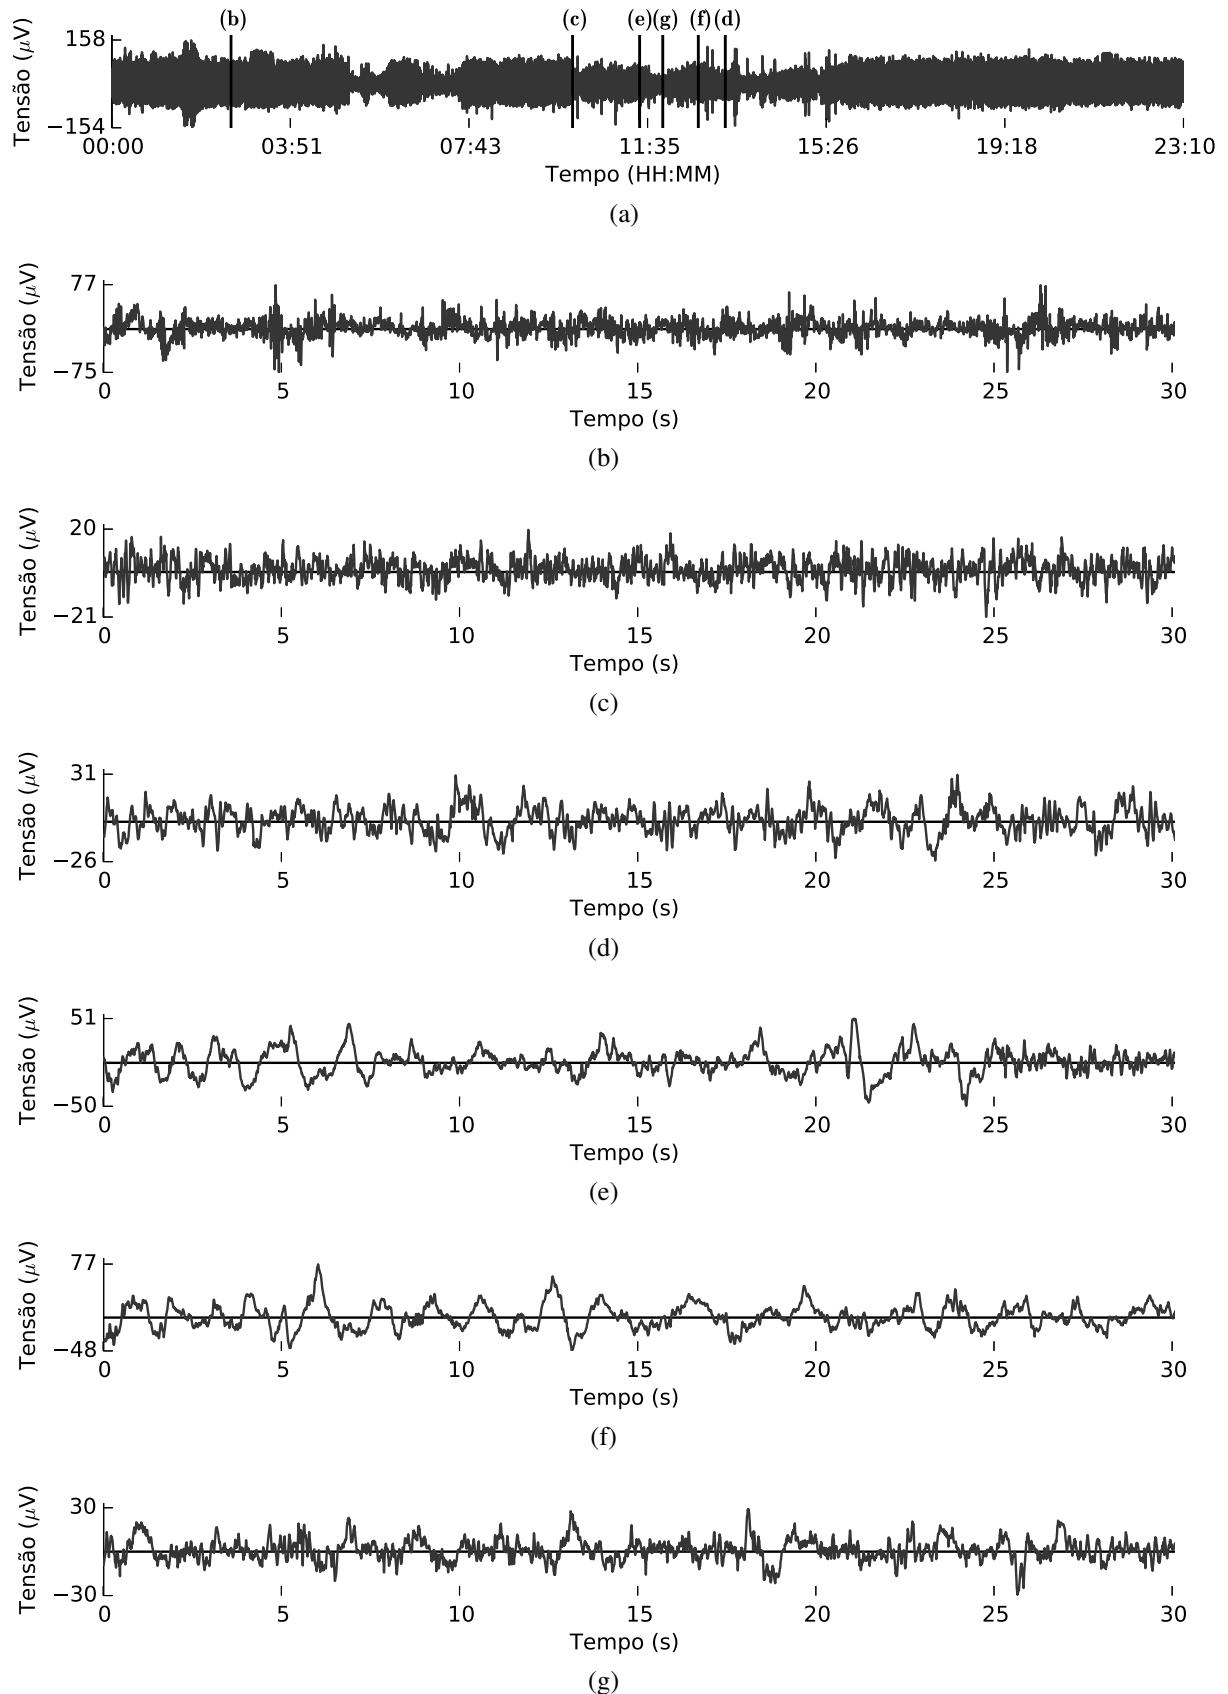


Figura 2.3: Sinal completo (a) e épocas de 30 segundos da segunda noite de sono do sujeito de número 11. De acordo com as anotações do banco de dados, respectivamente, as épocas de posição 310, 1196, 1592, 1370, 1522 e 1430 são características dos estados (b) W, (c) S1, (d) S2, (e) S3, (f) S4 e (g) REM.

Tabela 2.1: Distribuição das classes dos dados válidos da base *Sleep EDF [Expanded]*

Registro	W	S1	S2	S3	S4	REM
SC4001	1996	58	250	101	119	125
SC4002	1884	59	373	94	203	215
SC4011	1855	109	562	96	9	170
SC4012	1824	92	660	80	16	176
SC4021	1906	94	545	73	22	163
SC4022	1870	184	402	81	38	179
SC4031	2007	61	485	56	1	209
SC4032	1956	45	400	54	77	199
SC4041	1533	166	620	53	0	196
SC4042	1772	137	514	88	6	270
SC4051	2257	44	217	116	19	68
SC4052	1779	114	616	106	8	180
SC4061	2068	56	407	35	101	102
SC4062	2006	90	417	96	33	187
SC4071	1957	89	403	80	82	198
SC4072	1903	84	392	59	163	168
SC4081	1984	68	262	158	192	131
SC4082	1723	39	329	84	198	260
SC4091	1738	19	561	87	83	232
SC4092	1078	81	512	103	4	265
SC4101	1769	65	671	6	0	207
SC4102	1908	117	607	25	0	199
SC4111	1838	13	502	80	49	158
SC4112	2103	18	396	90	21	151
SC4121	1809	48	463	47	60	258
SC4122	1918	121	287	50	30	199
SC4131	1940	57	497	63	84	172
SC4141	1938	29	404	88	63	233
SC4142	2002	27	386	67	78	213
SC4151	1835	41	354	114	63	208
SC4152	1903	47	438	113	65	292
SC4161	1692	55	448	123	42	260
SC4162	1925	42	459	97	31	195
SC4171	1914	21	328	175	40	262
SC4172	1635	44	687	139	49	165
SC4181	1929	29	388	152	139	118
SC4182	2068	151	290	102	114	116
SC4191	1426	118	833	80	30	286
SC4192	1706	72	434	59	1	332
Total:	72354	2804	17799	3370	2333	7717

2.2 Pré-processamento

Em problemas de reconhecimento de padrões e classificação, uma importante etapa é a de pré-processamento de dados. Geralmente, os procedimentos efetuados neste passo visam ajustar os dados de entrada, possibilitando a realização das etapas posteriores (STRANNEBY, 2004). Neste estudo, assim como nos demais trabalhos relacionados, os sinais são particionados em épocas. Além disso, para possibilitar a construção e avaliação do classificador utilizado, épocas já identificadas pelos especialistas como não relacionadas aos padrões de interesse são excluídas. Esses assuntos são discutidos no restante desta seção.

2.2.1 Divisão dos sinais em épocas

Como já discutido, a classificação do sono segundo os padrões R&K e AASM é feita para cada época e não para o sinal inteiro. Dessa forma, na etapa de pré-processamento, deve-se particionar o sinal de entrada – aqui proveniente do canal Pz-Oz – em trechos de comprimento igual a 30 segundos. Tal procedimento é realizado por todos os autores de trabalhos correlatos que foram brevemente apresentados no Capítulo 1.

Como comentado anteriormente, este trabalho utiliza a DWT para analisar e decompor os sinais, de onde são extraídas características para classificação. Algoritmos clássicos para a DWT consideram que o conjunto de dados de entrada (época) a ser analisado tem cardinalidade na forma de potência de dois. Entretanto, as épocas do banco de dados têm $100 \text{ (Hz)} \times 30 \text{ (segundos)} = 3000$ amostras e, portanto, não podem ser diretamente analisadas através das transformadas discretas desenhadas desta forma.

Possíveis formas de contornar este problema incluem: (i) considerar a técnica de *zero-padding*, onde $(2^{12} - 3000)/2$ zeros seriam colocados de cada lado do conjunto de amostras (SILVEIRA, 2012); (ii) considerar épocas de $2^{11} = 2048$ ou $2^{12} = 4096$ amostras; e (iii) aplicar algoritmos de reamostragem em cada época para que tenham, ao invés de 3000 pontos, 2048 (*downsampling*) ou 4096 (*upsampling*) amostras.

A aplicação de (i) faz com que haja a necessidade de um acompanhamento minucioso dos dados válidos (que inicialmente eram 3000 pontos) em cada nível de decomposição *wavelet*, uma vez que as informações referentes a um dado evento não estariam mais localizadas de forma imediata numa vizinhança que preservasse uma estrutura de cone ao longo das escalas, exigindo assim um critério de busca mais específico ao longo das escalas. Ao considerar dire-

tamente a opção (ii), deslocam-se as marcações relativas dos hipnogramas, não permitindo nem treinar e nem avaliar o desempenho de um classificador com a confiabilidade desejada. Outra possibilidade de (ii), é aceitar a perda de 952 amostras de cada época ou a inclusão de 1096 de uma época adjacente àquela que está sendo analisada. Este tipo de escolha também não é sensata uma vez que, ao considerar 2048 pontos, descarta-se quase um terço das informações de uma época e, ao considerar 4096 amostras, inclui-se uma enorme quantidade de informações de outras épocas que, potencialmente, têm outro rótulo (marcação).

Segundo LAIRD; ROGERS; MEYERAND (2004), para que os dados reamostrados sejam acurados é importante que estes possuam propriedades estatísticas semelhantes às dos dados originais. Levando isso em consideração, fez-se um estudo prévio (SILVEIRA; RODRIGUES; KOZAKEVICIUS, 2014) que teve como objetivo avaliar a aplicabilidade de três técnicas do tipo (iii). A primeira abordagem avaliada para reamostragem de sinais consiste em sucessivas aplicações da transformada inversa de Daubechies de ordem 2 (Db2) sobre o sinal original, considerando coeficientes de detalhe zerados, de modo que a reconstrução dos dados nos níveis mais refinados seja feita apenas através dos coeficientes de escala da transformada, sem que haja a correção de nenhum detalhe. Dessa forma, esse procedimento pode ser visto como uma forma de interpolação apenas através das informações médias do sinal, e portanto uma boa estratégia para interpolação dos dados nas demais escalas necessárias para a reamostragem. Esse procedimento de interpolação baseado na transformada *wavelet* inversa é repetido para tantos níveis acima do original até que a quantidade de pontos do sinal (interpolado) seja múltipla do número de pontos correspondente à nova taxa de amostragem desejada, possibilitando então a obtenção dos novos dados nas posições correspondentes. Implementações abertas dos trabalhos de PUTNAM; SMITH (1997) e LAIRD; ROGERS; MEYERAND (2004), que consideram os sinais no domínio de frequências, foram também avaliadas.

Os resultados obtidos em SILVEIRA; RODRIGUES; KOZAKEVICIUS (2014) apontaram que todas as técnicas mostram-se viáveis quando os sinais considerados são periódicos, diferentemente dos de EEG, os quais além de não-periódicos são não-estacionários (SUBASI, 2005; RONZHINA et al., 2012). Neste cenário, melhores correspondências no domínio de tempo foram obtidas utilizando a técnica baseada em *wavelets*, enquanto que, no domínio de frequências o método de LAIRD; ROGERS; MEYERAND (2004) mostrou-se preferível. Nem as informações no domínio de frequência, utilizando a DWT, nem as temporais, utilizando as outras duas técnicas, foram satisfatoriamente preservadas. O resumo deste estudo prévio é ex-

posto no Apêndice A.

No presente trabalho, tanto informações de frequência quanto temporais são igualmente importantes. Dessa forma, como uma quarta solução, decidiu-se ajustar o algoritmo clássico de Daubechies, utilizado aqui na análise dos sinais, para considerar conjuntos de dados, não mais com cardinalidade em potências de dois, mas sim apenas um valor par. Dessa forma, parte da etapa de pré-processamento é mesclada na etapa de extração de características. Na Seção 2.3.1.2 esta contribuição é explicada em maiores detalhes e são apresentadas as alterações feitas no algoritmo clássico de Daubechies.

2.2.2 Remoção de épocas inválidas

Uma vez que o algoritmo de classificação utilizado no presente trabalho é baseado em fases de treino e, posteriormente, teste, é imprescindível que haja uma etapa de remoção de instâncias inválidas para evitar a geração de modelos errôneos e/ou testes inconsistentes. Assim como em RONZHINA et al. (2012); ZHU; LI; WEN (2014), no presente estudo, épocas etiquetadas pelos especialistas como “não classificado” ou “tempo de movimento” são descartadas, uma vez que seus padrões já foram identificados como não sendo relacionados aos estados W, S1–S4 e REM. Ao concluir tal passo, considera-se que as épocas remanescentes podem, potencialmente, ser utilizadas tanto nas etapas de construção do modelo de classificação quanto de teste.

É importante ressaltar que este passo só é feito para possibilitar a construção e avaliação da metodologia proposta. Na prática, após treinado o classificador, os sinais a serem rotulados são apenas particionados em épocas de 30s, como explanado na seção anterior.

2.3 Extração de características

2.3.1 Transformada *wavelet* discreta (DWT)

De acordo com STOLLNITZ; DEROSE; SALESIN (1995), funções *wavelets* e suas transformadas são ferramentas matemáticas para análise e decomposição hierárquica de funções. Como os senos e cossenos da transformada de Fourier (BRIGGS; HENSON, 1995), as *wavelets* servem como base para representação de outras funções (VIDAKOVIC; MUELLER, 1991). Em especial, as transformadas *wavelet* mostram-se mais eficientes em relação à de Fourier quando os sinais a serem analisados são não-periódicos (BAYER; KOZAKEVICIUS,

2010), como é o caso dos de EEG.

Através das *wavelets*, é possível enxergar uma determinada função (ou sequência de dados) como uma curva grosseira e, separadamente, os detalhes que a compõe em diversos níveis de resolução. *Wavelets* uni (1D) e bidimensionais (2D) são utilizadas em diversas áreas de pesquisa, como processamento digital de sinais, métodos de elementos finitos, compressão de imagens e análise estatística (BAYER; KOZAKEVICIUS, 2010). O uso destas transformadas 1D no processamento de sinais de PSG permite a visualização e extração de importantes parâmetros que podem ser direta ou indiretamente utilizados em aplicações de classificação de padrões (RONZHINA et al., 2012).

A transformada *wavelet* da família de Daubechies com 2 momentos nulos (Db2) é utilizada neste trabalho como parte fundamental da metodologia proposta. Ao considerar Db2, resultados acurados podem ser obtidos na análise e classificação do sono através de sinais fisiológicos (KIYMIK; AKIN; SUBASI, 2004; EBRAHIMI et al., 2008). Entretanto, para fins de introdução e fixação da técnica, a transformada *wavelet* mais simples – a de Haar – é inicialmente apresentada.

2.3.1.1 DWT de Haar

Neste trabalho, assim como em textos introdutórios às transformadas *wavelet* (VIDAKOVIC; MUELLER, 1991; STOLLNITZ; DEROSE; SALESIN, 1995), a transformada de Haar é primeiramente apresentada via exemplo. Depois, através de conceitos básicos de álgebra linear e das relações entre diferentes escalas é apresentada a estrutura de multirresolução associada às transformadas *wavelets* discretas.

Tome um vetor unidimensional de tamanho $2^j = 2^2$,

$$C_j = C_2 = [2 \ 0 \ 1 \ 5].$$

O vetor C_2 pode ser visto como uma coleção de pontos, que podem ser graficados de acordo com a Figura 2.4a. Entretanto, também é possível representá-lo como sendo uma função constante por partes (função escada), como ilustrado na Figura 2.4b. Essa segunda representação é particularmente útil, como poderá ser visto na sequência desta seção, e portanto é aquela adotada.

Pode-se aplicar a estes dados (vetor ou função escada) a transformada *wavelet* discreta de Haar na forma decimada. Faz-se isso, primeiramente, calculando a média aritmética – dois

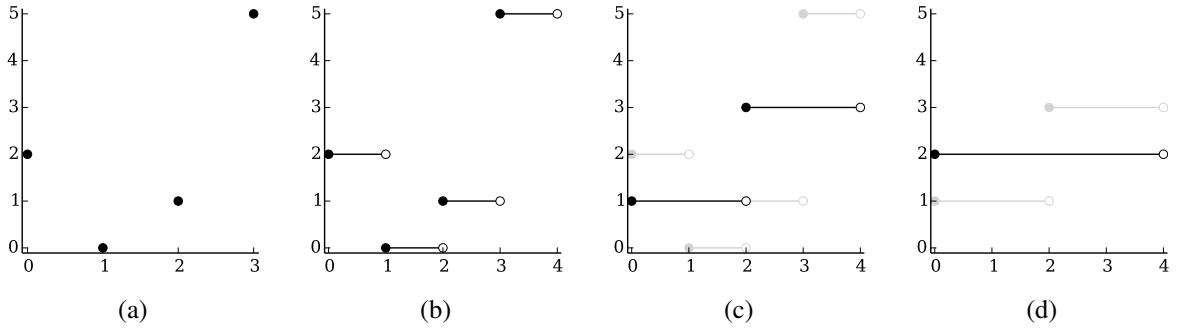


Figura 2.4: Vetor exemplo C_2 visto como (a) uma sequência de pontos e (b) função constante por partes. Vetores (c) C_1 e (d) C_0 vistos como funções constantes por partes.

a dois de forma disjunta – dos elementos de C_j de acordo com

$$C_{j-1,i} = \frac{C_{j,2i} + C_{j,2i+1}}{2},$$

sendo $i = 0, 1, 2, \dots, 2^{j-1}$ a posição dos elementos do novo vetor de *informações médias* (C_{j-1}). Para este exemplo têm-se $C_{j-1} = C_1 = [1 \ 3]$. Notavelmente, ao comparar as Figuras 2.4b e 2.4c, percebe-se que há perda de informação quando representamos C_2 simplesmente por sua informação média (C_1). É impossível recuperar os valores de C_2 a partir de C_1 sem que se considere um vetor de informações complementares (*detalhes*), ou seja as variações dos valores de C_2 em relação à informação média em C_1 .

Aqui, chama-se $D_{j-1} = D_1$ a sequência de valores que permite a recuperação dos elementos de C_j através de C_{j-1} . Para determinar os elementos de D_{j-1} , faz-se

$$D_{j-1,i} = C_{j,2i} - C_{j-1,i}, \quad i = 0, 1, 2, \dots, 2^{j-1}.$$

Neste exemplo, têm-se $D_{j-1} = D_1 = [1 \ -2]$. Ao processo de encontrar as médias e diferenças em relação aos valores do vetor C_j , dá-se o nome de decomposição *wavelet* de Haar em um nível.

Se esse procedimento for reaplicado, mas agora, sobre C_1 , obtém-se sua informação média como sendo o vetor $C_0 = [2]$ (ilustrado na Figura 2.4d) e a sua variação em relação à média será dada pelo vetor $D_0 = [-1]$. Assim, o vetor original C_2 dado neste exemplo pode ser representado na base *wavelet* de Haar, por $[2 \ -1 \ 1 \ -2]$: a informação média do último nível de decomposição e todas as demais informações de detalhe, ou seja, dados dos vetores de detalhe do último (D_0), penúltimo (D_1), ... e primeiro níveis (D_{j-1}).

Note que, o processo descrito inicialmente é reversível, uma vez que os dados originais de cada nível C_j podem ser reconstruídos a partir das médias e dos detalhes do nível

imediatamente mais grossoiro C_{j-1} e D_{j-1} . Assim, considerando-se C_{j-1} e D_{j-1} como dados de entrada, pode-se através de

$$C_{j,2i} = C_{j-1,i} + D_{j-1,i} \quad \text{e} \quad C_{j,2i+1} = C_{j-1,i} - D_{j-1,i} \quad i = 0, 1, 2, \dots, 2^{j-1} - 1$$

reconstruir o vetor C_j . Para o exemplo dado, a partir de C_0 e D_0 obtém-se exatamente C_1 ; e considerando C_1 e D_1 obtém-se C_2 . Esse processo é chamado de transformação inversa. Contudo, neste trabalho, apenas o processo de decomposição (análise) é empregado, e, portanto, a transformada *wavelet* inversa não é discutida mais detalhadamente. Para maiores informações o leitor é referido para DAUBECHIES (1992); MALLAT (2008).

Formalmente, pode-se interpretar $C_j, j \in \mathbb{N}$, como sendo definido dentro no intervalo $[0,1)$, onde cada coeficiente é constante em intervalos de tamanho $1/2^j$. Utilizando conceitos da álgebra linear, diz-se que esse vetor $C_j, j \in \mathbb{N}$ pertence ao espaço vetorial V^j , sendo V^j gerado por todas as translações da função escala $\phi(x)$.

Assim, se o vetor tiver apenas $2^0 = 1$ componente, este está contido em V^0 . O espaço vetorial V^0 tem como base a *função escala* de Haar $\phi(x)$, dada por

$$\phi(x) := \begin{cases} 1, & \text{se } 0 \leq x < 1 \\ 0, & \text{caso contrário.} \end{cases} \quad (2.1)$$

A Figura 2.5a apresenta graficamente a função $\phi(x)$. De fato, quando temos um vetor em V^0 , da forma $C_0 = [\alpha]$, podemos reescrevê-lo como $\alpha \cdot \phi(x)$ e, portanto, estará associado a uma função constante por partes, múltipla de $\phi(x)$.

Um vetor com dois elementos – o primeiro e o segundo elementos constantes associadas a $[0, 1/2)$ e $(1/2, 1)$, respectivamente – está em V^1 ; Da mesma forma, vetores com quatro elementos estão associados a funções contantes partes geradas por bases de V^2 , e assim sucessivamente.

As bases que geram os outros espaços vetoriais V^j de Haar são dadas pela translação e escala da função $\phi(x)$, agora parametrizada, na forma

$$\phi_i^j(x) := \phi(2^j x - i), \quad i = 0, 1, \dots, 2^j - 1,$$

em que j e i são, respectivamente, os fatores de escala e translação. As Figuras 2.5c e 2.5d ilustram as versões escaladas de $\phi(x)$ uma vez e transladas, respectivamente, zero e uma vez ($\phi_0^1(x)$ e $\phi_1^1(x)$) em V^1 .

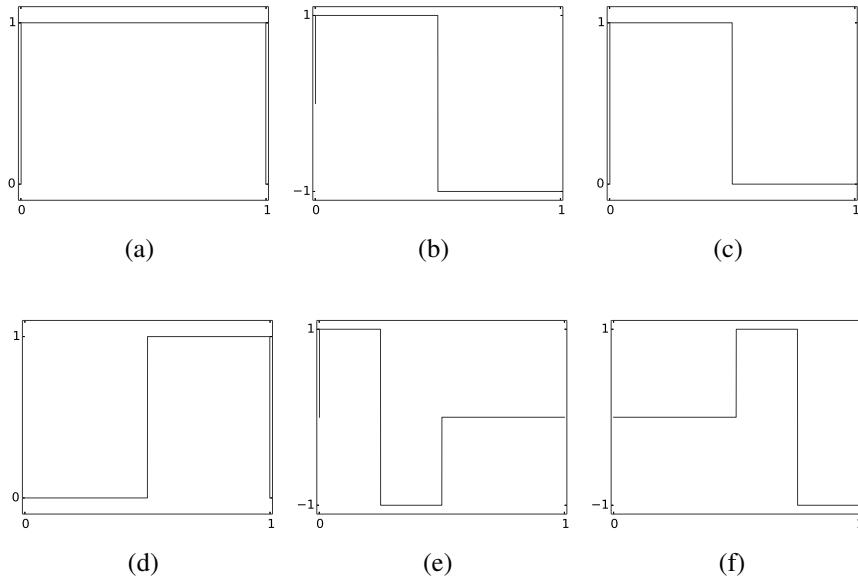


Figura 2.5: Funções $\phi_0^0(x)$ e $\psi_0^0(x)$, respectivamente, em (a) e (b); $\phi_i^1(x)$ com $i = 0, 1$ em (c) e (d) e $\psi_i^1(x)$ com $i = 0, 1$ em (e) e (f).

Como já mencionado para o caso de vetores em V^0 , um vetor $[\beta \gamma]$ em V^1 pode ser reescrito como uma combinação linear das bases de Haar em V^1 dada por $\beta.\phi_0^1(x) + \gamma.\phi_1^1(x)$. O mesmo vale para vetores em V^j , com j qualquer.

Uma vez que estes vetores $C_j, j \in \mathbb{N}$ estão definidos no intervalo unitário, todo aquele que pertence a V^j também está contido em V^{j+1} . Como argumentado em STOLLNITZ; DE-ROSE; SALESIN (1995), sempre é possível representar uma função constante por partes que tem dois elementos tanto em V^1 quanto em V^2 . Neste segundo caso, com quatro elementos, os dois primeiros valores seriam iguais, definidos em $[0, 1/2)$, e dois últimos também, sendo definidos em $(1/2, 1]$. Utilizando-se dessa heurística, é intuitivo pensar que o mesmo vetor pode ser representado em V^3, V^4, V^5 e assim sucessivamente. A partir desse fato, observa-se que os espaços vetoriais V^j são aninhados, ou seja

$$V^0 \subset V^1 \subset V^2 \subset \dots \subset L^2([0, 1]),$$

em que $L^2([0, 1])$ é o espaço de todas as funções integráveis em $[0, 1]$, cujo quadrado também é integrável em $[0, 1]$ (VIDAKOVIC; MUELLER, 1991).

Na verdade, tudo que ocorre dentro de $[0, 1]$ é replicado para qualquer intervalo do tipo $[k, k+1]$, produzindo uma cobertura para toda a reta Real. Portanto os espaços V^j podem ser associados a funções contantes por partes na escala j e definidas na reta toda, produzindo aproximações para funções do espaço $L^2(\mathbb{R})$. Neste trabalho os sinais de EEG são interpretados

como funções do espaço $L^2(\mathbb{R})$.

Dada uma função inicialmente discretizada em um nível de resolução mais refinado possível, aqui interpretado como sendo o espaçamento $h = 1/2^j$ entre seus pontos, o objetivo principal é representá-la através de suas decomposições em vários níveis de resolução (detalhamento), além de uma componente mais grosseira (DAUBECHIES, 1992), como visto com o vetor exemplo no início desta seção.

Como a questão da decomposição de uma função (vetor) em relação às escalas é um dos ingredientes fundamentais da transformada *wavelet* de Haar (e na verdade, de qualquer transformada *wavelet*), é importante que se tenha toda uma estrutura matemática que permita uma transição coerente e bem definida entre as escalas. Neste sentido é que se apresenta o conceito clássico de análise multirresolução.

A análise multirresolução é definida através de axiomas que estabelecem as relações entre os subespaços encadeados que fatoram $L^2(\mathbb{R})$ em diferentes resoluções (NIELSEN, 1998):

- (i) A completude do sistema multirresolução é dada pelas relações

$$\bigcap_{j \in \mathbb{Z}} V^j = \{0\} \quad \text{e} \quad \overline{\bigcup_{j \in \mathbb{Z}} V^j} = L^2(\mathbb{R}),$$

significando que união de todos os subespaços representa o espaço $L^2(\mathbb{R})$ e a interseção entre eles representa a função nula;

- (ii) A invariância de escala, dada por $f(x) \in V^j \Leftrightarrow f(2x) \in V^{j+1}$;
- (iii) A invariância ao deslocamento dentro de uma escala fixada, formalmente escrita como

$$f(x) \in V^0 \Leftrightarrow f(x - i) \in V^0 \forall i \in \mathbb{Z};$$

- (iv) Há uma função escala $\phi \in V^0$ tal que $\{\phi(x - i)\}_{i \in \mathbb{Z}}$ é uma base ortogonal de V^0 .

Ou seja, os algoritmos rápidos a serem desenhados para as transformadas *wavelets* devem preservar as propriedades entre as escalas expressas por esta construção axiomática.

De forma a capturar informações complementares entre dois níveis consecutivos, V^j e V^{j+1} , define-se o complemento ortogonal de V^j em V^{j+1} como sendo o espaço vetorial W^j . Ou seja, V^{j+1} é soma direta de V^j e W^j . As funções geradoras de W^j são chamadas de funções *wavelets*. Grosseiramente, pode-se pensar que os elementos de W^j são partes de funções em

V^{j+1} e que não podem ser representadas completamente por elementos de V^j . A função *wavelet* de Haar, base de W^0 , é dada por

$$\psi(x) := \begin{cases} 1, & \text{se } 0 \leq x < 1/2 \\ -1, & \text{se } 1/2 \leq x < 1 \\ 0, & \text{caso contrário.} \end{cases} \quad (2.2)$$

De forma análoga às funções escala, as funções *wavelet* são também escaladas e transladadas, formando as bases para os espaços vetoriais W^j da seguinte forma

$$\psi_i^j(x) := \psi(2^j x - i), \quad i = 0, 1, \dots, 2^j - 1,$$

em que, novamente, j e i são os fatores de escala e translação. As bases para W^0 e W^1 são mostradas graficamente nas Figuras 2.5b, 2.5e e 2.5f.

Uma vez que os conceitos de espaços vetoriais V^j e W^j foram introduzidos, podemos retomar nosso exemplo, mas agora aplicando esses novos conhecimentos. Considerando a transformada *wavelet* de Haar, quando encontramos as médias e as variações das médias de um vetor em V^j estamos, na verdade, reescrevendo-o como uma combinação linear das bases em V^{j-1} e W^{j-1} . Se aplicarmos novamente este processo sobre o vetor resultante em V^{j-1} , estaremos decompondo o vetor em V^j em um segundo nível, o que é o mesmo que reescrevê-lo em termos das bases em V^{j-2} , W^{j-2} e W^{j-1} .

As Figuras 2.6b e 2.6c apresentam, de forma gráfica, o vetor utilizado como exemplo no início desta seção decomposto via transformada *wavelet* de Haar em um e dois níveis, respectivamente. Quando fazemos a análise gráfica (Figuras 2.6b e 2.6c) é fácil ver que as combinações lineares, de fato, resultam no vetor original C_2 (Figuras 2.6a).

Quando são obtidas as informações médias e as variações em relação às médias, trata-se da aplicação da transformada *wavelet* de Haar *não-normalizada*. Da álgebra linear, a não-normalização é devido ao fato de que o produto interno das funções base que geram V^j e W^j é diferente de 1. Em determinadas aplicações é importante que sejam preservados diferentes tipos de informação do vetor original nos vários níveis de decomposição *wavelet*, como, por exemplo, a energia de seus coeficientes. Com essa informação preservada é possível, por exemplo, ver as regiões de um sinal discretizado (vetor) – em diferentes níveis de resolução – que mais contribuem para com a energia total.

Para explorar estas e outras aplicações, deve-se normalizar as bases de V^j e W^j . Em termos de formulação, para que se tenha a transformada de Haar *normalizada*, as Equações 2.1

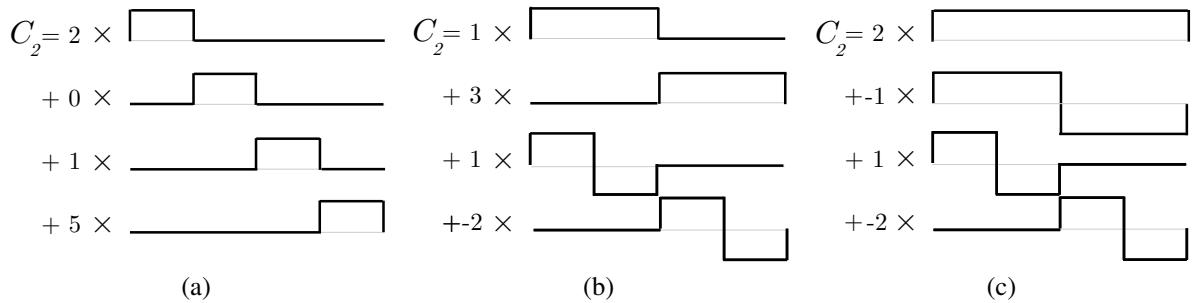


Figura 2.6: Diferentes combinações lineares do vetor exemplo C_2 . Em (a) têm-se $C_2 = 2\phi_0^2(x) + 0\phi_1^2(x) + 1\phi_2^2(x) + 5\phi_3^2(x)$; (b) têm-se $C_2 = 1\phi_0^1(x) + 3\phi_1^1(x) + 1\psi_0^1(x) + (-2)\psi_1^1(x)$ e (c) $C_2 = 2\phi_0^0(x) + (-1)\psi_0^0(x) + 1\psi_0^1(x) + (-2)\psi_1^1(x)$.

e 2.2 devem ser, respectivamente, substituídas por

$$\phi_i^j(x) := 2^{j/2} \phi(2^j x - i) \quad (2.3)$$

e

$$\psi_i^j(x) := 2^{j/2} \psi(2^j x - i). \quad (2.4)$$

Note que, para que as bases da *wavelet* de Haar sejam normalizadas, deve-se somente adicionar o fator multiplicativo $2^{j/2}$ em suas antigas formulações, mantendo-se todo o restante inalterado.

Apesar de as funções $\phi(x)$ e $\psi(x)$ de Haar serem facilmente definidas (Equações 2.1 e 2.2 ou 2.3 e 2.4), geralmente não há fórmulas explícitas para outras transformadas *wavelet*. Portanto, a maioria dos algoritmos para decomposição *wavelet* é formulado em termos de bancos de filtros de coeficientes (NIELSEN, 1998).

Com isso, a partir de um vetor em V^j (C_j), encontram-se os vetores de informações médias em V^{j-1} (C_{j-1}) e de detalhes em W^{j-1} (D_{j-1}), respectivamente, através de

$$C_{j-1,l} = \sum_{k=0}^{D-1} h_k \cdot C_{j,2l+k} \quad (2.5)$$

e

$$D_{j-1,l} = \sum_{k=0}^{D-1} g_k \cdot C_{j,2l+k} \quad (2.6)$$

em que $l = 0, 1, 2, \dots, 2^{j-1} - 1$ e h_k e g_k são, respectivamente, os k -ésimos filtros referente às funções escala e *wavelet* (ver Tabela 2.2). O parâmetro $D = 2M$ é a quantidade de valores em h_k e g_k e M é a quantidade de momentos nulos da *wavelet* utilizada.

Uma DWT cuja função escala possui M momentos nulos pode representar polinômios de grau até $M - 1$ utilizando apenas coeficientes de escala, sendo os coeficientes *wavelets*

correspondentes todos nulos em qualquer nível. A base de Haar tem apenas um momento nulo ($M = 1$ e $D = 2$) e, portanto, consegue representar exatamente polinômios de grau 0 (funções constantes) através apenas de suas funções escala.

Com a finalidade de ilustrar as modificações numéricas que a normalização das bases da *wavelet* de Haar traz, são apresentadas, nas Tabelas 2.3 e 2.4, as decomposições completas de um outro vetor exemplo considerando, respectivamente, filtros não-normalizados e normalizados.

Nota-se, na Tabela 2.3, que as médias dos vetores C_j são preservadas dado qualquer j . Ainda, é evidente que C_0 contém a informação média do vetor em V^j . Por outro lado, na Tabela 2.4, a energia do vetor original é preservada independentemente do nível de decomposição. Isto é, se o vetor em V^j é decomposto uma vez, sendo reescrito como uma combinação linear das bases em V^{j-1} e W^{j-1} , terá sua energia idêntica à de sua representação em dois níveis de decomposição – sendo uma combinação linear das bases de V^{j-2} W^{j-2} e W^{j-1} – ou três, etc.

A Figura 2.7 ilustra as informações apresentadas na Tabela 2.3. A propriedade dos momentos nulos pode ser vista, tanto numericamente quanto graficamente, quando observamos os dois últimos coeficientes do vetor exemplo C_4 . Pode-se, no caso de Haar, enxergar aqueles dois valores iguais como uma função constante naquele intervalo $((\frac{14}{16}, 1))$ e, portanto, como o esperado, o coeficiente de detalhe naquele trecho é nulo.

Tabela 2.2: Coeficientes de filtro não-normalizados e normalizados para DWT de Haar

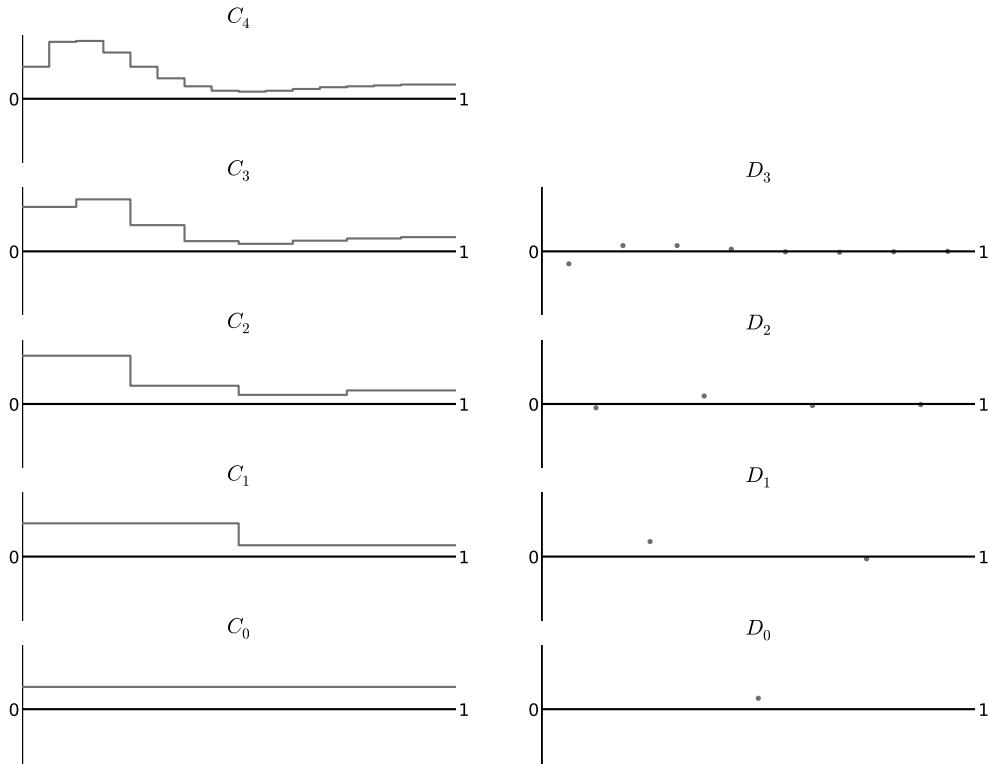
	Filtros não-normalizados		Filtros normalizados	
k	h_k	g_k	h_k	g_k
0	1/2	1/2	1/ $\sqrt{2}$	1/ $\sqrt{2}$
1	1/2	-1/2	1/ $\sqrt{2}$	-1/ $\sqrt{2}$

Tabela 2.3: Exemplo de aplicação da transformada de Haar não-normalizada

j	C_j	D_j
4	[72 128 130 104 72 46 28 18 16 18 22 26 28 30 32 32]	
3	[100 117 59 23 17 24 29 32]	[-28 13 13 5 -1 -2 -1 0]
2	[108,5 41 20,5 30,5]	[-8,5 18 -3,5 -1,5]
1	[74,75 25,5]	[33,75 -5]
0	[50,125]	[24,625]

Tabela 2.4: Exemplo de aplicação da transformada de Haar normalizada

j	C_j	D_j
4	[72 128 130 104 72 46 28 18 16 18 22 26 28 30 32 32]	
3	$\left[\frac{200}{\sqrt{2}} \frac{234}{\sqrt{2}} \frac{118}{\sqrt{2}} \frac{46}{\sqrt{2}} \frac{34}{\sqrt{2}} \frac{48}{\sqrt{2}} \frac{58}{\sqrt{2}} \frac{64}{\sqrt{2}} \right]$	$\left[\frac{-56}{\sqrt{2}} \frac{26}{\sqrt{2}} \frac{26}{\sqrt{2}} \frac{10}{\sqrt{2}} \frac{-2}{\sqrt{2}} \frac{-4}{\sqrt{2}} \frac{-2}{\sqrt{2}} 0 \right]$
2	[217 82 41 61]	$\left[-17 \ 36 \ -7 \ -3 \right]$
1	$\left[\frac{299}{\sqrt{2}} \frac{102}{\sqrt{2}} \right]$	$\left[\frac{135}{\sqrt{2}} \frac{-20}{\sqrt{2}} \right]$
0	[200,5]	[98,5]

Figura 2.7: Análise multirresolução de Haar não-normalizada sobre um conjunto de dados exemplo $C_4 = [72 \ 128 \ 130 \ 104 \ 72 \ 46 \ 28 \ 18 \ 16 \ 18 \ 22 \ 26 \ 28 \ 30 \ 32 \ 32]$. Adaptação de (STOLLNITZ; DEROSE; SALESIN, 1995).

2.3.1.2 DWT de Daubechies

Até então, dentro da Seção 2.3.1, foram apresentados alguns conceitos básicos sobre a transformada *wavelet* discreta, assim como seus algoritmos rápidos e ilustrou-se sua aplicabilidade através da base mais simples (VIDAKOVIC; MUELLER, 1991), a de Haar. De fato, todo o formalismo matemático referente à estrutura de análise de multirresolução, visto com a transformada de Haar, é compartilhado por todas as transformadas discretas *wavelet* ortonormais de Daubechies (DAUBECHIES, 1992), pois a função de Haar é também conhecida como Daubechies de ordem 1 ou Db1.

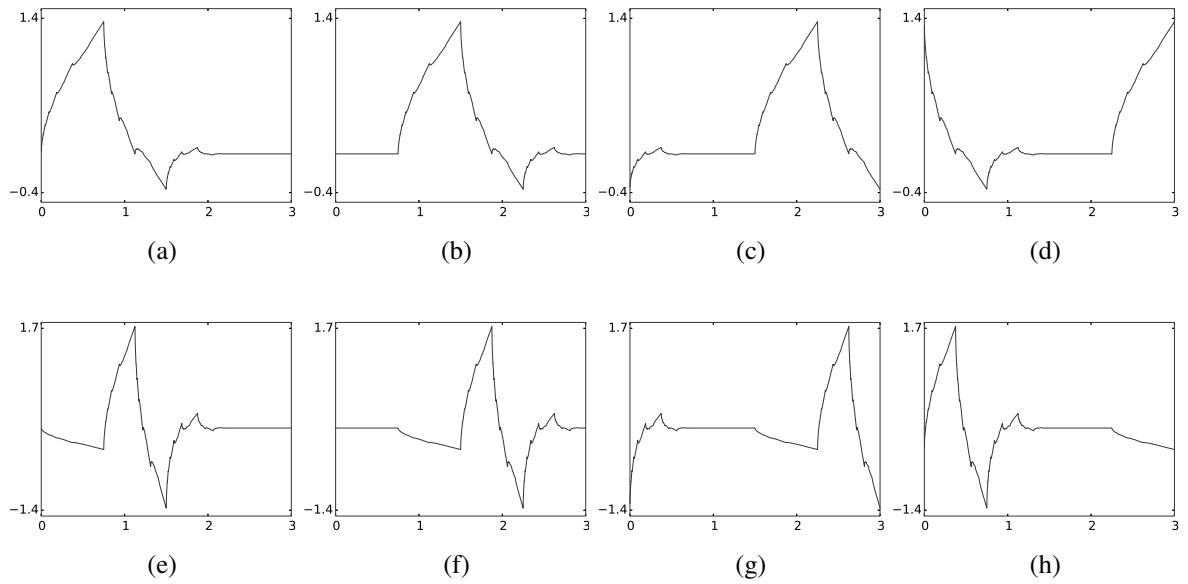


Figura 2.8: Funções $\phi_k^2(x)$ com $k = 0, 1, 2$ e 3 , respectivamente, em (a – d) e $\psi_k^2(x)$ com $k = 0, 1, 2$ e 3 , respectivamente, em (e – h).

Como argumentado anteriormente, outras WTs não possuem expressão analítica e são formuladas apenas através de algoritmos recursivos, o que torna difícil seu entendimento se não feito de forma incremental. As bases para DWT de Db2, por exemplo, não são mais as funções escada com comportamento analiticamente bem definido como em Haar, nem um polinômio conhecido, mas possuem um formato de “barbatanas de tubarão” conforme são geradas ponto a ponto de forma recursiva. A Figura 2.8 apresenta as funções escala e *wavelet* de Db2 em V^j e W^j , $j = 12$. Esta família de funções possui, além da propriedade de ortogonalidade, suporte compacto. Ou seja, fora de um certo intervalo fechado e limitado da reta estas funções são sempre todas nulas.

Uma vez que a estrutura de análise multirresolução permanece inalterada, pode-se decompor um vetor em V^j utilizando os mesmos artifícios apresentados para o caso de Haar. Entretanto, note que, como Db2 tem dois momentos nulos, há quatro valores para os filtros h_k e g_k (ver Tabela 2.5). Se optássemos por utilizar as formulações das Equações 2.5 e 2.6, iríamos encontrar problemas para obter o último elemento do vetor decomposto, seja ele pertencente ao espaço V^{j-1} ou a W^{j-1} .

A Figura 2.9 mostra as iterações 1, 2, $l - 2$ e $l - 1$, $l = 0, 1, 2, \dots, 2^{j-1} - 1$ quando obtemos C_{j-1} através da Equação 2.5. Note que, no caso de Db2, os filtros são aplicados a cada quatro valores e há interseção de dois deles de uma iteração para outra. Isso leva, na última iteração, à necessidade de extrapolação, ou seja, de se obter valores (potencialmente) artificiais

para serem utilizados nos cálculos.

A necessidade de extrapolação nas bordas é inerente às *wavelets* ortonormais de Daubechies, excetuando Haar. O aumento na quantidade de momentos nulos implica em extrapolar uma maior quantidade de pontos nas fronteiras para que seja possível aplicar a transformada. Em vista disso, como fator mais forte, optou-se por escolher Db2 para este trabalho, diminuindo o impacto desta extrapolação nos dados a serem analisados.

Uma possível solução para contornar o problema de extrapolação é considerar que o sinal é periódico. Esse recurso reconsidera, no lugar dos elementos faltantes, os primeiros elementos do vetor. Nesse caso, as Equações 2.5 e 2.6 são substituídas, respectivamente, por

$$C_{j-1,l} = \sum_{k=0}^{D-1} h_k \cdot C_{j,\langle 2l+k \rangle_{2^j}} \quad (2.7)$$

e

$$D_{j-1,l} = \sum_{k=0}^{D-1} g_k \cdot C_{j,\langle 2l+k \rangle_{2^j}}. \quad (2.8)$$

em que $\langle \cdot \rangle$ é a operação de módulo. Note que, para o caso de Haar, não há diferença nenhuma em considerar essas ou as Equações 2.5 e 2.6.

Apesar desta ser uma solução, geralmente, considerar que a função analisada é periódica não é razoável (em especial para a aplicação deste trabalho). Uma segunda solução poderia ser o preenchimento dos elementos faltantes com zeros. Dessa forma, não há influência dos filtros naquelas posições. O problema é que rapidamente o sinal se degrada, e perde o sentido, a medida que se decompõe em vários níveis. Outra possibilidade é extrapolar através de uma função (por exemplo linear) que considera alguns dos últimos elementos do vetor em V^j para “inferir” o comportamento dos faltantes.

Aqui, como o interesse é analisar sinais que, apenas por convenção, são divididos em trechos menores (épocas), pode-se extrapolar a sequência de coeficientes em questão obtendo-se poucas amostras da época seguinte, portanto, valores *exatos* para as posições em questão.

Tabela 2.5: Coeficientes de filtro normalizados para Db2

k	h_k	g_k
0	0,4829629131445341	-0,1294095225512603
1	0,8365163037378077	-0,2241438680420134
2	0,2241438680420134	0,8365163037378077
3	-0,1294095225512603	-0,4829629131445341

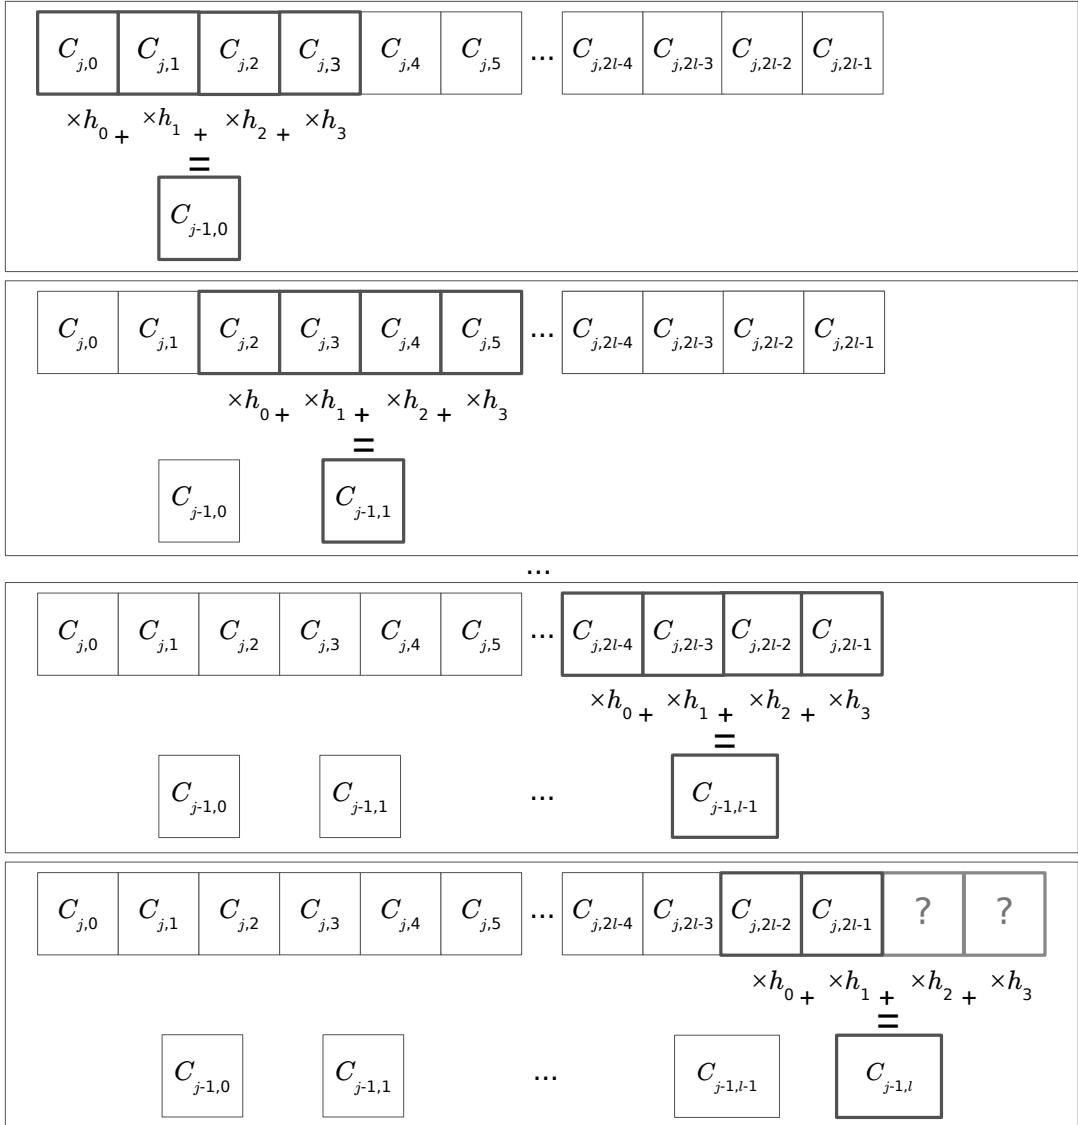


Figura 2.9: Primeira, segunda, $l - 2$ -ésima e $l - 1$ -ésima iterações da aplicação do algoritmo de decomposição *wavelet* com $D = 4$ para encontrar C_{j-1} a partir de C_j . Coeficientes destacados são usados no cálculo na respectiva iteração. O processo para encontrar D_{j-1} é análogo.

```

1: procedure DDWT( $C_j, h, g, E, D$ )
2:   for  $l \leftarrow 0$  to  $l < \text{length}(C_j)/2$  do
3:      $C_{j-1,l} \leftarrow 0$ 
4:      $D_{j-1,l} \leftarrow 0$ 
5:     for  $k \leftarrow 0$  to  $k < D$  do
6:        $aux \leftarrow 0$ 
7:        $i \leftarrow (2 \times l + k)$ 
8:       if  $i < \text{length}(C_j)$  then
9:          $aux \leftarrow C_{j,i}$ 
10:      else                                      $\triangleright$  tratamento de fronteira
11:         $m \leftarrow i \bmod \text{length}(C_j)$ 
12:         $aux \leftarrow E_m$ 
13:      end if
14:       $C_{j-1,l} \leftarrow C_{j-1,l} + h_k \times aux$ 
15:       $D_{j-1,l} \leftarrow D_{j-1,l} + g_k \times aux$ 
16:    end for
17:  end for
18:  return( $C_{j-1}, D_{j-1}$ )
19: end procedure

```

Figura 2.10: Pseudo-algoritmo para cálculo da transformada direta de Daubechies para vetores de entrada com tamanho par. Os parâmetros do procedimento C_j , h , g , E , e D são, respectivamente, os coeficientes de escala no j -ésimo nível, os filtros de escala, os filtros *wavelet*, as amostras extrapoladas no nível j e duas vezes o número de momentos nulos ($D = 4$). O procedimento retorna C_{j-1} e D_{j-1} que são os conjuntos de coeficientes de escala e *wavelet* em um nível mais grossoiro $j - 1$, cada um contendo metade da quantidade de valores do vetor original.

Essa abordagem é preferível uma vez que pontos não são artificialmente criados, o que difere a formulação proposta neste trabalho das outras soluções apresentadas na literatura estudada até o momento.

Além desse tratamento especial nas regiões de fronteira, outra contribuição desta dissertação é um outro ajuste feito no algoritmo clássico de Daubechies (ver Figura 2.10) para permitir a análise de funções discretas que não têm tamanho formatado em $L = 2^J$, mas sim, na forma $L = R \cdot 2^K$, $R \in \mathbb{N}$. Isto significa que um vetor desse tamanho pode ser decomposto K vezes e que, no nível mais grossoiro, têm-se R valores em ambos os vetores de coeficientes de escala e detalhe. Um vetor com $L = R \cdot 2^K$ pontos é, aqui, denotado por \tilde{C}_K . Para unificar a notação, sua decomposição em j níveis gera os vetores \tilde{C}_{K-j} e \tilde{D}_{K-j} .

Com esse ajuste, dado que as épocas têm 3000 amostras, podemos decompô-las duas vezes. Para possibilitar a aplicação do algoritmo de decomposição mais vezes, obtém-se 8 amostras da época seguinte de forma que cada época tenha, ao invés de 3000 amostras, 3008 pontos. Não há deslocamento do início das épocas. Dessa forma, pode-se decompor esses vetores seis vezes com o algoritmo ajustado.

Assim como em outros trabalhos (SUBASI, 2005, 2007; EBRAHIMI et al., 2008), o presente estudo explora o fato que o processo de decomposição *wavelet* pode ser visto como um conjunto de filtros passa-baixa e passa-alta, como sendo, respectivamente as funções escala e *wavelet*. Neste caso, associa-se diretamente a noção de escala ou resolução com a de frequências, o que é de interesse para este estudo, uma vez que há ritmos cerebrais – com faixas de frequência bem definidas – que devem ser resolvidos via aplicação da DWT. Uma vez que, pelo teorema de Nyquist (GRENDANDER, 1959), só se pode representar frequências até a metade da frequência de amostragem, pode-se desmembrar, via decomposição *wavelet*, faixas de frequências entre 0 e 50Hz de acordo com a Figura 2.11.

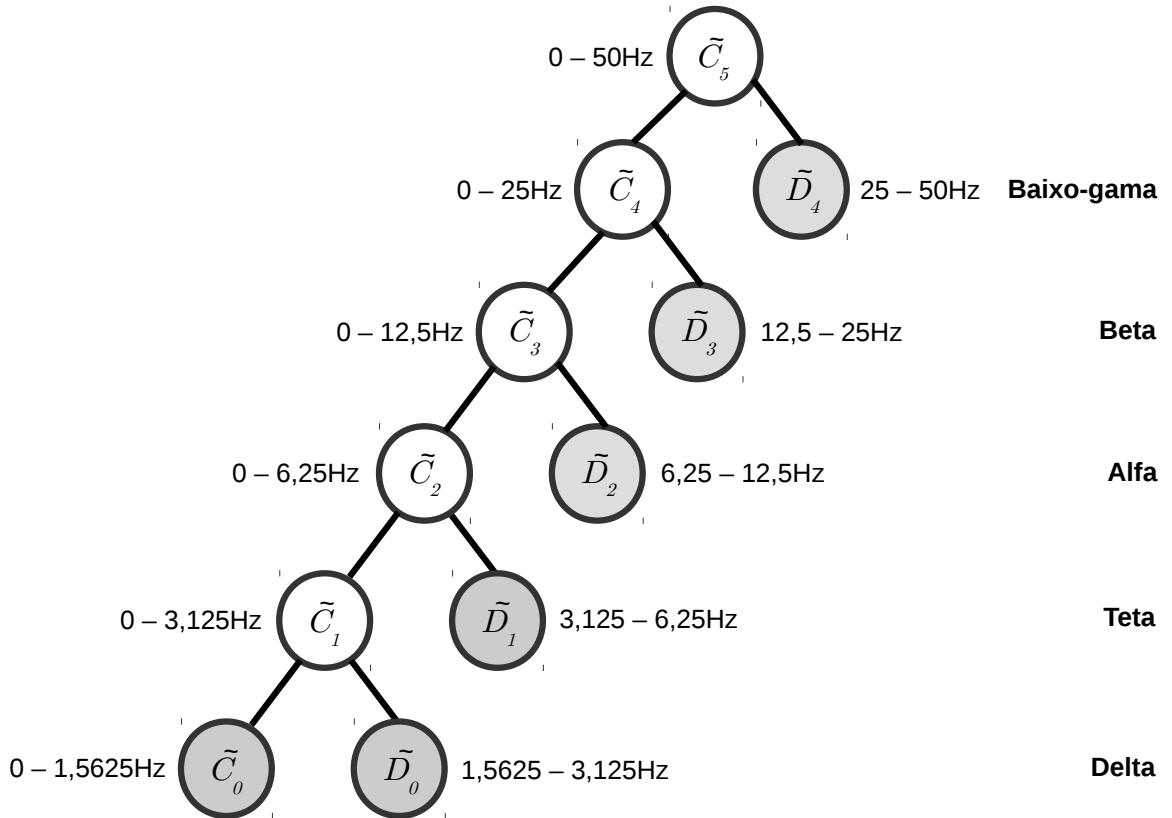


Figura 2.11: Decomposição *wavelet* em cinco níveis, faixas de frequência em cada nível e ritmos cerebrais associados. Conjuntos de coeficientes destacados em cinza são utilizados na etapa de redução de dimensionalidade. Este esquema de decomposição *wavelet* considera o sinal de entrada \tilde{C}_5 com frequência de amostragem de 100Hz.

Nota-se, através da Figura 2.11, que cinco dos seis níveis possíveis são necessários para que se possa representar as informações de uma época nas faixas de frequência próximas às dos ritmos baixo-gama, beta, alfa, teta e delta (ver Seção 2.1.1). Ao determinar quais informações estão associadas a quais faixas de frequência, podemos, via aprendizado de máquina, classificar padrões de sono, como discutido anteriormente. A Figura 2.12 ilustra o processo de decomposição de uma época seguindo o mesmo esquema da Figura 2.11. A partir da decomposição gerada pela DWT aplicada a cada uma das épocas serão extraídas novas informações associadas ao sinal cerebral analisado.

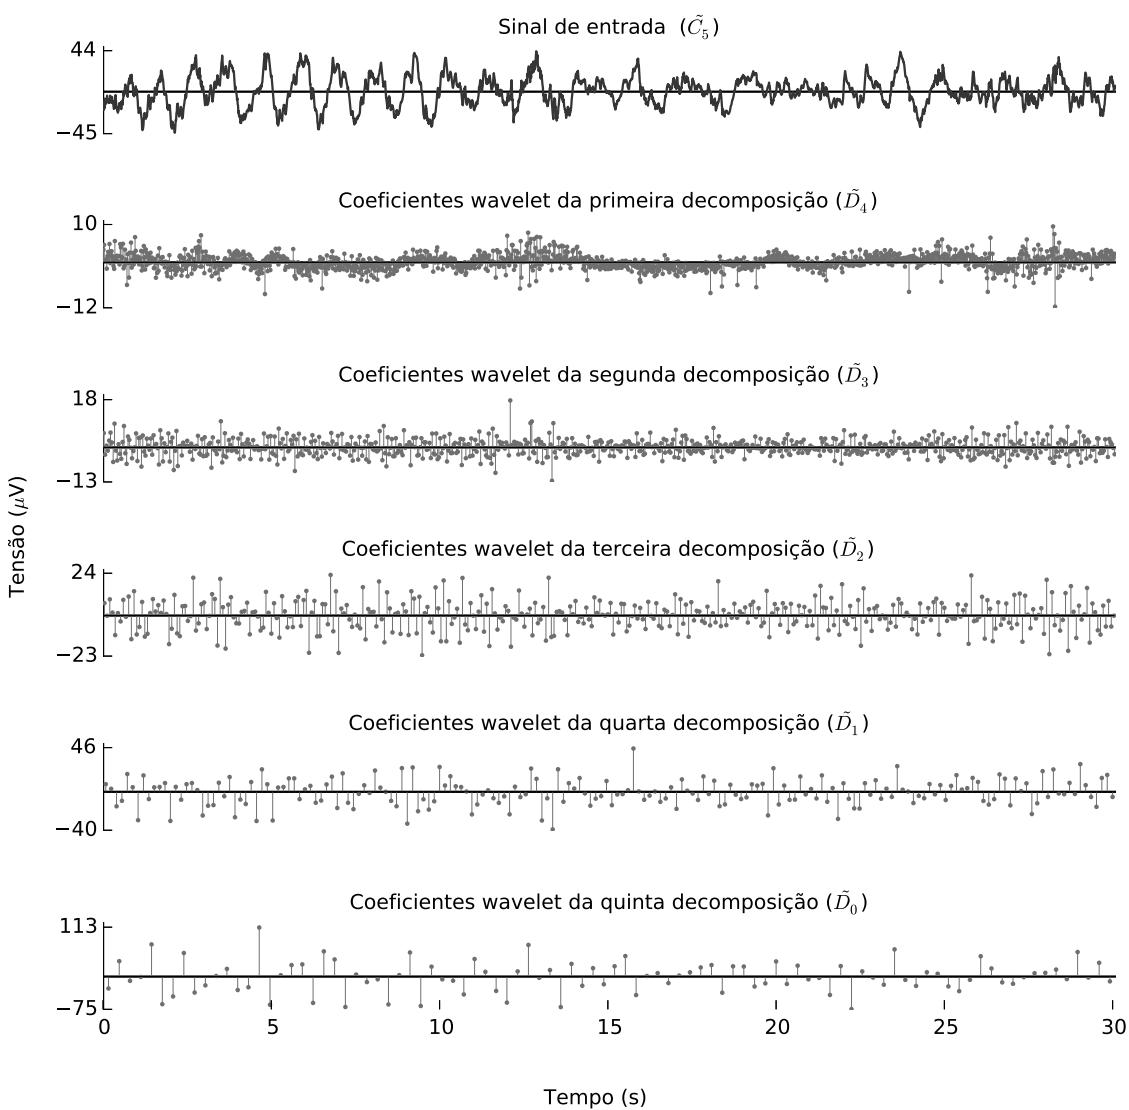


Figura 2.12: Decomposição *wavelet* em cinco níveis da 1800^a época da segunda noite do sujeito de número 11. Neste momento, de acordo com os especialistas do *PhysioBank*, este encontra-se em S4.

2.3.2 Redução de dimensionalidade e seleção de atributos

A escolha de um conjunto apropriado de características que representem os dados originais de EEG é a tarefa *mais importante e difícil* de ser realizada (ZHU; LI; WEN, 2014). Além disso, a má escolha dessas características resulta no desempenho deteriorado dos algoritmos de classificação em problemas de reconhecimento de padrões. Neste trabalho, a decomposição *wavelet* do sinal em múltiplas resoluções aponta, de forma compacta, importantes variações no comportamento dos sinais (padrões) em diversas faixas de frequência relacionadas a ritmos cerebrais conhecidos. Visando destacar ainda mais essas variações dentro dos conjuntos de coeficientes de detalhes e de escala ($\tilde{D}_4 - \tilde{D}_0$ e \tilde{C}_0) e, principalmente, reduzir drasticamente o conjunto de características necessárias para classificação, são extraídas a variância, a curtose e a assimetria.

RONZHINA et al. (2012) enfatizam o uso de medidas estatísticas em aplicações de análise do sono. De acordo com tais autores, a média, a mediana, o desvio-padrão, a curtose e a assimetria já foram utilizadas para análise de sinais fisiológicos no domínio de tempo. Estudos recentes como ŞEN et al. (2014); LAJNEF et al. (2015) aplicam algumas dessas medidas diretamente sobre os sinais de PSG para obter características importantes que serão processadas na etapa de classificação. KOLEY; DEY (2012) consideram os primeiros quatro momentos estatísticos tanto no domínio de tempo quanto no domínio de frequências, como parte de um conjunto de 39 características para classificação de estágios de sono. No trabalho destes autores, quando a transformada de Fourier é aplicada, todo o espectro é utilizado e, portanto, uma única característica, correspondente a todo espectro de frequências do sinal, é obtida.

As características aqui extraídas expressam, respectivamente, a dispersão ($\text{Var}(X)$), o grau de compressão ($\text{Kurt}(X)$) e o grau de simetria ($\text{Skew}(X)$) de uma distribuição de dados X (LAJNEF et al., 2015), neste caso, delimitada em faixas de frequência de interesse para o problema (baixo-gama, beta, alfa, teta e delta). Tomando os conjuntos de coeficientes $\tilde{D}_4 - \tilde{D}_0$ e \tilde{C}_0 como X , têm-se a variância, a curtose e a assimetria (PRESS et al., 1992) definidas, respectivamente, por

$$\text{Var}(X) = \frac{\sum_{i=1}^T (X_i - \bar{X})^2}{T}, \quad (2.9)$$

$$\text{Kurt}(X) = \frac{1}{T} \frac{\sum_{i=1}^T (X_i - \bar{X})^4}{\text{Var}(X)^2} - 3, \quad (2.10)$$

$$\text{Skew}(X) = \frac{1}{T} \frac{\sum_{i=1}^T (X_i - \bar{X})^3}{\text{Var}(X)^{3/2}}, \quad (2.11)$$

em que T e \bar{X} são, respectivamente, a cardinalidade e o valor médio dos coeficientes contidos no conjunto de dados X . A constante presente na Equação 2.10 apenas faz com que dados cuja distribuição é normal apresentem curtose igual a zero (PRESS et al., 1992).

Esses 18 valores (estimadores estatísticos das Equações 2.9, 2.10 e 2.11 aplicados sobre $\tilde{D}_4 - \tilde{D}_0$ e \tilde{C}_0) são obtidos para cada uma das 106.377 épocas de 30 segundos consideradas no presente trabalho. Depois de extraídas, todas as características são agrupadas em um único conjunto onde são mantidas as anotações dos especialistas, possibilitando a construção de um modelo de classificação e teste, como em FRAIWAN et al. (2012); ZHU; LI; WEN (2014). É importante destacar que este conjunto de 18 características é o mesmo usado para identificar quaisquer estágios de sono, *independente do cenário de classificação* (2, 3, 4, 5 e 6 estágios de estados de sono).

A Figura 2.13 exemplifica a aplicação dessas características em regiões de transição dos estágios W para S1 e S1 para S2. Para melhor visualização, medidas de curtose e a assimetria foram multiplicadas, respectivamente, por 5 e 15 e a variância foi, nos dois últimos gráficos, omitida. Note que esses atributos estatísticos são sensíveis às diferentes faixas de frequência e estágios de sono. Além disso, informações ressaltadas por algumas dessas métricas complementam aquelas destacadas por outras, como as medidas de curtose e variância, respectivamente, do primeiro e quarto gráficos da Figura 2.13.

2.4 Classificação

2.4.1 Waikato Environment for Knowledge Analysis (WEKA)

Mineração de dados, segundo (WITTEN; FRANK; HALL, 2011), é um processo automático ou semi-automático com o qual, através de uma técnica de aprendizado de máquina, é possível encontrar padrões em um conjunto de dados. Tal conceito, antes mesmo de sua nomeação, já era aplicado empiricamente em listas de controle de vendas de mercados ou em tabelas de dados científicos com a mesma finalidade. Este processo, agora computacional, se torna um aliado tanto na pesquisa científica quanto aplicada ao comércio visto que, com a crescente quantidade de dados, é praticamente impossível que se encontre padrões por inspeção manual.

Diversas técnicas de aprendizado de máquina foram propostas ao longo dos anos - cada

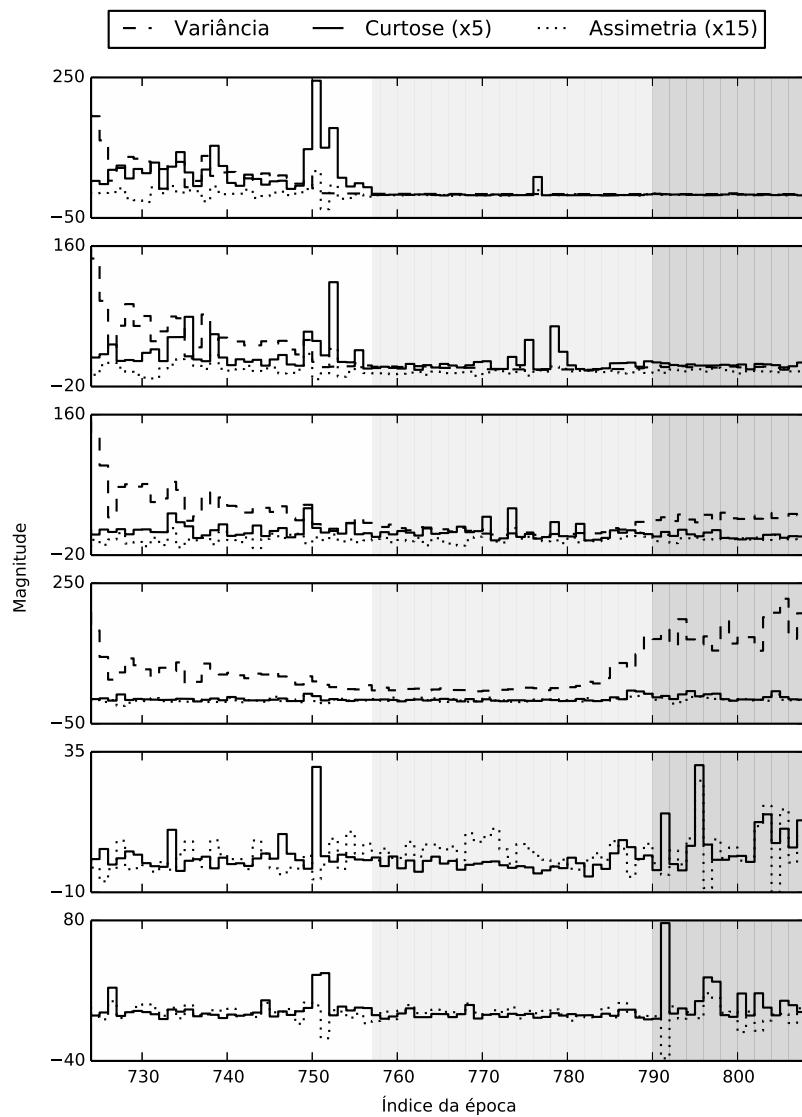


Figura 2.13: Variância, curtose (multiplicada por 5) e assimetria (multiplicada por 15) dos coeficientes *wavelet* em cada um dos cinco níveis de decomposição e do último conjunto de coeficientes de escala (de cima para baixo, respectivamente) da segunda noite do sujeito de número 02. As cores de fundo branco, cinza claro e cinza escuro correspondem, respectivamente, aos estágios W, S1 e S2, de acordo com as anotações do banco de dados.

uma com suas vantagens e desvantagens. Aglomeração de dados, identificação de regras de associação ou classificação de dados desconhecidos de acordo com dados já conhecidos são exemplos de aplicações-foco de algumas técnicas de aprendizado de máquina. O *software* de mineração de dados WEKA (HALL et al., 2009) desenvolvido pelo Grupo de Aprendizado de Máquina da Universidade de Waikato (Nova Zelândia) conta com uma série de implementações dessas técnicas. O acrônimo WEKA refere-se a *Waikato Environment for Knowledge Analysis* e, como símbolo, homenageia um pássaro nativo da Nova Zelândia que tem mesmo nome. O WEKA é *Open Source*, sob licença GNU (*General Public License*), e totalmente desenvolvido em linguagem Java, embora haja *wrappers* para outras linguagens como, por exemplo, Python.

Neste estudo, assim como em trabalhos correlatos (OSHIRO; PEREZ; BARANAUSKAS, 2012; FRAIWAN et al., 2012; RADHA et al., 2014), esta ferramenta é utilizada para tarefa de classificação. Todos os classificadores disponíveis foram testados, visando explorar o potencial destes algoritmos e da ferramenta em si no contexto de processamento de sinais. Uma relação do desempenho e tempo de execução desses classificadores é dada no Apêndice B. O algoritmo de floresta aleatória teve o melhor desempenho em todos os casos pré-analisados neste estudo. A superioridade deste algoritmo também é destacada em outras pesquisas relacionadas à análise do sono, onde o melhor custo benefício é atingido quando comparado com outros algoritmos de classificação (FRAIWAN et al., 2012; RADHA et al., 2014; ŞEN et al., 2014).

2.4.2 Florestas aleatórias

O algoritmo de florestas aleatórias, introduzido por BREIMAN (2001), é rápido, robusto a ruídos e livre de superajuste (*overfitting*) (HASTIE; TIBSHIRANI; FRIEDMAN, 2009; WITTEN; FRANK; HALL, 2011). Seu objetivo é combinar as classificações individuais de N árvores de decisão, cada uma construída com F atributos ou características, em uma só rotulagem. O número de atributos F obedece $F = \lfloor \log_2 P + 1 \rfloor$, sendo P a quantidade total de características do conjunto de dados (KHOSHGOFTAAR; GOLAWALA; HULSE, 2007). Neste estudo, têm-se $P = 18$ e, portanto, cada árvore de decisão é gerada com $F = 5$ atributos. A escolha de quais F características irão ser utilizadas para crescimento de cada árvore é feita de forma totalmente aleatória (BREIMAN, 2001) e a precedência desses atributos no corpo da árvore é guiada pelo estimador interno de ganho de informação (FRAIWAN et al., 2012).

Em OSHIRO; PEREZ; BARANAUSKAS (2012), medidas de densidade de conjuntos de dados foram propostas visando identificar quantas árvores uma floresta aleatória deve ter para

prover resultados acurados. Tais autores fizeram experimentos mostrando que usando tanto 64, 128, 256, 512 quanto 1024 árvores, atinge-se acurácia praticamente igual quando são considerados conjuntos de dados de baixa densidade. De acordo com as métricas propostas por tais autores, o conjunto de dados aqui utilizado deve ser considerado como de baixa densidade, e portanto o número de árvores escolhido é $N = 64$. BREIMAN (2001) endossa as conclusões expostas acima, demonstrando que, ao incrementar o número de árvores, aumenta-se o custo computacional, enquanto a taxa de acertos converge para um limite.

A construção de uma floresta aleatória é realizada como segue. A técnica de amostragem com reposição é aplicada sobre todo o conjunto de treino, gerando N conjuntos de mesmo tamanho, chamados de *in-bag*. Cada uma das N árvores de decisão considera seu conjunto *in-bag* como conjunto de treino, selecionando aleatoriamente F atributos para seu crescimento. BREIMAN (2001) sustenta que, ao considerar os conjuntos *in-bag*, que contém redundâncias, juntamente com a seleção aleatória de F características, aumenta-se o desempenho do classificador, tornando-o mais robusto a ruídos. De acordo com FRAIWAN et al. (2012), muitas árvores de decisão podem ser utilizadas, como árvores aleatórias, CART, J48, árvores REP, C4.5, CHAID, etc. A implementação de florestas aleatórias disponível na ferramenta WEKA utiliza árvores aleatórias como algoritmo para os N preditores. Cada árvore cresce ao máximo e nenhuma técnica de poda é aplicada. A classificação de uma floresta aleatória é dada pela moda dos votos das N árvores de decisão que a compõe (FRAIWAN et al., 2012). A Figura 2.14 – adaptada de FRAIWAN et al. (2012) – ilustra, na forma de um fluxograma, o procedimento de construção de uma floresta aleatória.

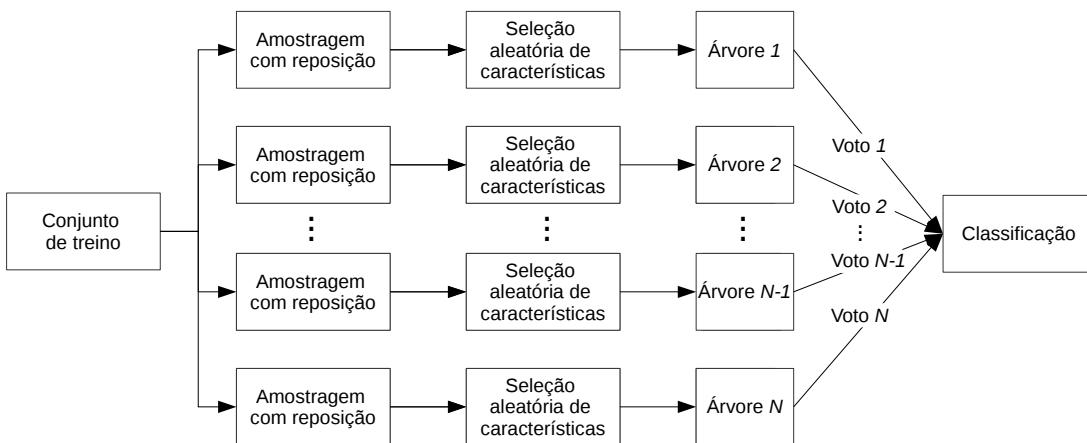


Figura 2.14: Arquitetura de um classificador do tipo floresta aleatória. Figura adaptada de (FRAIWAN et al., 2012).

2.5 Fluxograma do método

Nas seções anteriores deste capítulo foram introduzidos os conceitos básicos e explicado cada passo (pré-processamento, extração de características e classificação) do método aqui proposto. A Figura 2.15 resumidamente reapresenta estes passos, agora em forma de fluxograma, juntamente com o método de avaliação *10-fold cross validation*, o qual é considerado para análise de resultados.

Note que os passos 2 (Seção 2.1.3), 4 (Seção 2.2.2) , 7 (Seção 3.1) , 8.1 (Seção 2.4.2) são executados para que se possa construir e avaliar o método de classificação proposto com confiabilidade. Após a construção do método, quando se desconhece os verdadeiros estágios de sono de um sinal de EEG problema e quer-se classificá-lo, apenas os passos 1 (Seção 2.1.3), 3 (Seção 2.2.1) , 5 (Seção 2.3.1.2) , 6 (Seção 2.3.2) , 8.2 (Seção 2.4.2) e 9 são executados.

Como resultado da execução do processo completo (passos 1 a 9), são obtidas as matrizes de confusão para as classificações de 2 a 6 estados de estágios de sono. A partir dessas matrizes, métricas de desempenho podem ser calculadas. As métricas, matrizes de confusão e resultados são apresentados e discutidos no Capítulo 3.

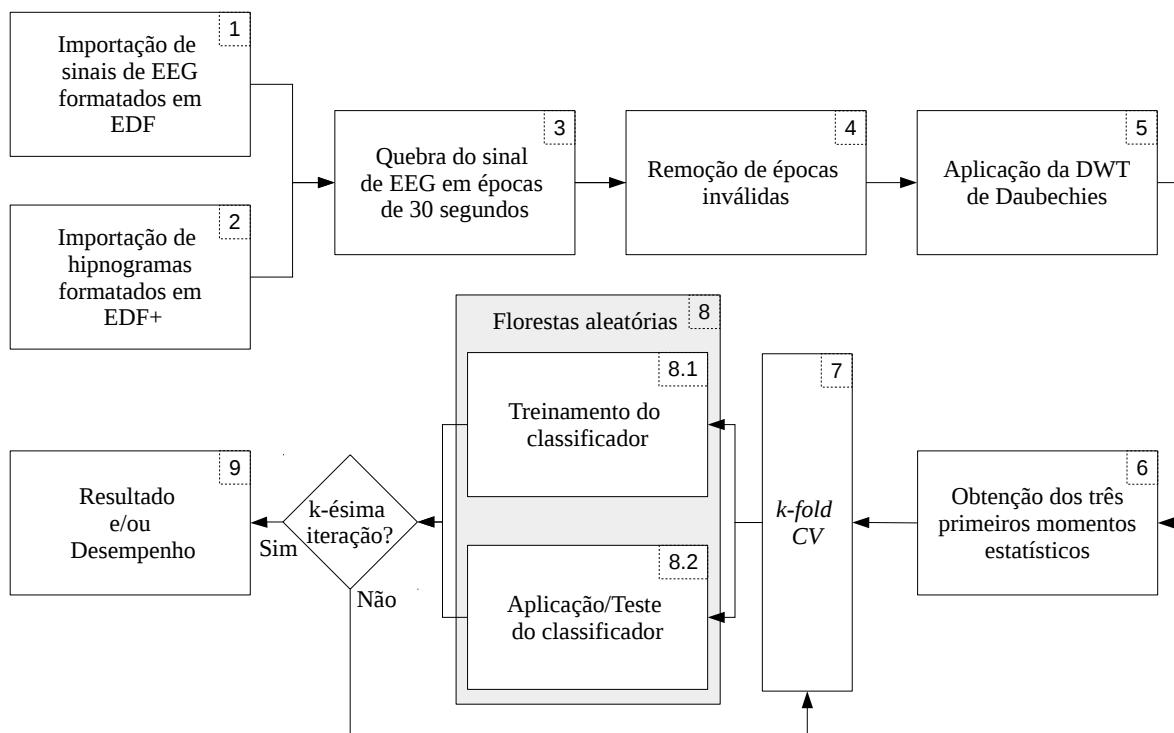


Figura 2.15: Fluxograma da metodologia proposta e a técnica de *k-fold cross validation* para avaliação de seu desempenho.

3 RESULTADOS E DISCUSSÕES

3.1 Experimento e métricas de avaliação

Dado um algoritmo de classificação, várias medidas podem ser calculadas para avaliação de seu desempenho. No presente trabalho, toma-se o cuidado em considerar aquelas medidas (funções de custo) que são amplamente utilizadas e, portanto, tidas como mais as representativas. O desempenho geral de um método de classificação, isto é considerando seu comportamento perante todas as classes do problema, pode ser medido pela acurácia total (WITTEN; FRANK; HALL, 2011) e pelo coeficiente *kappa* de COHEN (1960). Além destas medidas de desempenho, figuras de mérito como precisão e revocação (ALPAYDIN, 2010) apresentam-se como importantes indicadores de qualidade de um classificador no reconhecimento de cada classe separadamente.

Todas as métricas recém citadas são calculadas através da análise da matriz de confusão (HAN; KAMBER, 2012). Uma matriz de confusão é uma matriz quadrada que relaciona todos os acertos e erros por classe obtidos pela metodologia de classificação que está sendo avaliada. Para construção dessa matriz, pressupõe-se que as verdadeiras classes das instâncias submetidas ao método de classificação sejam conhecidas. No presente trabalho, assim como em BERTHOMIER et al. (2007); RONZHINA et al. (2012); ZHU; LI; WEN (2014), as anotações realizadas pelos especialistas do sono (hipnogramas) são consideradas corretas, sendo utilizadas na etapa de validação do método proposto. Apesar disso, sabe-se que a concordância entre dois especialistas do sono não é de 100%, como apontado em estudos como ANDERER et al. (2005); RONZHINA et al. (2012). No entanto, nada se pode fazer quanto a isso, uma vez que este é um problema inerente ao método, herdando a subjetividade e experiência dos especialistas.

A acurácia de um método de classificação, cuja matriz de confusão é \mathbf{M} , é obtida por

$$\text{Acc}(\mathbf{M}) = \frac{\sum_{i=1}^Q \mathbf{M}_{ii}}{\sum_{i=1}^Q \sum_{j=1}^Q \mathbf{M}_{ij}}, \quad (3.1)$$

sendo \mathbf{M}_{ij} o elemento na i -ésima linha e j -ésima coluna da matriz de confusão \mathbf{M} e Q a ordem desta matriz e também o número de classes do problema. Com os mesmos parâmetros,

calculam-se a precisão e a revocação para a classe na linha/coluna i de \mathbf{M} , respectivamente, por

$$\text{Pre}(\mathbf{M}, i) = \frac{\mathbf{M}_{ii}}{\sum_{j=1}^Q \mathbf{M}_{ji}} \text{ e} \quad (3.2)$$

$$\text{Rec}(\mathbf{M}, i) = \frac{\mathbf{M}_{ii}}{\sum_{j=1}^Q \mathbf{M}_{ij}}. \quad (3.3)$$

A medida de acurácia aponta a porcentagem total de acertos obtidos pelo classificador avaliado. A precisão indica a relação entre a quantidade de instâncias classificadas corretamente pela quantidade de instâncias rotuladas como pertencentes àquela classe. A medida de revocação apresenta a porcentagem de objetos que foram corretamente classificados como referentes àquela classe.

Por outro lado, o coeficiente *kappa* mede a acurácia de um método, subtraindo a fração relacionada à probabilidade de acerto ao acaso (BEN-DAVID, 2008) que, hipoteticamente, qualquer classificador poderia obter.

O coeficiente *kappa* é calculado através de

$$\kappa(\mathbf{M}) = \frac{\text{Acc}(\mathbf{M}) - \text{EA}(\mathbf{M})}{1 - \text{EA}(\mathbf{M})}, \quad (3.4)$$

sendo

$$\text{EA}(\mathbf{M}) = \frac{\sum_{i=1}^Q \left(\sum_{j=1}^Q \mathbf{M}_{ij} \sum_{j=1}^Q \mathbf{M}_{ji} \right)}{\left(\sum_{i=1}^Q \sum_{j=1}^Q \mathbf{M}_{ij} \right)^2} \quad (3.5)$$

a conformidade esperada (LANDIS; KOCH, 1977). $\text{Acc}(\mathbf{M})$ é a acurácia, que é a conformidade observada (VIERA; GARRETT, 2005). Para interpretar o valor do coeficiente *kappa*, pode-se utilizar a análise qualitativa de LANDIS; KOCH (1977), apresentada na Tabela 3.1.

Tabela 3.1: Interpretação qualitativa do coeficiente *kappa* de LANDIS; KOCH (1977).

Nível de qualidade do classificador	Valor do coeficiente <i>kappa</i>
Excelente	> 0,80
Bom	0,61 – 0,80
Razoável	0,41 – 0,60
Pobre	0,21 – 0,40
Ruim	0 – 0,20
Muito ruim	< 0

Com o intuito de aumentar a confiabilidade dos resultados obtidos pela aplicação da metodologia proposta, a técnica de *k-fold cross validation* (ALPAYDIN, 2010) (*k-fold CV*),

com $k = 10$, é empregada. O robusto método de k -fold CV consiste em dividir aleatoriamente o conjunto de dados completo (neste caso, as 18 características das 106.377 épocas) em k partes de tamanho aproximadamente igual. Destes, $k - 1$ subconjuntos são utilizados para treinar o classificador, enquanto que o subconjunto restante é usado na fase de teste. Este processo é repetido k vezes e cada subconjunto restante é usado para teste apenas uma vez. A medida de avaliação final é dada pela média das k execuções deste procedimento (RONZHINA et al., 2012). WITTEN; FRANK; HALL (2011) alegam que extensivos testes em diversos conjuntos de dados, através de diferentes algoritmos de aprendizado de máquina, têm mostrado que $k = 10$ é aproximadamente o número ideal para se obter a melhor estimativa de erro e que há estudos teóricos que evidenciam isto.

3.2 Desempenho geral da metodologia

No caso mais simples, o de duas classes, obteve-se uma acurácia média de 97,3% e um coeficiente *kappa* igual a 0.94. A matriz de confusão para a classificação das épocas em W ou SLP é apresentada na Tabela 3.2.

Os resultados obtidos neste trabalho para a classificação de 2 estados de estágios de sono superam em 1,5 – 3,2% aqueles publicados em estudo prévio (SILVEIRA; KOZAKEVICIUS; RODRIGUES, 2015) – disponível no Apêndice C. Em tal ocasião foram utilizados três algoritmos de árvores de decisão – árvores aleatórias, e algoritmos REP e CART – para classificação acordado/dormindo com abordagem para extração de características semelhante. Ademais, os resultados aqui reportados são superiores aos relatados no recente estudo de SANO; PICARD (2014) que utilizam SVM e k-vizinhos mais próximos (k-NN) para classificação de características extraídas de sinais de EEG, condutância e temperatura da pele, e dados de aceleração obtidos

Tabela 3.2: Matriz de confusão para a classificação de 2 estados de estágios de sono

		Método proposto	
		W	SLP
Especialistas	W	71419	934
	SLP	1939	32084
Precisão (%)		97,4	97,2
Revocação (%)		98,7	94,3

via pulseiras eletrônicas. As medidas de acurácia obtidas em tal estudo foram de 83% usando apenas EEG, 73% usando os demais sinais e 95% utilizando todos os sinais. Em termos de precisão e revocação médias, os resultados obtidos no presente estudo também são superiores em aproximadamente dois pontos percentuais em relação àqueles publicados em SILVEIRA; KOZAKEVICIUS; RODRIGUES (2015).

A matriz de confusão para classificação dos estados W, NREM e REM é apresentada na Tabela 3.3. Os valores para acurácia total e coeficiente *kappa* atingem, respectivamente, 93,9% e 0,87. Os estados W e NREM têm altas taxas de precisão e revocação, diferindo dos resultados médios para o estado REM, que é confundido na maioria das vezes com o NREM. Para este caso, há propostas recentes que se preocupam exclusivamente com a distinção do estado REM, como é o caso de IMTIAZ; RODRIGUEZ-VILLEGAS (2014). Os resultados obtidos no estudo corrente apresentam precisão maior em 2,1% e revocação inferior em 17,5% com relação a tal estudo – onde a base de dados *Sleep-EDF*, contendo pouco mais de 20% da quantidade de dados da base expandida, é considerada.

O desempenho da metodologia proposta no problema de classificação de 4 estados de estágios de sono é mostrado na Tabela 3.4. Nota-se que os desempenhos individuais para identificação dos estados W e REM permanecem praticamente inalterados, quando comparados com os do cenário anteriormente discutido (com 3 estados de estágios de sono). Os valores de precisão e revocação para S1/S2 e SWS mantém-se na faixa de 80 a 90%. Como ocorre com o estado REM, há recentes metodologias cujo objetivo é exclusivamente a identificação do estado SWS (SU et al., 2015). Tais autores testam sua proposta em sinais de 1003 sujeitos, obtendo valores de revocação e precisão, respectivamente, iguais a 64,4% e 70,9%. Ao considerarem apenas sujeitos saudáveis e não-idosos, como acontece no presente trabalho, os valores obti-

Tabela 3.3: Matriz de confusão para a classificação de 3 estados de estágios de sono

		Método proposto		
		W	NREM	REM
Especialistas	W	71669	500	184
	NREM	1743	23287	1276
	REM	562	2251	4904
Precisão (%)		96,9	89,4	77,1
Revocação (%)		99,1	88,5	63,5

Tabela 3.4: Matriz de confusão para a classificação de 4 estados de estágios de sono

		Método proposto			
		W	S1/S2	SWS	REM
Especialistas	W	71718	436	15	184
	S1/S2	1680	16983	655	1285
	SWS	87	1063	4552	1
	REM	555	2234	5	4923
Precisão (%)		96,9	82,0	87,1	77,0
Revocação (%)		99,1	82,4	79,8	63,8

dos por tais autores sobem para 75,8% e 81,2%, respectivamente. Nota-se que a metodologia proposta obtém interessantes resultados na identificação de SWS, mesmo quando comparada com SU et al. (2015). Em termos proporcionais, percebe-se que REM é mais frequentemente classificado de forma incorreta como S1/S2 e do que como SWS ou W.

Uma das mais utilizadas classificações de estados de sono é a de 5 estados. Tal divisão de classes é suportada pelo recente guia desenvolvido pela AASM (IBER et al., 2007). MOSER et al. (2009) afirma que, apesar das reformulações introduzidas pela AASM, ambas as classificações em cinco estados são equivalentes. Ao observar a Tabela 3.5, onde é apresentada a matriz de confusão para este caso, nota-se que grande parcela dos acertos relativos ao estado S1/S2 (existente no cenário de classificação em 4 estados) é referente à identificação de S2.

Este comportamento já foi observado em diversos outros estudos (LIANG et al., 2012). O estágio S1 é facilmente classificado de forma errônea como um de seus estágios adjacentes ou REM (CORSI-CABRERA et al., 2006; ZHU; LI; WEN, 2014). De acordo com RONZHINA et al. (2012), as arquiteturas de ANN apresentadas por tais autores não são capazes de obter bons resultados para S1 e S3, uma vez que seu conjunto de dados contém poucos exemplares de épocas destas classes. No presente estudo, embora o número de épocas por classe represente um cenário real, há deficiência semelhante quanto ao número de instâncias relacionadas ao estado S1. Como exemplo de baixa performance quando focalizada a classificação de S1, pode-se citar BERTHOMIER et al. (2007), em que são atingidos 35,6% de revocação e 14,8% de precisão, quando tais autores consideram uma base de dados privada. O Apêndice D apresenta algumas alternativas de pré-processamento, preservando o restante da metodologia, que foram investigadas com o intuito aumentar os valores obtidos para revocação de S1.

Tabela 3.5: Matriz de confusão para a classificação de 5 estados de estágios de sono

		Método proposto				
		W	S1	S2	SWS	REM
Especialistas	W	71819	45	251	14	224
	S1	1159	170	751	3	721
	S2	692	27	15487	633	960
	SWS	92	0	1057	4550	4
	REM	603	42	1740	3	5329
Precisão (%)		96,6	59,9	80,3	87,4	73,6
Revocação (%)		99,3	6,1	87,0	79,8	69,1

Nota-se que, neste trabalho, o reconhecimento das demais classes mantém-se praticamente constante à medida que são adicionadas novas classes ao problema. As métricas de precisão obtidas no presente trabalho para W, S1 e S2 são maiores em 11,8%, 6,6% e 10% quando comparadas com KRAKOVSKÁ; MEZEIOVÁ (2011). A mesma mensuração, quando a comparação é feita com LIANG et al. (2012), para W, S1, SWS e REM, apresenta diferenças de 61,8%, 40,3%, 7,4% e 5,7%. Os valores de revocação para W e S2, em comparação com FRAIWAN et al. (2012) e com HSU et al. (2013) são, respectivamente, maiores em 9,7% e 6,5% e 34,8% e 26,5%. A medida de revocação para SWS supera em 2,5% aquela obtida em ZHU; LI; WEN (2014), para este cenário, e tem valores inferiores em, no máximo, 5% quando comparados com aqueles reportados em LIANG et al. (2012); FRAIWAN et al. (2012). A medida de revocação de REM é 6,1% maior que as obtidas em BERTHOMIER et al. (2007), quando a base *Sleep-EDF* é utilizada, e CHARBONNIER et al. (2011), quando apenas sinais de EEG são considerados.

A Tabela 3.6 compara o desempenho da metodologia proposta no cenário de classificação em 5 estados de estágios de sono com outros estudos. Note que a metodologia proposta atinge um ganho de 2,5 a 17,5% no quesito acurácia dentre os estudos comparados. Além disso, no presente estudo é considerado um conjunto de dados de 1,7 a 37 vezes maior do que os utilizados nos demais estudos. Esta grande quantidade de dados está sujeita a maiores variações no comportamento dos sinais fisiológicos dos diversos indivíduos e, portanto, caracteriza-se com um fator positivo para análise da robustez do método proposto.

Tabela 3.6: Análise comparativa para a classificação de 5 estados de estágios de sono

Metodologia	Características - Classificador - Quantidade de épocas analisadas	Acurácia
LIANG et al. (2012)	Entropia multi-escala - LDA - 3.708	76,9%
FRAIWAN et al. (2012)	Entropia de Renyi - Florestas aleatórias - 20.269	83,0%
KRAKOVSKÁ; MEZEIOVÁ (2011)	Diversas características extraídas de EEG, ECG, EMG e EOG - QDA - 18.058	81,0%
CHARBONNIER et al. (2011)	Diversas características extraídas de EEG, EMG, EOG e ECG - ANN - 62.399	85,5%
HSU et al. (2013)	Energia - PNN, FNN e Redes neurais de Elman - 2.880	87,2%
ZHU; LI; WEN (2014)	DVG e HVG - SVM - 14.963	89,0%
Metodologia proposta	Variância, curtose e assimetria - Florestas aleatórias - 106.377	91,5%

Na Tabela 3.7 é apresentada a matriz de confusão para a classificação mais completa: a dos 6 estados de estágios de sono. Nota-se que, através dos resultados obtidos neste cenário de classificação, confirma-se claramente o que foi declarado em CORSI-CABRERA et al. (2006) e comentado anteriormente a respeito de S1. O estado S1 foi completamente discriminado de S3 e S4 pela metodologia proposta e é frequentemente confundido com W, S2 e REM.

Em comparação com FRAIWAN; KHASWANEH; LWEESY (2009), que utilizaram um conjunto de apenas 936 épocas para treino e teste de sua metodologia, o presente estudo atinge melhores resultados em termos de precisão de W com um significante acréscimo de 44% e revocação com 3,6% a mais. A revocação para S2 do método proposto, quando comparado com AGARWAL; GOTMAN (2001), apresenta um acréscimo de 63,7%. Valores de revocação para W, S1 e S2 são superiores aos de DOROSHENKOV; KONYSHEV; SELISHCHEV (2007) em, respectivamente, 48,3, 0,8 e 18,7 pontos percentuais. Tais autores consideram a reduzida base *Sleep-EDF*.

A Tabela 3.8 compara os valores de acurácia e coeficiente *kappa* do atingidos pelo método proposto com outras três metodologias (BERTHOMIER et al., 2007; RONZHINA et al., 2012; ZHU; LI; WEN, 2014) que utilizam registros da mesma base de dados, o mesmo canal de

Tabela 3.7: Matriz de confusão para a classificação de 6 estados de estágios de sono

		Método proposto					
		W	S1	S2	S3	S4	REM
Especialistas	W	71836	40	239	4	2	232
	S1	1176	164	746	0	0	718
	S2	690	20	15605	492	37	955
	S3	74	0	1102	1734	457	3
	S4	35	0	94	618	1586	0
	REM	605	47	1755	2	1	5307
Precisão (%)		96,5	60,5	79,9	60,8	76,1	73,6
Revocação (%)		99,3	5,8	87,7	51,5	68,0	68,8

Tabela 3.8: Acurárias e coeficientes *kappa* para classificações de 2 a 6 estados de estágios de sono

Metodologia	Quantidade de estados de estágios de sono				
	2	3	4	5	6
BERTHOMIER et al. (2007)	95,4%	88,3%	74,5%	71,2%	-
	0,83	0,76	0,63	0,61	-
RONZHINA et al. (2012)	96,9%	90,3%	81,4%	-	76,7%
	-	-	-	-	-
ZHU; LI; WEN (2014)	97,9%	92,6%	89,3%	88,9%	87,5%
	0,96	0,87	0,83	0,83	0,81
Método proposto	97,3%	93,9%	92,3%	91,5%	90,5%
	0,94	0,87	0,84	0,83	0,80

EEG para análise e o mesmo guia para classificação do sono. Pelo que foi observado no estado da arte atual, estes são os únicos trabalhos que propõem métodos para resolver todas as classificações de 2 a 6 estados de estágios de sono. Nota-se que o método aqui proposto apresenta acurárias maiores do que os demais para 3 a 6 estados. Os valores de *kappa* apresentam-se comparáveis aqueles obtidos em ZHU; LI; WEN (2014) e superiores aos dos demais estudos.

É notável também que, de acordo com a interpretação qualitativa do coeficiente *kappa* proposta por LANDIS; KOCH (1977) e ilustrada na Tabela 3.1, a metodologia proposta é considerada *excelente*. Dois importantes pontos favoráveis ao método proposto e que merecem

ser destacados aqui são (i) a adoção de um *único conjunto de características* para representar as épocas, independentemente do número de estágios de sono avaliados (diferentemente dos demais trabalhos - que atribuem seus bons resultados graças a escolha de características dependentemente do cenário de classificação); e (ii) a utilização de um robusto conjunto de treino e teste contendo mais de 100.000 épocas de 30 segundos referentes à 39 registros, o que nos leva a crer que o método é, de fato, robusto.

3.3 Outras avaliações da metodologia

Nesta Seção, são apresentadas dois novos testes do método proposto, variando a quantidade relativa de épocas por classe e a forma de avaliação do método de classificação. Os resultados destes novos testes são comparados com FRAIWAN et al. (2012), visto que tais autores utilizam *wavelets* contínuas e florestas aleatórias, e o recente ZHU; LI; WEN (2014), que obtêm interessantes e competitivos resultados.

3.3.1 Comparação com FRAIWAN et al. (2012)

Objetivando tornar os testes da metodologia proposta mais próximos daqueles realizados por FRAIWAN et al. (2012), diminuindo as diferenças nos contextos de avaliação, dois pontos foram reajustados. Os procedimentos de pré-processamento, decomposição do sinal e extração de características permanecem os mesmos, bem como o número de árvores de decisão do classificador.

Primeiramente, de forma aleatória, foram selecionadas 7.641, 1.152, 6.761, 2.293 e 2.431 épocas, respectivamente, em W, S1, S2, SWS e REM. Tal configuração de épocas por classe, totalizando 20.269 épocas, é exatamente a mesma utilizada por FRAIWAN et al. (2012). Em um segundo passo, ao invés de utilizar *10-fold CV*, como anteriormente, separamos o conjunto total de características *versus* número de épocas em dois terços para treino e um terço para teste. Os classificadores foram treinados e testados dez vezes sob esta heurística. Os resultados médios para a classificação de 5 estados de estágios de sono, como feito em FRAIWAN et al. (2012), foram de 85,9% de acurácia e um coeficiente *kappa* de 0,8. Os resultados reportados em FRAIWAN et al. (2012) foram, respectivamente, 83% para acurácia e 0,76 para o *kappa*.

A Tabela 3.9 apresenta, de forma resumida, as semelhanças e diferenças entre a metodologia proposta e a encontrada em FRAIWAN et al. (2012). Diferentemente do que ocorre

Tabela 3.9: Comparação de metodologia com FRAIWAN et al. (2012).

Recurso	FRAIWAN et al. (2012)	Método proposto
Padrão para classificação do sono	AASM	R&K
Base de dados	Clínica torácica da Universidade de Heidelberg	<i>Sleep EDF [Expanded]</i>
Canal de EEG	C3A1 a 100Hz	Pz-Oz a 100Hz
Extrator de características	CWT	DWT
Característica(s)	Entropia de Renyi	Variância, curtose e assimetria
Classificador	Florestas aleatórias	Florestas aleatórias
Quantidade de épocas	20.269	106.377
Acurárias para a classificação de 5 estados	83%	91,5%

em FRAIWAN et al. (2012), no presente trabalho um banco de dados público é utilizado, o que permite que outros pesquisadores possam reproduzir por inteiro os resultados aqui obtidos. Também, a escolha da DWT em contraste com a CWT é preferível uma vez que além de consumir menos recursos, gera menos dados redundantes o que é benéfico para o classificador, reduzindo também o tempo de processamento.

3.3.2 Comparação com ZHU; LI; WEN (2014)

Da mesma forma que na Seção 3.3.1, novos testes visando uma melhor comparação com ZHU; LI; WEN (2014) foram feitos. Novamente, os passos referentes a pré-processamento, análise dos sinais e extração de características foram mantidos inalterados. Além disso, número de árvores de decisão manteve-se em 64. Dessa vez, foram selecionadas 7.830, 604, 3.621, 672, 627 e 1.609 épocas, respectivamente, em W, S1–S4 e REM, como em ZHU; LI; WEN (2014). Da mesma forma como tais autores fazem em seu trabalho, também utilizamos *10-fold CV*. Os procedimentos de seleção aleatória de épocas, construção e teste do classificador também foram repetidos dez vezes. Os resultados médios obtidos nestes novos testes em comparação com aqueles reportados em ZHU; LI; WEN (2014) são resumidos na Tabela 3.10.

Nota-se que, novamente, os melhores resultados em termos de acurácia para as classificações de 3 a 6 estágios de sono são obtidos pela aplicação da metodologia proposta. Além disso, os valores de *kappa* aumentaram em, ao menos, dois centésimos em cada cenário, maximizando a diferença de desempenho da proposta deste trabalho com relação à (ZHU;

Tabela 3.10: Comparação de desempenho com ZHU; LI; WEN (2014).

Cenário de classificação	ZHU; LI; WEN (2014)		Método proposto	
	Acurácia	<i>Kappa</i>	Acurácia	<i>Kappa</i>
W - SLP	97,9%	0,96	97,8%	0,96
W - NREM - REM	92,6%	0,87	93,8%	0,89
W - S1/S2 - SWS -REM	89,3%	0,83	91,2%	0,86
W - S1 - S2 - SWS - REM	88,9%	0,83	90,3%	0,85
W - S1 - S2 - S3 - S4 - REM	87,5%	0,81	89,1%	0,83

LI; WEN, 2014). Deve-se, outra vez, destacar que os subconjuntos aleatórios utilizados para treinamento e teste do classificador são obtidos de 39 sinais de EEG referentes a 20 sujeitos, diferentemente daquele conjunto utilizado em ZHU; LI; WEN (2014), referente a 8 sinais obtidos de 8 sujeitos.

4 CONCLUSÕES

Este estudo apresenta uma metodologia para classificação de 2, 3, 4, 5 e 6 estados de estágios de sono de acordo com as recomendações de Rechtschaffen e Kales. O método proposto, assim como os de outros trabalhos recentes, é baseado em um único canal de EEG. Além disso, canais auxiliares de EOG, EMG e ECG são, aqui, descartados. Métodos robustos que consideram apenas um canal de EEG para classificação do sono têm reduzido custo computacional e contam com dispositivos de aquisição mais baratos e simples de usar quando comparados com os multicanais. Uma das principais contribuições deste trabalho reside no fato de que um único conjunto de características do canal de EEG escolhido (Pz-Oz) é necessário, independentemente do número de classes avaliadas, diferentemente do que ocorre em outras soluções encontradas na literatura, onde características específicas são escolhidas para cada um dos cenários de classificação.

A metodologia proposta é composta de uma etapa de pré-processamento simples, extração de características e classificação. Na etapa de pré-processamento, o sinal de EEG é particionado em épocas de 30 segundos. Para tornar possível a correta construção e posterior avaliação do método, épocas inválidas – aquelas não classificadas pelos especialistas do banco de dados – são removidas. A extração de características é realizada primordialmente através da análise multirresolução em cinco níveis do sinal de EEG. A transformada *wavelet* discreta de Daubechies com dois momentos nulos é escolhida para esta tarefa. Uma vez que o sinal completo de EEG é subdividido em épocas apenas por convenção, contorna-se o problema de tratamento de bordas da transformada obtendo pontos exatos provenientes da época seguinte. Após a decomposição do sinal, informações são separadas em faixas de frequência próximas a de ritmos cerebrais relacionados ao sono (baixo-gama, beta, alfa, teta e delta). Então um conjunto de três atributos por nível é extraído: variância, curtose e assimetria. Tais atributos alimentam um classificador do tipo floresta aleatória – rápido, robusto a ruídos e livre de *overfitting* – que, em um primeiro momento é treinado. A técnica de *k-fold cross-validation* é utilizada com o objetivo de avaliar a robustez do método proposto.

Ao considerar todas as 106.377 épocas válidas do banco de dados público *Sleep EDF [Expanded]* avalia-se o desempenho do método proposto em um *cenário real*, onde os dados são naturalmente desbalanceados. Uma vez que a base de dados é aberta, é possível reproduzir todos os resultados aqui obtidos. Métricas de avaliação geral, como acurácia e coeficiente *kappa*,

e específicas por classe, como precisão e revocação, são calculadas e apresentadas em todos os cenários. Os valores para acurácia e coeficiente *kappa* obtidos neste estudo para as classificações de 2 a 6 estados de estágios de sono são, respectivamente, 97,3% e 0,94, 93,9% e 0,87, 92,3% e 0,84, 91,5% e 0,83 e 90,5% e 0,8. Em comparações com trabalhos no estado da arte, a metodologia proposta apresenta os melhores resultados em termos de acurácia para os casos de 3 a 6 classes. Ainda, o valor obtido para o coeficiente *kappa* indica que, segundo avaliação qualitativa de Landis e Koch, o método é *excelente*.

Como contribuição secundária, destaca-se a ampla pesquisa bibliográfica acerca de métodos computacionais para classificação de estágios de sono realizada aqui. Em especial atém-se aos estudos onde há a preocupação com as classificações de 2 a 6 estados de estágios de sono. A fim de comparar a metodologia aqui apresentada com as desses estudos, procura-se equiparar os cenários de análise, a fim de reduzir ao máximo distorções acerca dos dados. Ainda que considerando o mesmo número de épocas por classe e método de treino e teste utilizados nesses estudos, os resultados alcançados pelo método aqui proposto superam ou ao menos igualam-se àqueles obtidos nos respectivos trabalhos.

Outra contribuição é a avaliação de acurácia e tempo de treino e teste de outros 62 algoritmos de classificação presentes na ferramenta WEKA. Os resultados reportados para estes classificadores apontaram o algoritmo de florestas aleatórias como a melhor opção para a etapa de classificação da metodologia proposta. Apesar de outros estudos apontarem o algoritmo de floresta aleatória como a mais interessante dentre as opções do WEKA em problemas relacionados, estes não haviam sido evidenciado tais informações seja em formato de tabela ou gráfico.

5 TRABALHOS FUTUROS

Como trabalhos futuros, entende-se como imediato o estudo dos seguintes pontos:

- Estruturar a metodologia proposta para embarcação em tecnologias como arranjo de portas programáveis por ação de campo (FPGA) e/ou implementação de circuitos de aplicação específica (ASICs) (FLOYD, 2011) para aplicações em *home care*.
- Avaliar mais precisamente outros algoritmos de classificação, ou até mesmo investigar a proposta de um novo. Como pode-se observar no Apêndice B, algoritmos baseados em “conjuntos de subclassificadores”, como as florestas aleatórias, tiveram melhores resultados.
- Identificação de características de sinais de EEG, nos domínios de tempo, escala ou frequência, que melhor refletem o comportamento de S1 e REM, a fim de melhorar as métricas específicas por classe desses dois estágios de sono. Ainda, uma possibilidade é considerar metodologias completamente novas que se preocupem exclusivamente com a identificação dessas classes como endereçado por SU et al. (2015) e IMTIAZ; RODRIGUEZ-VILLEGAS (2014).
- Propor modificações na metodologia introduzida visando a identificação de outros eventos definidos em faixas de frequência como sonolência, epilepsia, arritmia cardíaca, etc. Também, investigar o potencial de implementação da metodologia proposta (ou modificada) para essas aplicações em tempo real.
- Considerar outros algoritmos para decomposição *wavelet* do sinal, como, por exemplo, o algoritmo *packet*. Este é capaz de prover melhor resolução em termos de frequência. Entretanto, a menos que se considere a base de Haar, há maior impacto das fronteiras do sinal em cada nível de decomposição.

REFERÊNCIAS

- ADRIAN, E. E.; MATTHEWS, B. H. C. The Berger rhythm: potential changes from the occipital lobes in man. **Brain**, [S.l.], p.355–385, 1934.
- AGARWAL, R.; GOTMAN, J. Computer-assisted sleep staging. **IEEE Trans. Biomed. Eng.**, [S.l.], v.48, n.12, p.1412–1423, 2001.
- ALPAYDIN, E. **Introduction to Machine Learning**. 2nd.ed. [S.l.]: The MIT Press, 2010.
- AMABIS, J. M.; MARTHO, G. R. **Fundamentos da Biologia Moderna**. 4.ed. [S.l.]: Mordena, 2006.
- ANDERER, P. et al. An E-Health Solution for Automatic Sleep Classification according to Rechtschaffen and Kales: validation study of the somnolyzer 24 x 7 utilizing the siesta database. **Neuropsychobiology**, [S.l.], v.51, p.115–133, 2005.
- ASADZADEH, M.; HASHEMI, E.; KOZAKEVICIUS, A. Efficiency of Combined Daubechies and Statistical Parameters Applied in Mammography. **Applied and Computational Mathematics: An International Journal**, [S.l.], v.12, n.3, p.289–305, 2013.
- FRAIWAN, L. AND KHASWANEH, N. AND LWEESY, K. Automatic Sleep Stage Scoring With Wavelet Packets Based On Single Eeg Recording. **Proceedings of the World Academy of Science, Engineering and Technology** [S.l.: s.n.], 2009. v.54, p.385–488.
- BAYER, F. M.; KOZAKEVICIUS, A. J. SPC-Threshold: uma proposta de limiarização para filtragem adaptativa de sinais. **Trends in Applied and Computational Mathematics**, [S.l.], v.12, n.2, p.112–132, 2010.
- BEAR, M. F.; CONNONRS, B. W.; PARIDISO, M. A. **Neuroscience: exploring the brain**. 4.ed. [S.l.]: Wolters Kluwer, 2015.
- BEN-DAVID, A. Comparison of classification accuracy using Cohen's Weighted Kappa. **Expert Systems with Applications**, [S.l.], v.34, n.2, p.825–832, Feb 2008.
- BERTHOMIER, C. et al. Automatic Analysis of Single-Channel Sleep EEG: validation in healthy individuals. **Sleep**, [S.l.], v.30, p.1587–1595, 2007.

- BREIMAN, L. Random Forests. **Machine Learning**, [S.l.], v.45, n.1, p.5–32, 2001.
- BRIGGS, W. L.; HENSON, V. E. **The DFT**: an owners' manual for the discrete fourier transform. [S.l.]: Society for Industrial and Applied Mathematics, 1995. (Miscellaneous Bks).
- CHAPOTOT, F.; BECQ, G. Automated sleep–wake staging combining robust feature extraction, artificial neural network classification, and flexible decision rules. **International Journal of Adaptive Control and Signal Processing**, [S.l.], v.24, n.5, p.409–423, 2010.
- CHARBONNIER, S. et al. Self-evaluated automatic classifier as a decision-support tool for sleep/wake staging. **Computers in Biology and Medicine**, [S.l.], v.41, n.6, p.380 – 389, 2011.
- COHEN, J. A coefficient of agreement for nominal scales. **Educational and Psychological Measurement**, [S.l.], v.20, p.37–46, 1960.
- COLE, R. J. et al. Automatic Sleep/Wake identification From Wrist Activity. **Sleep**, [S.l.], v.15, n.5, 1992.
- CORSI-CABRERA, M. et al. Power and coherent oscillations distinguish REM sleep, stage 1 and wakefulness. **International Journal of Psychophysiology**, [S.l.], v.60, n.1, p.59–66, 2006.
- DAUBECHIES, I. **Ten Lectures on Wavelets**. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 1992.
- DOROSHENKOV, L. G.; KONYSHEV, V. A.; SELISHCHEV, S. V. Classification of human sleep stages based on EEG processing using hidden Markov models. **Biomed Eng**, [S.l.], v.41, n.1, p.25–28, Jan 2007.
- EBRAHIMI, F. et al. Automated Sleep Stage Classification Based on EEG Signals by Using Neural Networks and Wavelet Packet. **30th Annual International IEEE EMBS Conference** [S.l.: s.n.], 2008. p.1151–1154.
- FLOYD, T. L. **Sistemas Digitais - Fundamentos e Aplicações**. [S.l.]: Bookman, 2011.
- FRAIWAN, L. et al. Classification of Sleep Stages Using Multi-wavelet Time Frequency Entropy and LDA. **Methods of Information in Medicine**, [S.l.], v.49, p.230–237, 2010.
- FRAIWAN, L. et al. Automated sleep stage identification system based on time-frequency analysis of a single EEG channel and random forest classifier. **Computer Methods and Programs in Biomedicine**, [S.l.], v.108, n.1, p.10–19, 2012.

- GOLDBERGER, A. L. et al. PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. **Circulation**, [S.l.], v.101, n.23, p.e215–e220, 2000.
- GRENANDER, U. The Nyquist frequency is that frequency whose period is two sampling intervals. In: PROBABILITY AND STATISTICS: THE HARALD CRAMÉR VOLUME. **Probability and statistics: the Harald Cramér volume** Almqvist & Wiksell, 1959.
- HALL, M. et al. The WEKA Data Mining Software: an update. **SIGKDD Explorations**, [S.l.], v.11, n.1, 2009.
- HAN, J.; KAMBER, M. **Data Mining**: concepts and techniques. 3.ed. [S.l.]: Morgan Kaufmann/Elsevier, 2012.
- HASTIE, T.; TIBSHIRANI, R.; FRIEDMAN, J. **The Elements of Statistical Learning**: data mining, inference, and prediction. 2.ed. [S.l.]: Springer, 2009.
- HSU, Y.-L. et al. Automatic sleep stage recurrent neural classifier using energy features of EEG signals. **Neurocomputing**, [S.l.], v.104, p.105–114, 2013.
- HUNTER, A. M. et al. Neurophysiologic Correlates of Side Effects in Normal Subjects Randomized to Venlafaxine or Placebo. **Neuropsychopharmacology**, [S.l.], v.30, p.792–799, 2005.
- IBER, C. et al. **The AASM Manual for the Scoring of Sleep and Associated Events**: rules, terminology and technical specifications. [S.l.]: American Academy of Sleep Medicine, 2007.
- IMTIAZ, S. A.; RODRIGUEZ-VILLEGAS, E. A Low Computational Cost Algorithm for REM Sleep Detection Using Single Channel EEG. **Ann Biomed Eng**, [S.l.], v.42, n.11, p.2344–2359, Aug 2014.
- JAP, B. T. et al. Using EEG spectral components to assess algorithms for detecting fatigue. **Expert Systems with Applications**, [S.l.], v.36, n.2, p.2352–2359, 2009.
- JIA, X.; KOHN, A. Gamma Rhythms in the Brain. **PLoS Biology**, [S.l.], v.9, n.4, p.1–4, 2011.
- KEMP, B. et al. A simple format for exchange of digitized polygraphic recordings. **Electroencephalography and Clinical Neurophysiology**, [S.l.], n.82, p.391–393, 1992.

KEMP, B.; JANSSEN, A. J. M. W.; ROESSEN, M. J. A digital telemetry system for ambulatory sleep recording. **Sleep-Wake Research in The Netherlands** 4, [S.l.], p.129–132, 1993. Dutch Society for Sleep Wake Research.

KEMP, B.; OLIVAN, J. European data format 'plus' (EDF+), an EDF alike standard format for the exchange of physiological data. **Clinical Neurophysiology**, [S.l.], v.114, n.9, p.1755–1761, 2003.

KHOSHGOFTAAR, T. M.; GOLAWALA, M.; HULSE, J. V. An Empirical Study of Learning from Imbalanced Data Using Random Forest. In: **19th IEEE International Conference On Tools With Artificial Intelligence, 2007. ICTAI 2007.** [S.l.: s.n.], 2007. v.2, p.310–317.

KIYMIK, M. K.; AKIN, M.; SUBASI, A. Automatic recognition of alertness level by using wavelet transform and artificial network. **Journal of Neuroscience Methods**, [S.l.], v.139, n.2, p.231–240, 2004.

KOLEY, B.; DEY, D. An ensemble system for automatic sleep stage classification using single channel EEG signal. **Computers in Biology and Medicine**, [S.l.], v.42, n.12, p.1186–1195, 2012.

KRAKOVSKÁ, A.; MEZEIOVÁ, K. Automatic sleep scoring: A search for an optimal combination of measures. **Artificial Intelligence in Medicine**, [S.l.], v.53, n.1, p.25–33, 2011.

KRYGER, M. H.; ROTH, T.; DEMENT, W. C. **Principles and Practice of Sleep Medicine.** 5.ed. [S.l.]: Elsevier Saunders, 2011.

LAIRD, A. R.; ROGERS, B. P.; MEYERAND, M. E. Comparison of Fourier and wavelet resampling methods. **Magnetic Resonance in Medicine**, [S.l.], v.51, n.2, p.418–422, 2004.

LAJNEF, T. et al. Learning machines and sleeping brains: automatic sleep stage classification using decision-tree multi-class support vector machines. **Journal of Neuroscience Methods**, [S.l.], v.250, p.94 – 105, 2015. Cutting-edge {EEG} Methods.

LANDIS, J. R.; KOCH, G. G. The measurement of observer agreement for categorical data. **Biometrics**, [S.l.], v.33, p.159–174, 1977.

LIANG, S. F. et al. Automatic Stage Scoring of Single-Channel Sleep EEG by Using Multiscale Entropy and Autoregressive Models. **IEEE Transactions on Instrumentation and Measurement**, [S.l.], v.61, p.1649–1657, 2012.

MALLAT, S. **A Wavelet Tour of Signal Processing:** the sparse way. 3.ed. [S.l.]: Academic Press, 2008.

MARTIN, W. et al. Pattern recognition of EEG-EOG as a technique for all-night sleep stage scoring. **Electroencephalography and Clinical Neurophysiology**, [S.l.], v.32, p.417–427, 1972.

MOSER, D. et al. Sleep classification according to AASM and Rechtschaffen & Kales: effects on sleep scoring parameters. **Sleep**, [S.l.], v.32, n.2, 2009.

MOURTAZAEV, M. S. et al. Age and gender affect different characteristics of slow waves in the sleep EEG. **Sleep**, [S.l.], v.18, n.7, p.557–564, 1995.

NATIONAL INSTITUTES OF HEALTH. **Sleep, Sleep Disorders, and Biological Rhythms.** [S.l.]: Biological Sciences Curriculum Study, 2003.

NIELSEN, O. M. **Wavelets in Scientific Computing.** 1998. Tese de Doutorado — Technical University of Denmark.

NOOR, Z. M. et al. A study protocol: a community pharmacy-based intervention for improving the management of sleep disorders in the community settings. **BMC Health Services Research**, [S.l.], v.14, n.1, p.74, 2014.

OSHIRO, T. M.; PEREZ, P. S.; BARANAUSKAS, J. A. How Many Trees in a Random Forest? In: PERNER, P. (Ed.). **Machine Learning and Data Mining in Pattern Recognition.** [S.l.]: Springer Berlin Heidelberg, 2012. p.154–168. (Lecture Notes in Computer Science, v.7376).

PANDI-PERUMAL, S. R. et al. Sleep disorders, sleepiness and traffic safety: a public health menace. **Brazilian Journal of Medical and Biological Research**, [S.l.], v.39, p.863–871, 2006.

PENZEL, T. et al. The SIESTA database and the SIESTA sleep analyzer. In: **Engineering In Medicine And Biology Society, Embs, 2011 Annual International Conference Of The IEEE.** [S.l.: s.n.], 2011. p.8323–8326.

PFEIL, T. **Exploring the potential of brain-inspired computing.** 2015. Tese de Doutorado — Ruperto-Carola University of Heidelberg.

PHYSIONET. **The Sleep-EDF-X Database.** Online; Accessed on May 12th 2015, <http://www.physionet.org/physiobank/database/sleep-edfx>.

PHYSIONET. The Sleep-EDF Database. Online; Accessed on May 12th 2015, <http://www.physionet.org/physiobank/database/sleep-edf>.

PRESS, W. H. et al. **Numerical Recipes in C**: the art of scientific programming. Second Edition.ed. [S.l.]: Cambridge University Press, 1992.

PUTNAM, W.; SMITH, J. Design of fractional delay filters using convex optimization. **Workshop On Applications Of Signal Processing To Audio And Acoustics IEEE ASSP**. [S.l.: s.n.], 1997.

RADHA, M. et al. Comparison of feature and classifier algorithms for online automatic sleep staging based on a single EEG signal. **2014 36th Annual International Conference of the IEEE Engineering in Medicine and Biology Society**, [S.l.], Aug 2014.

RAO, R. P. N. **Brain Computer Interface - An Introduction**. 1.ed. [S.l.]: Cambridge University Press, 2013.

RAY, S. R. et al. Computer Sleep Stage Scoring - An Expert System Approach. **International Journal of Bio-Medical Computing**, [S.l.], v.16, p.43–61, 1986.

RECHTSCHAFFEN, A.; KALES, A. A manual of standardized terminology, techniques and scoring system for sleep stages of human subjects. **Electroencephalography and Clinical Neurophysiology**, [S.l.], v.26, n.6, p.644, 1969.

RONZHINA, M. et al. Sleep scoring using artificial neural networks. **Sleep Medicine Reviews**, [S.l.], v.16, p.251–263, 2012.

SANO, A.; PICARD, R. W. Comparison of sleep-wake classification using electroencephalogram and wrist-worn multi-modal sensor data. **Engineering In Medicine And Biology Society (EMBC), 2014 36th Annual International Conference Of The IEEE**. [S.l.: s.n.], 2014. p.930–933.

SCHOMER, D. L.; SILVA, F. H. L. da. **Niedermeyer's Electroencephalography**. 6.ed. [S.l.]: Lippincott, Williams & Wilkins, 2010.

ŞEN, B. et al. A Comparative Study on Classification of Sleep Stage Based on EEG Signals Using Feature Selection and Classification Algorithms. **Journal of Medical Systems**, [S.l.], v.38, n.3, Mar 2014.

SILVEIRA, T. da. **Detecção do Estado de Sonolência Via um Único Canal de Eletroencefalografia Através da Transformada Wavelet Discreta.** 2012. Dissertação de Mestrado — Universidade Federal de Santa Maria.

SILVEIRA, T. L. T. da; KOZAKEVICIUS, A. J.; RODRIGUES, C. R. Awake/Sleep Scoring Through Wavelet Analysis Associated to Decision Tree Algorithms. **XXX Simpósio Sul De Microeletrônica.** [S.l.: s.n.], 2015.

SILVEIRA, T. L. T. da; RODRIGUES, C. R.; KOZAKEVICIUS, A. J. Técnicas de Reamostragem de Sinais e seus Impactos no Processamento Digital nos Domínios do Tempo e da Frequência. **Primer Encuentro de Jóvenes Investigadores en Matemática Aplicada de la Asociación de Universidades Grupo Montevideo (AUGM)** [S.l.: s.n.], 2014. p.39–40.

STOLLNITZ, E. J.; DEROSE, T. D.; SALESIN, D. H. Wavelets for Computer Graphics: A primer - part 1. **IEEE Computer Graphics and Applications**, [S.l.], v.15, p.76–84, 1995.

STRANNEBY, D. **Digital Signal Processing and Applications.** 2.ed. [S.l.]: Newnes, 2004.

SU, B.-L. et al. Detecting slow wave sleep using a single EEG signal channel. **Journal of Neuroscience Methods**, [S.l.], v.243, p.47–52, Mar 2015.

SUBASI, A. Automatic recognition of alertness level from EEG by using neural network and wavelet coefficients. **Experts Systems with Applications**, [S.l.], v.28, n.4, p.701–711, 2005.

SUBASI, A. EEG signal classification using wavelet feature extraction and a mixture of expert model. **Expert Systems with Applications**, [S.l.], v.32, n.4, p.1084–1093, May 2007.

SWEDEN, B. van et al. Alternative electrode placement in (automatic) sleep scoring (Fpz-Cz/Pz-Oz versus C4-A1). **Sleep**, [S.l.], v.13, n.3, p.279 – 283, June 1990.

TEPLAN, M. Fundamentals of EEG Measurement. **Measurement Science Review** [S.l.: s.n.], 2002. p.1–11.

VIDAKOVIC, B.; MUELLER, P. **Wavelets for kids:** A tutorial introduction. [S.l.]: Duke University, 1991.

VIERA, A. J.; GARRETT, J. M. Understanding interobserver agreement: the kappa statistic. **Family Medicine**, [S.l.], v.37, n.5, p.360–363, 2005.

WHO. **WHO technical meeting on sleep and health.** [S.l.]: World Health Organization European Centre for Environment and Health, 2004.

WITTEN, I. H.; FRANK, E.; HALL, M. A. **Data Mining:** practical machine learning tools and techniques. 3.ed. [S.l.]: Morgan Kaufmann/Elsevier, 2011.

ZHU, G.; LI, Y.; WEN, P. Analysis and Classification of Sleep Stages Based on Difference Visibility Graphs from a Single-Channel EEG Signal. **IEEE Journal of Biomedical and Health Informatics**, [S.l.], v.18, n.6, p.1813–1821, 2014.

APÊNDICES

APÊNDICE A – TRABALHO APRESENTADO NO PRIMER ENCUENTRO DE JÓVENES INVESTIGADORES EN MATEMÁTICA APLICADA DE LA AUGM

Técnicas de Reamostragem de Sinais e seus Impactos no Processamento Digital nos Domínios do Tempo e da Frequência

Thiago L. T. da Silveira^{1*}, Cesar R. Rodrigues² e Alice J. Kozakevicius³

Universidade Federal de Santa Maria

¹Programa de Pós-Graduação em Informática

²Departamento de Eletrônica e Computação, ³Departamento de Matemática e LANA

E-mail: thiago@inf.ufsm.br, cesar@ieee.org e alice@ufsm.br

RESUMO

O processamento digital de sinais (DSP) permite que dados discretos, oriundos das mais diversas aplicações, possam ser analisados e manipulados de maneira digital [5]. Há duas principais formas de DSP: as no domínio do tempo e as no domínio da frequência [5]. Contudo, nem sempre apenas a simples conversão analógico-digital permite a utilização imediata de certas ferramentas. Por exemplo, para a aplicação de transformadas discretas *wavelet* (DWT) [2] ou aproximadas do cosseno (DCT) [1], o sinal (vetor de entrada) deve ter comprimento dado em potência de dois, ou seja, 2^N pontos. Além disso, a taxa de amostragem utilizada na aquisição do sinal pode não coincidir com a taxa de amostragem projetada para ser considerada no aplicativo. Nestes casos, são necessárias técnicas de reamostragem de sinais para que os dados possam ser transferidos de uma malha de referência para outra, como feito em compressão de áudio [4].

Apesar da reamostragem ser uma opção viável, podem ocorrer tanto perda quanto inserção de informações indesejadas no sinal original. Para se obter resultados acurados, é importante que os dados reamostrados possuam propriedades estatísticas semelhantes às do sinal original [3]. O presente estudo avalia a aplicação de três abordagens para reamostragem de um sinal digital 1D. A primeira utiliza sucessivas aplicações da TWD inversa Db2 [2] para interpolar e, posteriormente, fornecer uma versão do sinal original na malha correspondente a uma nova taxa de amostragem. Outra abordagem, presente no pacote `scipy.signal.resample` do Python, utiliza uma técnica baseada na transformada de Fourier para reamostragem [3]. O terceiro método avaliado está presente no pacote `scikits.samplerate.resample` do Python e é baseado no trabalho de Putnam & Smith [4].

Resultados mostram que apesar das técnicas analisadas terem bom desempenho para sinais periódicos, isso não acontece quando não se tem essa hipótese. Em processamentos no domínio das frequências, o método de Fourier apresenta os melhores resultados, enquanto que para processamentos no domínio temporal, o método baseado em *wavelet* mostra-se como a melhor opção em relação à proximidade do sinal reamostrado com o sinal original. Dessa forma, sugere-se que haja uma fase preliminar de escolha da técnica de reamostragem de acordo com o tipo de processamento ao qual o sinal será submetido.

Palavras-chave: *Reamostragem, Sinais digitais, Processamento de sinais*

Referências

- [1] T. L. T. DA SILVEIRA, *Aproximações da DCT de comprimento 16 com baixa complexidade aritmética para compressão de imagens*, 2013. Trabalho de Graduação, Universidade Federal de Santa Maria.
- [2] A. KOZAKEVICIUS AND A. A. SCHIMDT, *Wavelet transform with special boundary treatment for 1d data*, Computational and Applied Mathematics, 32 (2013), pp. 447–457.
- [3] A. R. LAIRD, B. P. ROGERS, AND M. E. MEYERAND, *Comparison of fourier and wavelet resampling methods*, Magnetic Resonance in Medicine, 51 (2004), pp. 418–422.
- [4] W. PUTNAM AND J. SMITH, *Design of fractional delay filters using convex optimization*, in Workshop on Applications of Signal Processing to Audio and Acoustics IEEE ASSP, Oct 1997.
- [5] D. STRANNEBY, *Digital Signal Processing and Applications*, Newnes, 2 ed., 2004.

*Bolsista de Mestrado Capes.

APÊNDICE B – DESEMPENHO DE ALGORITMOS DE CLASSIFICAÇÃO DA FERRAMENTA WEKA

Alguns algoritmos de classificação do WEKA não puderam ser avaliados devido (i) à incopatibilidade de dados ou (ii) à falta de arquivos não-padrão do WEKA. São eles: ADTree, AODE, AODEsr, AdditiveRegression, BayesianLogisticRegression, CitationKNN, ComplementNaiveBayes, CostSensitiveClassifier, GaussianProcesses, GridSearch, HNB, Id3, Iso-tonicRegression, LBR, LeastMedSq, LibLINEAR, LinearRegression, M5P, M5Rules, MDD, MIBoost, MIDD, MIEMDD, MILR, MINND, MIOptimalBall, MISMO, MISVM, MIWrapper, MetaCost, NaiveBayesMultinomial, NaiveBayesMultinomialUpdateable, NaiveBayesUpdateable, PLSClassifier, PaceRegression, Prism, RegressionByDiscretization, SMOreg, SPegasos, SerializedClassifier, SimpleLinearRegression, SimpleMI, ThresholdSelector, VotedPerceptron, WAODE e Winnow.

Os demais algoritmos foram avaliados utilizando parâmetros padrão e, respectivamente, 66% e 33% das 106.377 instâncias para treino e teste. A acurácia (ver Equação 3.1) e o tempo gasto para construção e teste do modelo foram obtidos em cada um dos cenários de classificação (2 a 6 classes) e são apresentados na Tabela B.1. As execuções foram feitas em um computador pessoal com memória RAM de 8Gb, Core i7 com quatro núcleos operando a 2GHz. Uma vez que os experimentos não foram repetidos, impossibilitando obter um tempo médio, como em uma simulação de Monte Carlo, opta-se por apresentar essas informações em faixas de tempo. Algoritmos de classificação que demoraram mais do que 12h (MDH) foram cancelados e não foram avaliados (NA).

Tabela B.1: Acurácia (%) e tempos (s) de treino e teste dos algoritmos avaliados nas classificações de 2 a 6 estados de sono.

Identificador do algoritmo	W - S1 - S2 - S3 - S4 - REM			W - S1 - S2 - SWS - REM			W - S1/S2 - SWS - REM			W - NREM - REM			W - SLP			
	Acurácia (%)	Treino (s)	Teste (s)	Acurácia (%)	Treino (s)	Teste (s)	Acurácia (%)	Treino (s)	Teste (s)	Acurácia (%)	Treino (s)	Teste (s)	Acurácia (%)	Treino (s)	Teste (s)	
AdaBoostM1	75,23	10 ⁻²	1-10	75,23	10 ⁻²	1-10	77,30	10 ⁻²	1-10	82,19	10 ⁻²	1-10	92,11	10 ⁻²	1-10	
AttributeSelectedClassifier	84,72	10 ⁻²	10 ⁻²	85,95	10 ⁻²	10 ⁻²	86,82	10 ⁻²	10 ⁻²	89,34	10 ⁻²	10 ⁻²	89,53	10 ⁻²	1-10	
Bagging	89,43	10 ² -10 ³	10 ² -10 ²	90,61	10 ²	10 ²	91,34	10 ²	10 ²	92,89	10 ²	10 ²	97,00	10 ²	10 ²	
BayesNet	78,73	10 ⁻²	10 ⁻²	79,96	1-10	1-10	81,35	1-10	1-10	83,61	1-10	1-10	90,86	1-10	1-10	
BTTree	86,23	10 ² -10 ³	10 ² -10 ³	87,68	10 ² -10 ³	10 ² -10 ³	88,72	10 ² -10 ³	10 ² -10 ³	90,32	10 ² -10 ³	10 ² -10 ²	96,01	10 ² -10 ³	10 ² -10 ²	
ClassificationViaClustering	64,94	10 ⁻²	10 ⁻²	64,94	10 ⁻²	10 ⁻²	65,33	10 ⁻²	10 ⁻²	65,48	10 ⁻²	10 ⁻²	66,02	10 ⁻²	10 ⁻²	
ClassificationViaRegression	89,14	10 ² -10 ³	10 ² -10 ³	90,32	10 ²	10 ²	91,02	10 ²	10 ²	92,94	10 ²	10 ²	96,62	10 ²	10 ²	
ConjunctiveRule	75,55	10 ³ -10 ⁴	10 ² -10 ³	75,54	10 ² -10 ³	10 ² -10 ³	77,77	10 ² -10 ³	10 ² -10 ³	82,81	10 ² -10 ³	10 ² -10 ³	89,73	10 ² -10 ³	10 ² -10 ³	
CVParameterSelection	67,79	0-1	10 ⁻²	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	
Dagging	68,71	10 ² -10 ³	10 ² -10 ³	68,81	10 ⁻²	10 ⁻²	70,03	10 ⁻²	10 ⁻²	75,95	10 ⁻²	10 ⁻²	81,03	1-10	1-10	
DecisionStump	75,23	1-10	1-10	75,23	1-10	1-10	77,30	1-10	1-10	82,19	1-10	1-10	88,83	0-1	1-10	
DecisionTable	85,74	10 ² -10 ³	10 ² -10 ³	86,23	10 ² -10 ³	10 ² -10 ³	87,31	10 ² -10 ³	10 ² -10 ³	90,16	10 ² -10 ³	10 ² -10 ³	94,79	10 ² -10 ³	10 ² -10 ²	
Decorate	88,93	10 ⁴ -10 ⁵	10 ⁴ -10 ⁵	90,46	10 ³ -10 ⁴	10 ³ -10 ⁴	91,57	10 ³ -10 ⁴	10 ³ -10 ⁴	93,27	10 ³ -10 ⁴	10 ³ -10 ⁴	95,94	10 ³ -10 ⁴	10 ³ -10 ⁴	
DMNBtext	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	
DTNB	83,24	10 ³ -10 ⁴	10 ³ -10 ⁴	84,21	10 ³ -10 ⁴	10 ³ -10 ⁴	85,26	10 ³ -10 ⁴	10 ³ -10 ⁴	88,28	10 ³ -10 ⁴	10 ³ -10 ⁴	93,79	10 ³ -10 ⁴	10 ² -10 ³	
END	89,42	10 ³ -10 ⁴	10 ² -10 ³	90,51	10 ² -10 ³	10 ² -10 ³	90,92	10 ² -10 ³	10 ² -10 ³	92,17	10 ² -10 ³	10 ² -10 ³	96,33	10 ²	10 ²	
FilteredClassifier	86,90	10 ⁻²	10 ⁻²	87,72	1-10	1-10	88,77	1-10	1-10	91,00	1-10	1-10	95,95	1-10	1-10	
FT	87,80	10 ² -10 ³	10 ² -10 ³	89,10	10 ² -10 ³	10 ² -10 ³	90,32	10 ² -10 ³	10 ² -10 ³	92,02	10 ² -10 ³	10 ² -10 ³	96,51	10 ² -10 ²	10 ² -10 ²	
Grading	67,79	1-10	1-10	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	
HyperPipes	67,92	0-1	1-10	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	
IB1	73,44	0-1	10 ³ -10 ⁴	74,81	0-1	10 ³ -10 ⁴	76,06	0-1	10 ³ -10 ⁴	78,69	0-1	10 ³ -10 ⁴	83,70	0-1	10 ³ -10 ⁴	
IBk	73,44	0-1	10 ³ -10 ⁴	74,81	0-1	10 ³ -10 ⁴	76,06	0-1	10 ³ -10 ⁴	78,69	0-1	10 ³ -10 ⁴	83,70	0-1	10 ³ -10 ⁴	
J48	86,55	10 ⁻²	10 ⁻²	87,75	10 ⁻²	10 ⁻²	89,23	10 ⁻²	10 ⁻²	91,31	10 ⁻²	10 ⁻²	96,33	10 ⁻²	10 ⁻²	
J48graft	87,34	10 ² -10 ³	10 ² -10 ²	88,46	10 ² -10 ³	10 ² -10 ²	89,61	10 ² -10 ³	10 ² -10 ²	91,70	10 ² -10 ²	10 ² -10 ²	96,48	10 ²	10 ²	
JRip	86,69	10 ³ -10 ⁴	10 ³ -10 ⁴	87,70	10 ³ -10 ⁴	10 ³ -10 ⁴	89,31	10 ³ -10 ⁴	10 ³ -10 ⁴	90,68	10 ³ -10 ⁴	10 ³ -10 ⁴	96,20	10 ² -10 ³	10 ² -10 ³	
Kstar	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	
LADTree	83,45	10 ² -10 ³	10 ² -10 ³	85,34	10 ² -10 ³	10 ¹⁰	86,68	10 ² -10 ³	10 ¹⁰	89,02	10 ² -10 ³	10 ¹⁰	94,65	10 ² -10 ³	10 ² -10 ²	
LibSVM	NA	MDH	NA	NA	MDH	NA	NA	MDH	NA	NA	MDH	NA	NA	67,81	10 ² -10 ³	10 ⁴ -10 ⁵
LMT	88,93	10 ⁴ -10 ⁵	10 ⁴ -10 ⁵	90,20	10 ⁴ -10 ⁵	10 ³ -10 ⁴	90,75	10 ⁴ -10 ⁵	10 ³ -10 ⁴	92,45	10 ⁴ -10 ⁵	10 ³ -10 ⁴	96,54	10 ³ -10 ⁴	10 ³ -10 ⁴	
Logistic	80,52	10 ² -10 ³	10 ² -10 ³	81,89	10 ⁻²	10 ⁻²	82,57	10 ⁻²	10 ⁻²	83,90	10 ⁻²	10 ⁻²	89,23	10 ⁻²	1-10	
LogitBoost	85,28	10 ² -10 ³	10 ² -10 ³	86,29	10 ² -10 ²	10 ² -10 ²	87,05	10 ² -10 ²	10 ² -10 ²	89,03	10 ² -10 ²	10 ² -10 ²	91,81	10 ² -10 ²	10 ² -10 ²	
IWL	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	NA	0-1	MDH	NA
MultiBoostAB	75,23	10 ⁻²	10 ⁻²	75,23	10 ⁻²	10 ⁻²	77,30	10 ⁻²	10 ⁻²	82,19	10 ⁻²	10 ⁻²	88,85	10 ⁻²	10 ⁻²	
MulticlassClassifier	78,98	10 ² -10 ³	10 ² -10 ³	80,85	10 ⁻²	10 ⁻²	81,68	10 ⁻²	10 ⁻²	83,62	10 ⁻²	10 ⁻²	89,22	10 ⁻²	1-10	
MultilayerPerceptron	86,07	10 ³ -10 ⁴	10 ³ -10 ⁴	87,38	10 ³ -10 ⁴	10 ² -10 ³	88,12	10 ² -10 ³	10 ² -10 ³	89,54	10 ² -10 ³	10 ² -10 ³	93,77	10 ² -10 ³	10 ² -10 ³	
MultiScheme	67,79	1-10	1-10	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	
NaiveBayes	37,46	1-10	10 ⁻²	40,77	0-1	1-10	42,50	1-10	1-10	49,46	0-1	1-10	61,54	1-10	1-10	

* Continua na próxima página

Tabela B.1: Acurácia (%) e tempos (s) de treino e teste dos algoritmos avaliados nas classificações de 2 a 6 estados de sono.

Identificador do algoritmo	W - S1 - S2 - S3 - S4 - REM			W - S1 - S2 - SWS - REM			W - S1/S2 - SWS - REM			W - NREM - REM			W - SLP		
	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	Acurácia (%) Treino (s)	
NaiveBayes	37,46	1-10	10 ⁻¹⁰ ²	40,77	0-1	1-10	42,50	1-10	1-10	49,46	0-1	1-10	61,54	1-10	1-10
NaiveBayesSimple	37,54	0-1	1-10	40,84	0-1	1-10	42,57	0-1	0-1	49,54	0-1	0-1	61,59	0-1	0-1
NaiveBayesUpdateable	37,47	1-10	10 ⁻¹⁰ ²	40,77	0-1	1-10	42,50	0-1	0-1	49,46	0-1	0-1	61,54	0-1	0-1
NBTree	88,19	10 ² -10 ³	10 ² -10 ³	89,06	10 ² -10 ³	10 ² -10 ³	89,85	10 ² -10 ³	10 ² -10 ³	91,89	10 ² -10 ³	10 ² -10 ³	95,56	10 ² -10 ³	10 ² -10 ³
NNge	NA	10 ³ -10 ⁴	MDH	NA	10 ³ -10 ⁴	MDH	NA	10 ³ -10 ⁴	MDH	NA	10 ³ -10 ⁴	MDH	NA	10 ³ -10 ⁴	MDH
OneR	75,19	1-10	1-10	75,06	1-10	0-1	76,67	1-10	0-1	81,34	1-10	0-1	88,07	1-10	0-1
OrdinalClassClassifier	85,52	10 ² -10 ³	10 ² -10 ³	87,22	10 ² -10 ²	10 ² -10 ²	88,45	10 ² -10 ²	10 ² -10 ²	91,56	10 ² -10 ²	10 ² -10 ²	96,33	10 ² -10 ²	10 ² -10 ²
PART	87,03	10 ³ -10 ⁴	10 ³ -10 ⁴	88,46	10 ² -10 ³	10 ² -10 ³	89,62	10 ² -10 ³	10 ² -10 ³	91,97	10 ² -10 ³	10 ² -10 ²	96,42	10 ² -10 ²	10 ² -10 ²
RacedIncrementalLogitBoost	84,66	10-10 ²	10-10 ²	86,29	1-10	1-10	88,53	1-10	1-10	90,53	1-10	1-10	95,06	1-10	1-10
RandomCommittee	88,56	10 ² -10 ³	10 ² -10 ³	90,87	10 ² -10 ²	10 ² -10 ²	91,57	10 ² -10 ²	10 ² -10 ²	92,42	10 ² -10 ²	10 ² -10 ²	97,09	10 ² -10 ²	10 ² -10 ²
RandomForest	89,55	10-10 ²	10-10 ²	90,95	10-10 ²	10-10 ²	91,80	10-10 ²	10-10 ²	92,99	10-10 ²	10-10 ²	97,12	10-10 ²	10-10 ²
RandomSubSpace	87,47	10 ² -10 ³	10 ² -10 ³	88,67	10-10 ²	10-10 ²	88,73	10-10 ²	10-10 ²	91,67	10-10 ²	10-10 ²	96,64	10-10 ²	10-10 ²
RandomTree	84,86	1-10	10-10 ²	86,20	1-10	1-10	87,62	1-10	1-10	89,80	1-10	1-10	95,25	1-10	1-10
RBFNetwork	73,65	10 ² -10 ³	10 ² -10 ³	74,21	10-10 ²	10-10 ²	74,38	10-10 ²	10-10 ²	74,94	10-10 ²	10-10 ²	77,95	10-10 ²	10-10 ²
REPTree	88,18	10-10 ²	1-10	89,15	10-10 ²	1-10	89,78	10-10 ²	1-10	91,98	10-10 ²	1-10	96,47	1-10	1-10
Ridor	86,15	10 ³ -10 ⁴	10 ³ -10 ⁴	88,21	10 ² -10 ³	10 ² -10 ³	88,95	10 ² -10 ³	10 ² -10 ³	91,40	10 ² -10 ³	10 ² -10 ²	95,24	10 ² -10 ³	10 ² -10 ²
RotationForest	88,77	10 ³ -10 ⁴	10 ³ -10 ⁴	89,66	10 ² -10 ³	10 ² -10 ³	90,49	10 ² -10 ³	10 ² -10 ³	92,12	10 ² -10 ³	10 ² -10 ³	95,45	10 ² -10 ³	10 ² -10 ³
SimpleCART	88,11	10 ² -10 ³	10 ² -10 ³	89,41	10 ² -10 ³	10 ² -10 ³	89,99	10 ² -10 ³	10 ² -10 ³	91,90	10 ² -10 ³	10 ² -10 ³	96,58	10 ² -10 ²	10 ² -10 ²
SimpleLogistic	80,50	10 ³ -10 ⁴	10 ³ -10 ⁴	81,85	10 ³ -10 ⁴	10 ³ -10 ⁴	82,54	10 ³ -10 ⁴	10 ² -10 ³	83,87	10 ³ -10 ⁴	10 ² -10 ³	89,15	10 ² -10 ³	10 ² -10 ³
SMO	71,43	10 ² -10 ³	10 ² -10 ³	79,96	10 ² -10 ³	10 ² -10 ²	72,99	10-10 ²	10-10 ²	79,33	10-10 ²	10-10 ²	86,04	1-10	1-10
Stacking	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1
StackingC	67,79	10-10 ²	10-10 ²	67,79	0-1	1-10	67,79	0-1	1-10	67,79	0-1	1-10	67,79	0-1	1-10
UserClassifier	67,79	10-10 ²	1-10	67,79	1-10	1-10	67,79	1-10	1-10	67,79	1-10	1-10	67,79	1-10	1-10
VFI	43,58	1-10	1-10	32,94	0-1	0-1	34,37	0-1	0-1	14,25	0-1	0-1	36,16	0-1	0-1
Vote	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1
ZeroR	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1	67,79	0-1	0-1

APÊNDICE C – TRABALHO APRESENTADO NO XXX SIMPÓSIO SUL DE MICROELETROÔNICA

Awake/Sleep Scoring Through Wavelet Analysis Associated to Decision Tree Algorithms

Thiago L. T. da Silveira
Masters' Student in Computer Science (PPGI) and
Undergraduate Student in Information Systems
Universidade Federal de Santa Maria (UFSM)
Santa Maria, Brazil
Email: thiago@inf.ufsm.br

Alice J. Kozakevicius¹ and Cesar R. Rodrigues²
¹Department of Mathematics and LANA and
²Department of Electronics and Computing
Universidade Federal de Santa Maria (UFSM)
Santa Maria, Brazil

Abstract—Sleep deprivation is a public health problem which must be carefully examined and treated. Several studies have proposed automatic methods aiming to identify when a person falls asleep. The identification of the sleep state can help sleep experts to diagnose and prevent certain disorders such as apnea and insomnia. In the current work, the discrete wavelet transform is employed in order to analyze signals from a single electroencephalogram channel. Statistical features are then extracted from the wavelet coefficients, representing the characteristics of specific frequency ranges of the signal. Afterwards, these features are carried out to the classification procedure. Three classical decision tree algorithms are considered aiming to assess the extracted features' robustness. Results yielding more than 95% of accuracy are achieved in two of the three analyzed classifiers.

Keywords—Awake/Sleep stages scoring; discrete wavelet transform (DWT); electroencephalogram (EEG); decision tree algorithms.

I. INTRODUCTION

The comprehension of the human sleep can help doctors to diagnose and avert sleep-related disorders such as apnea, narcolepsy and insomnia [1]. Several researches, as [2], [3], have proposed automatic methods to distinguish when a subject is awake or sleeping based on simple wearable devices, reducing therefore health care costs [3]. Cole *et al.* [2] and Tilmanne *et al.* [4] have proposed an awake/sleep scoring method based on actigraph signals, respiration effort and accelerometer signals. In this context, an introductory study is presented here, investigating analysis and classification algorithms, which, in the future, will be embedded in integrated systems for processing electroencephalogram (EEG) signals. However, at the initial development phase, the execution of these algorithms is made in conventional desktop computers over single channel EEG signals from a public polysomnograph (PSG) database.

Since 1983, the distinction of sleep and awake stages through physiological signals is the goal of several researches. In van Luijtelaar and Coenen [5] study, which method's input are the non-invasive EEG and electromyogram (EMG) signals, 93.6% of accuracy is achieved in experiments with rats. Tilmanne *et al.* [4] have employed their methodology in an infant polysomnograph database, reaching around 86.9% of accuracy when considering a healthy group of infants. Cole *et al.* [2] and Karlen & Floreano [3] methods achieved, respectively, 91.9% and $90.4 \pm 3.6\%$ of accuracy also consider-

ing healthy subjects. In the current work, signals from healthy patients, aged between 25 and 34, of a public polysomnography database – Physionet Sleep EDF [Expanded] [6] – are considered.

Independently of the used polysomnograph or actigraph signals, in order to be analyzed, they must be divided into small time intervals called epochs. According to both standards for sleep classification - the Rechtschaffen's and Kales' (R&K) recommendations [7] and the American Academy of Sleep Medicine [8] - the length of these epochs is often 20 or 30 seconds. Here, 30-second epochs are adopted. Different techniques to analyze and to extract features of these epochs as well as different classification algorithms can be found in literature. The current study identifies the sleep and awake stages through wavelet analysis of signals from a single EEG channel; other EEG channels as well as electrooculogram (EOG), electrocardiogram (ECG) and EMG signals are discarded. Afterwards the wavelet analysis, three statistical features are applied to the coefficients, generating distinct magnitudes for awake and sleep stages. The robustness of the chosen features is assessed though three decision tree classifiers: random tree, reduced error pruning (REP) tree and classification and regression tree (CART) [9]. The main contribution of this study is to provide a methodology based on a single EEG channel and reduced feature set allied to the usage of low computational cost decision tree algorithms.

The remaining of this work is organized as follows: Section II presents the proposed methodology. The data description and preprocessing procedure are presented in Section II-A. Section II-B briefly describes the chosen discrete wavelet transform and also explains the feature extraction. The results are pointed out and discussed in Section III. Finally, the conclusions are drawn in Section IV.

II. PROPOSED METHODOLOGY

The proposed methodology is described in detail in the following subsections.

A. Data description and preprocessing

The experimental data considered in this work was obtained from the Physionet Sleep EDF [Expanded] public database [6]. This database offers recordings from two EEG channel – the Fpz-Cz and Pz-Oz – sampled at 100Hz besides EOG and EMG

signals of Caucasian volunteers. Here, only the Pz-Oz EEG channel is used. Signals from all healthy subjects without any sleep-related medication were selected in this study. The total quantity of recordings is 106,376 30-second epochs (about 886.5 hours). In order to balance the data, a subsample of the complete set of epochs was obtained. This subset contains 34,023 epochs in the awake stage and the same quantity of epochs in the sleep stage (which comprises the different patterns of sleep stages S1, S2, S3 and S4 besides rapid eye movement (REM) stage according to the R&K recommendations). Expert's scores, i.e. hypnogram annotations, for each 30-second time segment are jointly provided in the database. These annotations are considered as a correct reference and are used to train and test the decision tree algorithms.

B. Discrete wavelet transform and feature extraction

Over each epoch, a four-level Daubechies 2 (Db2) discrete wavelet transform (DWT) [10] is applied in order to separate the signal components approximately into specific cerebral rhythms. The wavelet transform has good representativity in both time and scale domains [10] unlike Fourier transform which temporal mark is easily lost. Furthermore, the wavelets can efficiently analyze non-stationary signals – as the EEG ones – and allow to extract different statistical properties of them [11].

Since the signals of interest were sampled at 100Hz, it is possible to decompose them, using a Db2 wavelet, as follows: the first wavelet coefficient set contains the signal's information relative to 25-50Hz which is close to the low-gamma rhythm (30-50Hz). The second wavelet coefficient set has the 12.5-25Hz frequency range which contains relevant information about the beta rhythm (13-30Hz). The third and fourth wavelet coefficient sets have, respectively, informations about data in 6.25-12.5Hz and 3.125-6.25Hz. The main associated rhythms to these sets are, respectively, the alpha (4-13Hz) and theta (0.5-4Hz). Fig. 1 illustrates the 4-level wavelet decomposition scheme and the main rhythm associated with each wavelet coefficient set.

The knowledge of the signal's behavior in each one of these specific bands, thanks to the wavelet analysis, allows to extract particular characteristics of it, assisting the chosen classifier to accurately recognize the awake and sleep stages. The low-gamma rhythm is associated to activities in the awake stage such as attention [12]. Beta rhythm occurs more intensely in the awake stage [13]. In the transitions from the wakefulness to resting conditions, alpha gradually decreases and theta increases [11].

In order to emphasize these differences, besides reducing the data dimensionality, the standard deviation, skewness and kurtosis are extracted from each one of the wavelet coefficient sets of interest. Statistical measurements have already been successfully used to analyze physiological signals as performed in [14], [15] and commented in [16]. Fig. 2 shows the differences in magnitude of the selected features in each decomposition level. It is possible to notice the sensitivity of specific features per level around the moments in which the subject wakes up. For better visualization, skewness and kurtosis were multiplied by a factor 2.

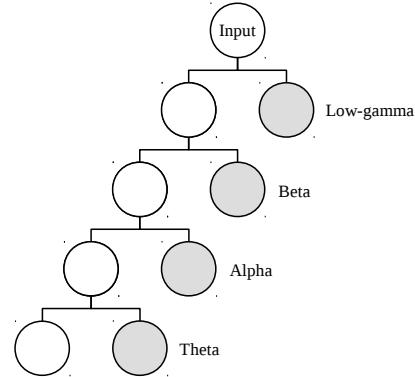


Fig. 1. Four-level wavelet decomposition scheme. The tree's root present the input epoch sampled at 100Hz. The remainder nodes are the scale (in white) and wavelet (in gray) coefficient sets. Main cerebral rhythm related to each wavelet coefficient set is shown on its right side.

C. Decision tree algorithms

A decision tree is a computational tree whose internal nodes are tests made on input patterns (the features) and the leaf nodes are classes (in this case, awake or sleep) [17]. There are several algorithms based on decision trees as the random trees, REP trees, CART, J48 tree, ID3 tree and C.45 tree. They can differ in relation to the attribute type (numerical and/or categorical), number of child nodes (binary tree or not), rules for growing themselves, etc. In this study, we focus in the three first tree decision algorithms. The Weka [18] data mining tool is used for the classification task based on the $F = 12$ (standard deviation, kurtosis and skewness for four wavelet coefficient sets) extracted features.

The random trees select randomly $K = \log_2(F) + 1$ features to grow themselves and do not apply pruning techniques. By other hand, the REP trees grow by computing the information gain estimator [1] for each attribute. Furthermore, REP trees apply a reduced error pruning technique. CART grow by estimating the Gini impurity [19] besides applying a pruning technique that prizes at minimal complexity.

All these tree algorithms are grown by considering a relevant to the problem training set. The complete balanced feature dataset is then split randomly into training and testing sets. Fig. 3 illustrates the features' dataset organization. The training set is used to grow the tree algorithms, whilst the testing one is used to evaluate them. Approximately a half of the features in the training and testing sets refer to the awake stage whilst the other half is relative to the sleep stage according to the experts' annotation.

III. RESULTS AND DISCUSSION

Several metrics can be used to evaluate a classification method, as the accuracy, precision, recall (sensitivity), and Cohen's kappa coefficient [20]. These metrics can be computed through analysis of the confusion matrix. The confusion matrix relates the accepted as truth data (sleep experts' scoring) versus the predicted data (the classifier output) and gives an overview of all hits and misses by class.

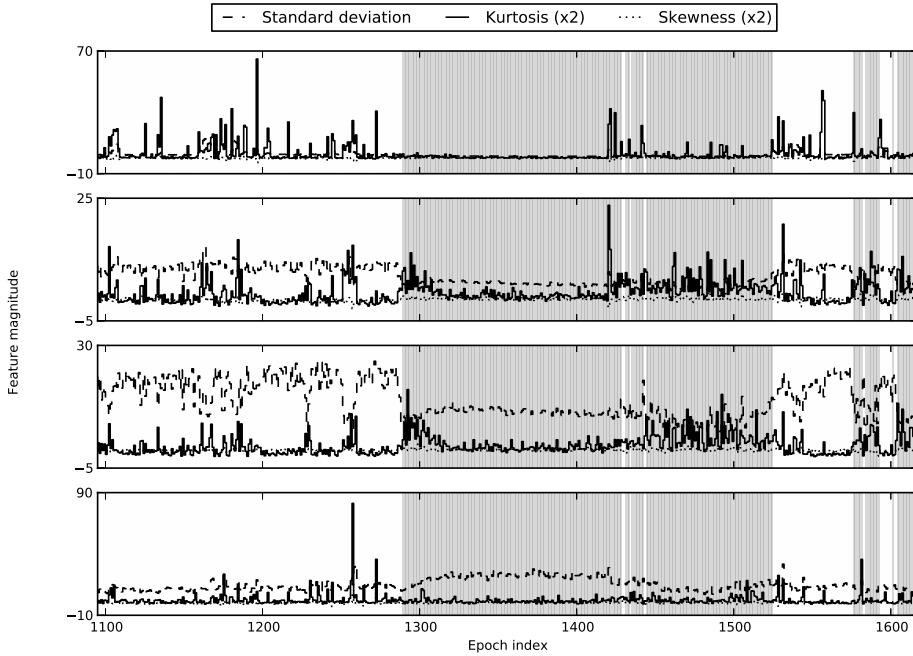


Fig. 2. Standard deviation, kurtosis (multiplied by 2) and skewness (multiplied by 2) for several 30-second epochs of the first night recording of the subject labeled as 05 according to the Physionet. The areas where the background is white are relative to the awake stage whilst those where the background is gray are relative to the sleep stage. These markings are according to the sleep experts.

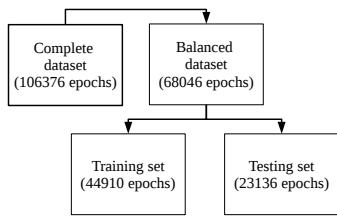


Fig. 3. Data preprocessing and separation in training and testing sets.

Let TP , TN , FP and FN be the quantity of true positives, true negatives, false positives and false negatives. Thus, it is possible to calculate the method's accuracy (ACC) through

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}. \quad (1)$$

Similarly, the precision (PRE) and recall (RCL) for each class are given, respectively, by

$$PRE = \frac{TP}{TP + FP} \text{ and} \quad (2)$$

$$RCL = \frac{TP}{TP + FN}. \quad (3)$$

The Cohen's kappa coefficient (κ) can be calculate through

$$\kappa = \frac{\pi_0 - \pi_e}{1 - \pi_e}, \quad (4)$$

where π_0 is an observational probability of agreement and π_e is a expected probability by chance [20]. The values of π_0 and π_e are computed respectively through [1]

$$\pi_0 = \frac{\sum_{i=1}^N M_{ii}}{\sum_{i=1}^N \sum_{j=1}^N M_{ij}} \text{ and} \quad (5)$$

$$\pi_e = \frac{\sum_{i=1}^N \left(\sum_{j=1}^N M_{ij} \sum_{j=1}^N M_{ji} \right)}{\left(\sum_{i=1}^N \sum_{j=1}^N M_{ij} \right)^2}, \quad (6)$$

where $N = 2$ is the quantity of classes of the problem and M_{ij} is the $\{i, j\}$ -th value of the confusion matrix.

Tables I, II and III present, respectively, the confusion matrix for the random tree, REP tree and CART algorithms. Its is possible to notice the high performance achieved by all the methods through analysis of the precision and recall values (optimal classifier has 100% of precision and recall).

TABLE I. CONFUSION MATRIX FOR RANDOM TREE

		Physionet's annotation	
		Awake	Sleep
Classifier's score	Awake	10871	684
	Sleep	688	10893
Precision (%)		94.1	94.1
Recall (%)		94.0	94.1

Accuracies reached 94.07%, 95.79% and 95.72% and Cohen's kappa coefficient, 0.88, 0.92 and 0.91, respectively, for

TABLE II. CONFUSION MATRIX FOR REP TREE

		Physionet's annotation	
		Awake	Sleep
Classifier's score	Awake	11147	563
	Sleep	412	11014
Precision (%)		95.2	96.4
Recall (%)		96.4	95.1

TABLE III. CONFUSION MATRIX FOR CART

		Physionet's annotation	
		Awake	Sleep
Classifier's score	Awake	11126	558
	Sleep	433	11019
Precision (%)		95.2	96.2
Recall (%)		96.3	95.2

the random tree, REP tree and CART algorithms. The average accuracy and Cohen's kappa are also computed after a 10-fold cross-validation [19]. In this case, the complete balanced feature dataset (containing 68,046 30-second epochs) is considered. Results achieved, respectively for random tree, REP tree and CART algorithms, 94.39%, 95.63% and 95.64% of accuracy and 0.89, 0.91 and 0.91 of Cohen's kappa coefficient. According to Landis and Koch [20], methods which kappa coefficient is greater than 0.80 are considered excellent.

In comparison with a recent study, Sano and Picard [21], the current study has comparable or even higher accuracy in relation to the considered EEG (83%), wrist (73%) and combined EEG and wrist feature sets (95%). These authors have assessed their feature sets in k -nearest neighbor (with $k=1-4$) and support vector machines under a 10-fold cross-validation. Additionally, the results presented in the current study also outperform those reported in Section I.

IV. CONCLUSION

This study performs the awake and sleep stages separation through analysis of a single EEG channel, which in real applications can be acquired by a portable grade consumer EEG headset. Furthermore, the four-level discrete wavelet transform of Daubechies family with two vanish moments (Db2) is considered as signal analyzer and feature extractor. Three statistical measures – the standard deviation, kurtosis and skewness – are computed for all the wavelet coefficient sets. In order to test the selected feature set, three decision tree algorithms are evaluated with the same training and testing sets.

The methodology is assessed through precision, recall, accuracy and Cohen's kappa coefficient measurements. The achieved results suggest that (i) the feature set is robust and (ii) simple decision tree techniques with or without pruning can provide good results in terms of sleep and awake identification.

Future works include the investigation of other features in the time and scale domains besides the test of the methodology presented in this study in a real scenario with a consumer grade EEG headset.

ACKNOWLEDGMENT

The first author would like to thank CAPES for his Master's Scholarship. The second and third authors would like to thank

FAPERGS, grant PG n.1873-25.51/13-0.

REFERENCES

- [1] L. Fraiwan, K. Lweesy, N. Khasawneh, H. Wenz, and H. Dickhaus, "Automated sleep stage identification system based on time-frequency analysis of a single eeg channel and random forest classifier," *Computer Methods and Programs in Biomedicine*, vol. 108, no. 1, pp. 10–19, 2012.
- [2] R. J. Cole, D. F. Kripke, W. Gruen, D. J. Mullaney, and J. C. Gillin, "Automatic sleep/wake identification from wrist activity," *Sleep*, vol. 15, no. 5, 1992.
- [3] W. Karlen and D. Floreano, "Adaptive sleep-wake discrimination for wearable devices," *IEEE Transactions on Biomedical Engineering*, vol. 58, no. 4, 2011.
- [4] J. Tilmanne, J. Urbain, M. V. Kothare, A. V. Wouwer, and S. V. Kothare, "Algorithms for sleep-wake identification using actigraphy: a comparative study and new results," *Journal of Sleep Research*, vol. 18, no. 1, pp. 85–98, 2009.
- [5] E. L. J. M. van Luijtelaar and A. M. L. Coenen, "An eeg averaging technique for automated sleep-wake stage identification in the rat," *Physiology and Behavior*, vol. 33, pp. 837–841, 1983.
- [6] B. Kemp, A. H. Zwinderman, B. Tuk, H. A. C. Kamphuisen, and J. J. L. Oberye, "Analysis of a sleep-dependent neuronal feedback loop: the slow-wave microcontinuity of the EEG," *IEEE Transactions on Biomedical Engineering*, vol. 47, pp. 1185–1194, 2000.
- [7] A. Rechtschaffen and A. Kales, "A manual of standardized terminology, techniques and scoring system for sleep stages of human subjects," *Electroencephalography and Clinical Neurophysiology*, vol. 26, no. 6, p. 644, 1969.
- [8] C. Iber, S. Ancoli-Israel, A. L. C. Jr, and S. F. Quan, *The AASM Manual for the Scoring of Sleep and Associated Events: Rules, Terminology and Technical Specifications*, American Academy of Sleep Medicine, 2007.
- [9] I. H. Witten, E. Frank, and M. A. Hall, *Data Mining: Practical Machine Learning Tools and Techniques*, 3rd ed. Morgan Kaufmann/Elsevier, 2011.
- [10] I. Daubechies, *Ten Lectures on Wavelets*. Philadelphia, PA, USA: Society for Industrial and Applied Mathematics, 1992.
- [11] A. Subasi, "Automatic recognition of alertness level from eeg by using neural network and wavelet coefficients," *Experts Systems with Applications*, vol. 28, no. 4, pp. 701–711, 2005.
- [12] J. X. and K. A., "Gamma rhythms in the brain," 2011.
- [13] M. Corsi-Cabrera, Z. Muoz-Torres, Y. del Ro-Portilla, and M. Guevara, "Power and coherent oscillations distinguish REM sleep, stage 1 and wakefulness," *International Journal of Psychophysiology*, vol. 60, no. 1, pp. 59 – 66, 2006.
- [14] B. Koley and D. Dey, "An ensemble system for automatic sleep stage classification using single channel eeg signal," *Computers in Biology and Medicine*, vol. 42, no. 12, pp. 1186–1195, 2012.
- [15] M. Asadzadeh, E. Hashemi, and A. Kozakevicius, "Efficiency of combined daubechies and statistical parameters applied in mammography," *Applied and Computational Mathematics: An International Journal*, vol. 12, no. 3, pp. 289–305, 2013.
- [16] M. Ronzhina, O. Janoušek, J. Kolářová, P. Honzik, and I. Provazník, "Sleep scoring using artificial neural networks," *Sleep Medicine Reviews*, vol. 16, pp. 251–263, 2012.
- [17] N. J. Nilsson, *Introduction to Machine Learning*, draft ed., 1998.
- [18] M. Hall, E. Frank, G. Holmes, B. Pfahringer, P. Reutemann, and I. H. Witten, "The weka data mining software: An update," *SIGKDD Explorations*, vol. 11, no. 1, 2009.
- [19] E. Alpaydin, *Introduction to Machine Learning*, 2nd ed. The MIT Press, 2010.
- [20] J. R. Landis and G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, vol. 33, pp. 159–174, 1977.
- [21] A. Sano and R. Picard, "Comparison of sleep-wake classification using electroencephalogram and wrist-worn multi-modal sensor data," in *Engineering in Medicine and Biology Society (EMBC), 2014 36th Annual International Conference of the IEEE*, 2014, pp. 930–933.

APÊNDICE D – REVOCAÇÃO DE S1 × PRÉ-PROCESSAMENTO

Visando obter melhores resultados para a revocação do estágio de sono S1 (presente nas classificações de 5 e 6 estágios de sono), algumas abordagens de pré-processamento dos dados de entrada foram testadas. Todas elas baseiam-se na desconsideração da informação média do sinal, visando minimizar as variações intrínsecas dos sinais fisiológicos de cada paciente.

Em uma abordagem global, foi calculado o valor médio do sinal completo de EEG de cada paciente. Cada amostra do sinal pré-processado é dada, ou pela (i) subtração da amostra original da média ou pela (ii) divisão dessa amostra pela média. Os mesmos procedimentos – ou seja, de (iii) subtração da média e (iv) divisão pela média – foram feitos também considerando, em uma abordagem local, não a média do sinal completo mas sim de cada época. Os melhores resultados são obtidos quando o cenário (ii) é considerado na etapa de pré-processamento. Neste caso, os valores para revocação de S1 nas classificações de 5 e 6 estágios de sono sobem de 6,1% para 8,4% e 5,8% para 8,2%, respectivamente. Medidas de precisão também atingem melhores resultados, aumentando de 59,9% para 61,3% e de 60,5% para 63%.

Como outra alternativa para remoção da informação média, com inspiração em ASAD-ZADEH; HASHEMI; KOZAKEVICIUS (2013), optou-se por calcular e subtrair a linha base de cada época. A linha base, aqui, é encontrada após a decomposição do sinal em questão (época) em seis níveis (um nível a mais do que é utilizado no restante da metodologia). A informação média neste nível é preservada, todos os coeficientes de detalhe são anulados e a transformada *wavelet* inversa de Daubechies de ordem 2 é aplicada. As Figuras D.1a, D.1b e D.1c ilustram, respectivamente, um sinal de entrada (época), sua linha base, e sua versão pré-processada de acordo com esse procedimento.

A retirada da linha base proporcionou acréscimos de 1,6% e 1,7% na precisão e revocação de S1 na rotulagem de 5 estágios de sono. Considerando o arranjo de 6 estados, têm-se, respectivamente, um aumento de 1,4% e 2% nos valores dessas mesmas métricas.

Sabe-se que a classificação de S1 é um problema em aberto (CORSI-CABRERA et al., 2006; ZHU; LI; WEN, 2014). Aqui, algumas possibilidades de pré-processamento adicionais foram investigadas de modo a manter todo o restante da metodologia idêntico ao que já foi apresentado. Como trabalhos futuros, pretende-se intensificar ainda mais essas pesquisas ainda que isto gere outros trabalhos que focam apenas na identificação deste estado de sono, como feito para REM em IMTIAZ; RODRIGUEZ-VILLEGAS (2014) e SWS em SU et al. (2015).

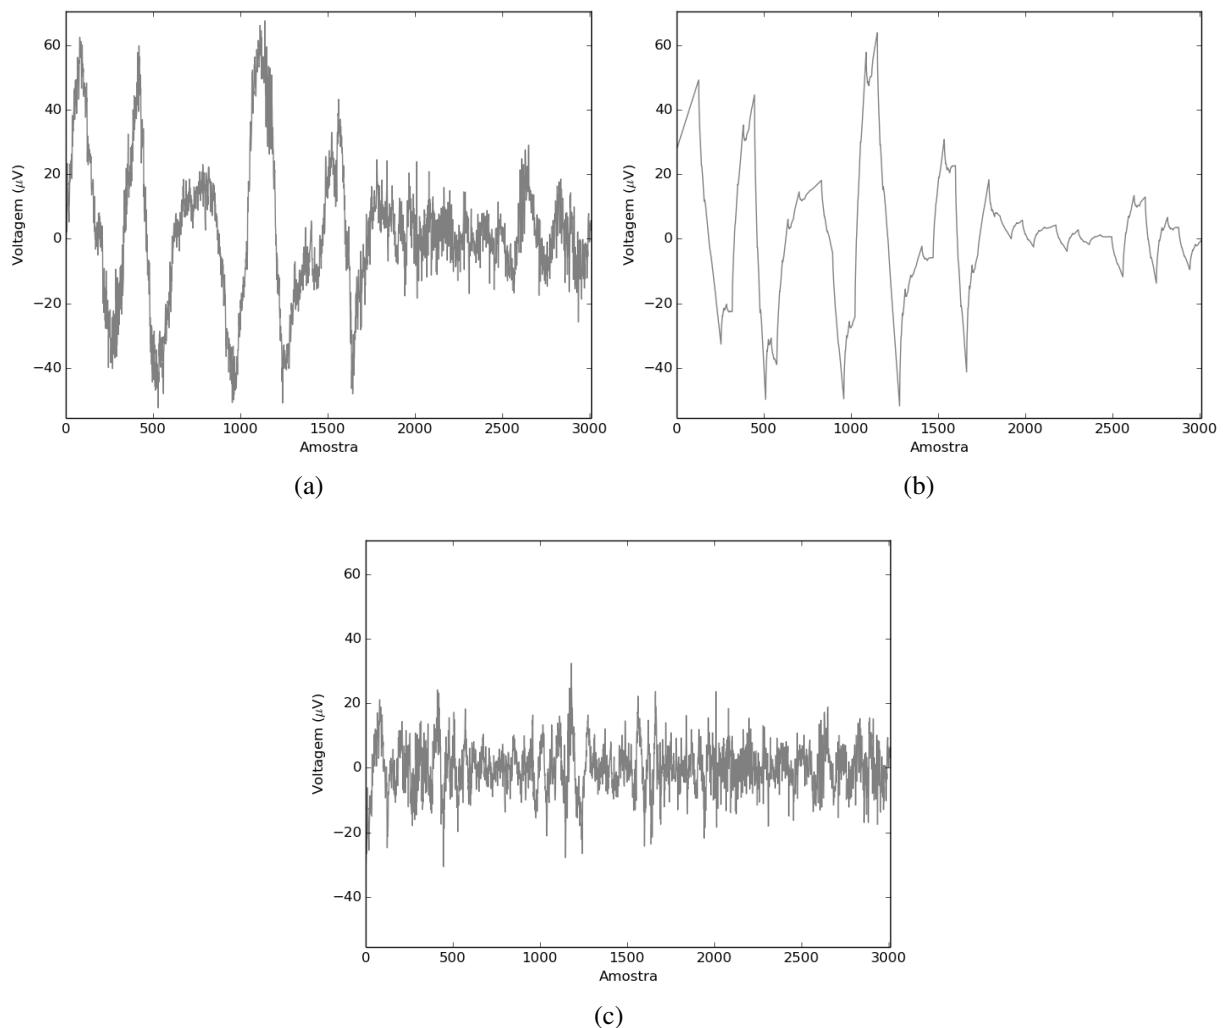


Figura D.1: Remoção de linha base: (a) terceira época da segunda noite de sono do sujeito de número 00, (b) sua linha base, e (c) época sem sua linha base.

APÊNDICE E – PRODUÇÃO CIENTÍFICA

Os trabalhos produzidos pelo autor deste trabalho e colaboradores entre 2014 e 2016 estão listados abaixo.

Trabalhos relacionados

- Silveira, T. L. T., Rodrigues, C. R., e Kozakevicius, A. J.; Técnicas de Reamostragem de Sinais e seus Impactos no Processamento Digital nos Domínios do Tempo e da Frequência; Anais do Primer Encuentro de Jóvenes Investigadores en Matemática Aplicada de la Asociación de Universidades Grupo Montevideo (AUGM); p. 39-40; 2014.
- Silveira, T. L. T., Kozakevicius, A. J. e Rodrigues, C. R.; Awake/Sleep Scoring Through Wavelet Analysis Associated to Decision Tree Algorithms; Anais do 30º Simpósio Sul de Microeletrônica; 2015.
- Silveira, T. L. T., Kozakevicius, A. J. e Rodrigues, C. R.; Automated drowsiness detection through wavelet packet analysis of a single EEG channel; Expert Systems With Applications; Aceito em 23/02/2016.
- Silveira, T. L. T., Kozakevicius, A. J. e Rodrigues, C. R.; Single-channel EEG sleep stage classification based on a streamlined set of statistical features in wavelet domain; Submetido para Medical & Biological Engineering & Computing; 2015.

Demais trabalhos

- Silveira, T. L . T., Bayer, F. M., Cintra, R. J., Kulasekera, S., Madanayake, A. e Kozakevicius, A. J.; An orthogonal 16-point approximate DCT for image and video compression; Multidimensional Systems and Signal Processing; Springer US; p. 1-18; 2014. DOI: 10.1007/s11045-014-0291-6
- Silveira, T. L. T., Pasin, M. e Lima, J. C. D.; Experimental Evaluation of Intersection Control Policies: a Simulation Based on Ubiquitous Computing and VANETs; Proceedings of XL Conferencia Latinoamericana en Informática; 2014.
DOI: 10.1109/CLEI.2014.6965162
- Silveira, T. L. T., Bayer, F. M., Cintra, R. J. S. e Kozakevicius, A. J.; Algoritmos Rápidos para Cifragem de Imagens Utilizando Aproximações da DCT de Comprimento 8; Proceeding Series of the Brazilian Society of Applied and Computational Mathematics; volume 2; no. 1; 2014. DOI: 10.5540/03.2014.002.01.0123
- Silveira, T. L. T., Bayer, F. M., Cintra, R. J. S.; Método para o Cômputo Aproximado da Transformada Discreta do Cosseno de Comprimento 16 com Baixo Custo Aritmético em Aplicações de Compressão de Imagem e Vídeo. Patente depositada em 22/12/2015 junto ao Instituto Nacional da Propriedade Industrial. Número de registro: BR1020150322720